学校代号 10536　　学　　号

分 类 号 TU43　　密　　级 公开

长沙理工大学

# 硕士学位论文

# 基于随机森林的诱发滑坡降雨阈值及稳定性评价系统

学位申请人姓名 ***

所　在　学　院 水利与海洋工程学院

专业学位类别 土木水利

专业学位专业领域 水利工程

校内导师姓名及职称 ***

校外导师姓名及职称 ***

论文提交日期 2025.4.10

2025.04.10.22.12.207791

送审稿—长沙理工大学

2025.04.10.22.12.207791

# 摘　要

中国复杂的地质构造与季风气候特征使其成为全球地质灾害频发的国家之一。统计数据显示，滑坡灾害占各类地质灾害的 71%，而 90%以上的滑坡由降雨诱发。然而，现有滑坡预警体系存在预警精度不足、区域普适性较差等问题，其根本原因在于诱发滑坡临界降雨阈值具有显著的空间异质性，不仅不同地质单元之间存在差异，同一山体相邻边坡的触发阈值亦可能存在较大差异。针对上述问题，本论文以均质边坡模型为研究对象，分析了降雨诱发滑坡的作用机理，建立了基于随机森林的边坡安全系数预测模型，进一步构建了基于随机森林的降雨诱发滑坡阈值模型，最终将该模型集成到边坡稳定性评价系统中，开发了基于诱发滑坡降雨阈值模型的边坡稳定性评价系统。本文主要工作和结论包括：

（1）建立了基于随机森林的边坡安全系数预测模型。结果显示，预测模型在测试集上取得了高达 0.99998 的决定系数（$R^2$）和仅为 0.00132 的均方根误差（RMSE），具有极高的预测精度。同时，通过分析降雨强度和持续时间共同作用下边坡渗流场的动态演变及其对安全系数的影响，揭示了降雨渗流与边坡失稳之间的耦合机制。

（2）建立了基于随机森林的诱发滑坡降雨阈值模型。通过采用全局寻优与交叉验证确定了超参数最优组合，使得模型的决定系数（$R^2$）提高至 0.9079，均方误差（RMSE）降低了 50.1%，验证了其优越的泛化性能。相较于传统经验阈值，本研究所建立的单体化降雨阈值模型具有更高的工程应用价值。

（3）研发了基于诱发滑坡降雨阈值模型的边坡稳定性评价系统。该系统创新地将边坡稳定性评价系统与所构建的降雨阈值模型相结合，开发了基于诱发滑坡降雨阈值模型的边坡稳定性评价系统。该系统在易用性和可视化方面表现良好，为边坡稳定性评估提供了一个有效的工具。

**关键词**：随机森林；降雨诱发滑坡；降雨阈值；边坡稳定性；评价



2025.04.10.22.12.207791

# ABSTRACT

China's complex geological structure and monsoon climate characteristics make it one of the countries most prone to frequent geological disasters worldwide. Statistical data indicate that landslide disasters account for 71% of various geological hazards, with over 90% of these landslides being rainfall-induced. However, existing landslide early warning systems face challenges including insufficient prediction accuracy and poor regional applicability. This primarily stems from the significant spatial heterogeneity in critical rainfall thresholds for landslide initiation - substantial variations exist not only between different geological units but also among adjacent slopes within the same mountain mass. To address these issues, this study employs homogeneous slope models to analyze the mechanisms of rainfall-induced landslides. We establish a Random Forest-based prediction model for slope safety factors and further develop a Random Forest-driven rainfall-induced landslide threshold model. These models are ultimately integrated into a comprehensive slope stability evaluation system. The main contributions and conclusions of this research include:

(1) A Random Forest-based prediction model for slope safety factor was developed. The results demonstrate that the proposed model achieves exceptional predictive accuracy, attaining a coefficient of determination ($R^2$) of 0.99998 and a root mean square error (RMSE) of merely 0.00132 on the testing set. Furthermore, through systematic analysis of the dynamic evolution of slope seepage fields under combined rainfall intensity-duration conditions and their subsequent impacts on safety factors, this study elucidates the coupling mechanism between rainfall-induced seepage processes and slope instability.

(2) A Random Forest-based rainfall threshold model for landslide triggering was developed. By employing global optimization and cross-validation to determine the optimal combination of hyperparameters, the model's coefficient of determination ($R^2$) was enhanced to 0.9079 while



2025. 04. 10. 22. 12. 207791

the Root Mean Square Error (RMSE) was reduced by 50.1%, thereby validating its superior generalization performance. Compared with conventional empirical thresholds, the individualized rainfall threshold model established in this study demonstrates greater engineering applicability

(3) Developed a slope stability assessment system based on a landslide-triggering rainfall threshold model. This system innovatively integrates slope stability evaluation with the established rainfall threshold model, creating a novel slope stability assessment framework anchored in landslide-precipitation correlation mechanisms. The developed system demonstrates superior performance in user-friendliness and visualization interfaces, serving as an effective tool for slope stability evaluation that significantly enhances the precision of rainfall-induced landslide prediction and prevention.

**KEY WORDS:**Random Forest; Rainfall-induced Landslides; Rainfall Threshold; Slope Stability; Evaluation

送审稿—长沙理工大学



2025. 04. 10. 22. 12. 207791

送审稿—长沙理工大学



2025.04.10.22.12.207791

# 目　录


**摘　要** ..... I

**ABSTRACT** ..... II

**第 1 章 绪论** ..... 1

1.1 研究背景与意义 ..... 1

1.2 国内外研究现状 ..... 2

1.2.1 随机森林算法在边坡安全中的应用研究现状 ..... 2

1.2.2 诱发滑坡降雨阈值的研究现状 ..... 3

1.2.3 滑坡灾害预警研究现状 ..... 5

1.3 研究内容与技术路线 ..... 7

**第 2 章 随机森林算法基本原理** ..... 10

2.1 机器学习的原理 ..... 10

2.2 机器学习工作流程 ..... 11

2.3 随机森林理论 ..... 12

2.3.1 随机森林基础分析 ..... 13

2.3.2 随机森林回归基本原理 ..... 13

2.3.3 随机森林优缺点 ..... 15

2.4 C/S 架构 ..... 15

**第 3 章 基于随机森林的边坡安全系数预测模型研究** ..... 17

3.1 模型方案设计 ..... 17

3.1.1 数据集的建立 ..... 17

3.1.2 数据集可视化分析 ..... 19

3.2 降雨诱发滑坡机理研究 ..... 22

3.2.1 数值模拟软件的介绍 ..... 22

3.2.2 数值模型构建与参数选取 ..... 22

3.2.3 模型边界条件设计 ..... 23

3.2.4 数值模拟结果与分析 ..... 24


2025.04.10.22.12.207791

3.3 模型性能指标 ..... 28
3.3.1 均方误差 ..... 29
3.3.2 均方根误差 ..... 29
3.3.3 决定系数 ..... 29
3.4 安全系数预测模型 ..... 30
3.4.1 预测模型的构建及结果分析 ..... 30
3.4.2 特征重要性分析 ..... 33
3.5 本章小结 ..... 34
**第 4 章 基于随机森林的诱发滑坡降雨阈值模型** ..... 36
4.1 诱发滑坡的降雨强度-历时阈值曲线 ..... 36
4.1.1 降雨强度-降雨历时阈值模型介绍 ..... 36
4.1.2 降雨历时的确定 ..... 37
4.1.3 降雨强度初步确定 ..... 38
4.2 计算流程与样本构造 ..... 39
4.2.1 计算流程 ..... 39
4.2.2 模型参数选取及范围确立 ..... 40
4.2.3 样本构造方法 ..... 41
4.3 降雨诱发滑坡的降雨阈值研究 ..... 43
4.3.1 前期准备基础 ..... 43
4.3.2 批量文件的处理与生成 ..... 44
4.3.3 降雨阈值数据的提取与处理 ..... 45
4.3.4 数据的拟合 ..... 48
4.4 基于随机森林的诱发滑坡降雨阈值模型构建 ..... 49
4.4.1 随机森林的构建步骤 ..... 49
4.4.2 数据准备与预测 ..... 49
4.4.3 随机森林模型的调优 ..... 51
4.4.4 诱发滑坡降雨阈值预测模型的结果分析 ..... 57
4.5 本章小结 ..... 60

2025.04.10.22.12.207791

第 5 章 基于诱发滑坡降雨阈值模型的边坡稳定性评价系统 ..... 61
5.1 需求分析 ..... 61
5.2 系统架构设计与实现环境 ..... 62
5.3 系统架构构建 ..... 62
5.3.1 系统开发目标 ..... 62
5.3.2 系统架构层次划分 ..... 63
5.4 系统功能架构设计及灾害预警应用 ..... 63
5.4.1 程序设计流程 ..... 64
5.4.2 系统交互界面架构设计 ..... 65
5.4.3 用户信息管理 ..... 69
5.4.4 数据管理 ..... 69
5.4.5 滑坡预警分析 ..... 70
5.5 本章小结 ..... 74
第 6 章 结论与展望 ..... 76
6.1 结论 ..... 76
6.2 展望 ..... 77
参考文献 ..... 78
致谢 ..... 84
附录 A 攻读学位期间的主要研究成果 ..... 85
附录 B 攻读学位期间主持（参与）的科研（实践）项目 ..... 86

送审稿 长沙理工大学

2025.04.10.22.12.207791

# 第1章 绪论

## 1.1 研究背景与意义

基于地质力学与灾害链理论，滑坡失稳过程可界定为岩土复合体在重力势能主导下，受外源水动力或构造活动诱发，沿剪切破坏面产生位移的地质灾变现象[1]。此类灾害具有突发性强、致损路径复杂等特征。更具威胁性的是，滑坡体运移物质通过物质-能量耦合效应，常在灾后 72 小时内形成堰塞湖并引发洪涝链式反应，造成不可估量的影响。

滑坡作为一种常见的地质灾害，在全球范围内频繁发生，其诱因多为降水或地震等自然因素。2003 年 7 月，日本熊本县因连降暴雨引发了一系列滑坡灾害，其中集村的滑坡在山洪作用下演变为泥石流，对村庄造成了毁灭性打击，导致大量人员伤亡和财产损失[2]。2010 年 6 月，贵州关岭县岗乌镇因强降雨发生滑坡，致使 99 人失去生命，37 户房屋被掩埋[3]。2018 年 10 月 11 日，印度尼西亚西苏门答腊省、北苏门答腊省因降水影响，发生多处山体滑坡，致使许多房屋倒塌，死亡人数超过 27 人。Petley 建立的全球滑坡数据库显示，2004 年至 2010 年间共发生 2620 起滑坡，导致 32322 人死亡，其中喜马拉雅山脉沿线和中国是滑坡致死人数最多的地区[4]。

中国陆域范围内山地区域占国土总面积的 65%以上，受多期构造运动影响形成断裂带纵横交错的复杂地貌特征。因我国阶梯式地形格局与东亚季风、大陆性气候的复合作用使得滑坡灾害在我国发生频率较高。根据我国统计的地质灾害表，如表 1.1 所示：在 2014 年到 2018 年间，由降雨诱发的地质灾变事件占总量的 84.34%，且最终导致发生滑坡的总数量占总的地质灾害数的 67.8%，凸显该类灾害在自然致灾因子中的主导地位。

表 1.1 2014~2018 年我国地质灾害灾情表

| 年度 | 2014 | 2015 | 2016 | 2017 | 2018 | 合计 |
|---|---|---|---|---|---|---|
| 总地灾数（起） | 10907 | 8224 | 9710 | 7521 | 2966 | 39328 |
| 降雨为主致灾（起） | 10328 | 7047 | 8937 | 6857 | 2738 | 33169 |
| 直接损失（亿） | 54.1 | 24.9 | 31.7 | 35.9 | 14.7 | 161.3 |
| 伤亡人数（人） | 618 | 425 | 714 | 523 | 186 | 2466 |
| 滑坡（起） | 8128 | 5616 | 7403 | 5524 | 1632 | 26671 |



2025.04.10.22.12.207791

滑坡的发生与降雨密切相关，由表 1.1 可知，2014-2018 期间 84.3%的地质灾害事件与降雨存在直接关联，降雨是导致滑坡与泥石流发生的主要因素[5]。降雨的相关参数与滑坡的发生存在复杂的关系[6]。

基于防灾减灾体系现代化建设需求，构建滑坡失稳多源数据融合预警系统已成为国土安全保障的关键技术突破方向。本文以均质边坡模型为研究对象，首先对降雨诱发滑坡机理进行了研究，然后对随机森林算法在边坡安全系数上的预测进行了分析和验证。接着分析了由滑坡的 4 个特征输入对降雨强度 *I*-降雨历时 *D* 的影响，研究其特征输入与 *I-D* 曲线之间的关系，通过建立随机森林模型，找到了特征输入与 *I-D* 曲线之间的非线性关系，提出了一种基于随机森林的降雨诱发滑坡阈值模型。最后开发了一套基于 PyQt 的诱发滑坡降雨阈值的边坡稳定性评价系统，主要实现了数据库管理、预警分析、账号管理三部分功能，本研究对单体滑坡预警与防治具有重要的理论和现实意义。

## 1.2 国内外研究现状

### 1.2.1 随机森林算法在边坡安全中的应用研究现状

以往的研究强调了可用于评估边坡安全的各种方法，其选择通常受到时间、预算和问题复杂性的影响，此外，数值模拟计算的方法可能很费力且计算密集。近几十年来，机器学习成为预测边坡安全系数的有力工具，允许分析大型数据集并识别其中的复杂模型[7-9]，而随机森林算法对高维数据问题有着良好的可扩展性和并行性，并且作为一种由数据驱动的非参数分类和回归方法，使用随机森林算法时无需过度调参以及分类先验知识[10]。

1984 年 Breiman 等开创性地提出了分类树算法，通过引入样本重采样策略显著提升分类效率与计算效能[11]。且该团队于 2001 年进一步优化决策树架构，发展出具有自主特征选择机制的随机森林框架[12]。在工程应用领域，李亭等通过受试者特征曲线评估方法，对深圳中西部 221 处滑坡变形案例进行特征分析，验证了随机森林算法在岩土体稳定性分级中的适用性[13]。汶川震后重建研究中，黎新裕构建了自动化地灾信息提取系统，采用随机森林模型实现区域滑坡风险量化评估[14]。胡添翼等基于 99 组边坡状态样本构建预测模型，经交叉验证表明随机森林的预测精度较传统支持向量机提升 15.6%（F-score=0.89）[15]。Fang Chen 等创新性提出了一种基于概率回归的滑坡检测方法，该方法结合了 HOG、LBP 和 DEM 导数等特征，利用随机森林模型计算像素属于滑坡的概



2025.04.10.22.12.207791

率，从而实现滑坡的检测。实验结果表明，该方法在检测准确性和鲁棒性方面表现良好，F 值大多高于 0.9，用户精度高于 90%，且生产者精度均为 100%，能够有效检测出滑坡区域，为实际应用提供了潜在途径[16]。王红珠集成 Scoket 通信架构与随机森林算法，构建了实时动态预警平台[17]。针对三峡库区，孙德亮通过逻辑回归与随机森林耦合模型，使用安全系数作为输出，建立了降雨-位移联合预警体系[18]。毛宇昆在宁南山区研究中，对比随机森林等多种分类器性能后优选组合模型，同时自主研发了边坡状态智能研判系统[19]。刘睿等基于 22 维特征空间构建易发性评价模型，其预测结果与实地调查高度吻合，验证了随机森林模型在边坡应用的准确性[20]。Liu 等提出地质探测器-随机森林混合模型，采用 13 项致灾因子构建的数据集在易发性区划中表现出 0.87 的 AUC 值。显示了其在滑坡预测中的优异表现[21]。

随着随机森林（Random Forest，RF）算法日趋成熟，基于该算法开展特征属性简化、消除冗余信息、学习复杂非线性关系及提升模型泛化能力等方面的研究已取得一系列成功成果[22-23]。然而，现有文献中关于运用 RF 算法解决土质边坡安全系数问题的研究相对匮乏。本研究依据土质边坡多因素影响特征，结合 RF 算法优势，采用 GeoStudio 软件构建样本数据集并应用随机森林模型进行土质边坡安全系数进行预测。

### 1.2.2 诱发滑坡降雨阈值的研究现状

阈值又叫临界值，是指地质过程触发所需物理量的极值边界[24-26]。在水文地质学领域，滑坡失稳的降雨阈值可定义为区分岩土体稳定态与失稳态的划分边界[27]。其应用目的在于依据特定降雨条件预测区域滑坡发生的可能性，对于降雨诱发的滑坡，阈值可体现为引发滑坡的最小降雨强度或时长、孔隙水压力下限、抗剪强度减弱程度或导致滑坡的最小位移值[28]。该研究范式自 20 世纪 60 年代逐步形成，1969 年 Endo 开创性提出最小致灾雨量概念，奠定了降雨阈值机制量化研究基础[29]。随后经过数年的发展，1974 年 Onodera 等通过 Logistic 回归分析，系统建立首个基于强度-历时（*I-D*）关系的定量判别模型[30]。这些研究成果为后续降雨阈值的发展奠定了基石。1980 年 Caine 突破地域限制，整合全球 73 个典型滑坡等灾例构建首个跨区域 *I-D* 双参数模型，经多区域验证具有 72%的适用性[31]，尽管初期存在争议，但其构建的降雨强度-历时（*I-D*）双参数模型现已成为滑坡灾变预测基准框架[32]。

目前对降雨阈值的研究主要分为以下两大类：



2025.04.10.22.12.207791

（1）物理型降雨阈值

物理机制型降雨阈值通过水-力耦合建模推演获得，需基于非饱和土力学原理与浅层坡稳定性控制方程进行系统构建。该方法整合土体的渗透系数、地形曲率指数及降水时空分布特征等多维参数，采用仿真模拟软件推求斜坡临界失稳状态的水文力学条件阈值。

在水文地质建模领域，Borga 等[33]针对浅层土质滑坡灾变机制，通过水文特征解析与滑坡稳定性评价，构建了阿尔卑斯山区的临界降雨阈值体系。Casadei 等[34]创新性融合地下径流监测数据与改进型无限滑坡模型，开发出具有工程适用性的浅层失稳预测框架，这种性能明显优于经验强度-持续时间阈值方法。Chang 等[35]采用 Logistic 概率模型与极限平衡理论交叉验证方法，揭示临界降雨阈值与实测雨强间的系统偏差。

当累积有效降水量突破临界值时，滑坡失稳概率呈指数增长。陈志强等[36]通过斜率阈值优化算法，将预测精度上升到新的高度。Megahan[37]证实湿润锋运移引发孔隙水压突变是边坡失稳的关键诱因。部分学者[38]因未充分考虑斜坡地质因素与其物理过程，得出的临界降雨阈值曲线无法精准的预测滑坡发生，也不能确定准确的临界降雨量和相应条件下的滑坡稳定性。魏丽等[39]结合实时监测数据与数值模拟，确定江西地区 24h 临界降水量阈值。常金源等[40]探究了降雨影响浅层滑坡的机制，并基于 Green-Ampt 模型考虑动水压力，建立了概念模型，分析边坡稳定性变化原因，提出饱和临界时间用于预警。何玉琼等[41]通过滑坡降雨阈值模型，综合多种影响因素进行分析，得出与实际滑坡位置吻合率达 80%。

（2）经验型降雨阈值

相较于物理模型法，经验性阈值因无需构建复杂的水文力学模型及繁琐的数学推导，具有显著的应用优势，现已成为滑坡预警领域主流的阈值确定方法。该方法通过整合区域降雨观测资料与历史滑坡事件数据库，运用数理统计手段揭示降雨参数与滑坡失稳的关联规律。学术界在此方向已取得丰硕成果，构建了涵盖不同空间尺度的降雨强度-历时（*I-D*）阈值体系。

国际研究方面，Guzzetti 等通过分析 2626 起浅层滑坡及泥石流灾害案例，首次建立了全球尺度的经验阈值模型[25]。后续学者发现大范围阈值的区域性适用局限，遂转向特定地质单元的精细化研究，如区域性 *I-D* 曲线的构建[42]。但该方法存在显著局限性：降



2025.04.10.22.12.207791

水数据统计方法（如雨量站插值方式）与降雨历时界定标准的差异易导致结果偏差，且在基础数据匮乏区域难以实施。

我国在该领域研究虽起步较晚，但随着监测技术的进步与基础数据库的完善，近年取得突破性进展。近年来也取得了显著进展。谢剑明等[43]基于浙江地区降雨强度-降雨量相关性研究，构建了区域有效降雨模型并确定临界阈值；詹良通等[44]采用参数敏感性分析法，系统揭示了土体渗透系数、边坡几何特征等要素对残积土滑坡降雨阈值(*I-D*)曲线的调控机理；陈洪凯等[45]系统评述现有研究体系，指出降雨参数选取与数据标准化处理是制约模型精度的关键因素，并提出改进方案；沈玲玲等[46]融合 TRMM 遥感降水产品与地面观测数据，创新性地构建了汶川地区多时间尺度（30d-0d）阈值模型；杨攀和杨军[47]通过引入前期降雨效应参数 A，在国际上率先建立非饱和土滑坡三维阈值曲面（A-I-D）；李巍岳等[48]基于 2005-2011 的 7 年间 60 例典型滑坡灾例的统计分析，构建了适用于短历时降雨（3-45h）的 *I-D* 预测模型，并借助敏感性分析验证其时空适用性。

总体而言，关于降雨诱发滑坡的降雨阈值研究已取得显著成果，尤其在边坡预警方面贡献突出。但仍存在显著不足：其一，传统统计模型多关注降雨参数而忽视滑坡本体特征（如滑体规模、几何形态等），导致宏观阈值难以准确反映局部失稳机制；其二，定性经验模型与定量预测系统的融合度不足，制约了阈值模型的实际应用价值。这些缺陷亟待通过多学科交叉研究加以改进。

与此同时，前面关于 *I-D* 阈值的研究，阈值公式里仅考虑了降雨强度和降雨持时两个参数变量，每一个地方若想获得属于自己的 *I-D* 阈值，就必须进行一次关于阈值的研究。研究工作不仅繁琐，而且没有一个统一的标准，在浪费了大量的人力物力情况下也不利于阈值研究的发展。此外，使用 RF 算法解决降雨阈值预测方面的文献少之又少，故本文将以临界降雨阈值作为滑坡发生的指标，基于广泛的数值模型结果为原始样本数据集，对临界降雨阈值进行预测。

### 1.2.3 滑坡灾害预警研究现状

滑坡灾害的产生受到多种因素的影响，其中降雨量在该过程中扮演关键驱动角色。基于致灾因子分析的滑坡预警体系，其构建原理在于通过科学确定不同参量的贡献度，再依据特定算法搭建起预警模型。这种空间预警机制可对具有不同地质环境背景的潜在风险区域实施灾害预报。近些年来，在滑坡预警这一研究领域，不管是技术层面所运用



2025.04.10.22.12.207791

的手段，还是学术范畴所采用的研究方法，均实现了显著的突破，取得了令人瞩目的进展。

（1）国外现状

滑坡灾害的预测预警研究在国际学术界具有较长的发展历程。20 世纪 70 年代起，国外学者逐步开展相关领域的系统性探索。Wilsen 于 1976 年率先针对美国加利福尼亚州区域，深入研究了滑坡地质灾害与降雨参数间的关联机制。随后，NewMan 与 Mark 在 1982 年通过系统考察当地历史灾情数据，发现引发滑坡的短历时降水临界值可达年降水总量的 30%，对滑坡预警的研究迈出了重要的一步[49]。到了 1984 年，Brand 等将研究目光投向香港地区，通过定量分析，最终确定该地区小时与日降雨临阈值分别为 70 毫米和 200 毫米，达到此阈值后将会导致滑坡，可作为该地的滑坡预警[50]。

上世纪 90 年代，相关研究方法呈现多元化发展。Montgomery 和 Dietrich 在 1994 年创新性地引入地形效应参数，构建了基于土壤含水率的滑坡预测模型[51]。同期，Mejia 和 Wohl 针对格伦伍德泉地区完成地质灾害危险性量化评估，并开发了系统的风险评价体系[52]。1997 年，Glade 对新西兰降雨型滑坡展开动力学分析，创新性地将累积降水量、实时降雨强度及土体持水状态作为核心参数，成功搭建预警预测框架[53]。

进入 21 世纪后，相关研究持续深化。Daha 和 Hasegawa 于 2008 年对尼泊尔喜马拉雅山区进行专题研究，首次明确了该特殊地质单元的降水触发阈值，为喜马拉雅山地区提供了可靠的滑坡预警系统[54]。至 2020 年，Adrian 等通过 logistic 回归函数和长期降水时间相结合分析揭示了土壤持水状态与滑坡发生概率的定量关系，研究表明，此方法优于早期滑坡的预警系统 LEWS[55]。同年，Niu Hongtao 将人工智能技术引入该领域，基于改进型 BP 神经网络算法构建了新型地质灾害预警模型[56]。

（2）国内现状

我国滑坡地质灾害预警研究体系呈现渐进式发展特征。在 1982 年，王兰生等针对四川盆地强降雨诱发的滑坡失稳现象开展研究，首次确定该区域触发滑坡地质灾害的 24 小时临界雨量为 200 毫米，同时对其区域内的防治措施展开了探讨[57]。随着研究深入，殷坤龙和晏同珍在 1987 年创新性构建了区域内滑坡的危险性分级体系，通过双模型对比验证提升了滑坡预测精度[58]。至 1996 年，惠振德和李晓玲选取陕南地区六个关键地质参数展开特征解析，由此提出适应区域特点的滑坡防灾对策[59]。



2025.04.10.22.12.207791

新世纪以来方法学持续革新，2001 年王平突破传统模式，将改进型聚类算法应用于农业地质灾害分区研究，通过实证研究验证了算法效能，为防灾减灾工作做出了贡献[60]。2004 年李广洁等在吉林地区引入二级模糊综合评价体系，实现了滑坡地质灾害易发区的科学区划[61]。三峡工程相关研究取得显著进展，2006 年李铁峰和丛威青运用 Logistic 回归法和前期有效降雨量相结合确立了该区域降雨阈值，并验证了其滑坡预报的准确性[62]，随后程温鸣等于 2013 年对秭归县开展易发性的滑坡建模，并通过空间验证完善了预测模型[63]。

近年来的研究呈现多技术融合趋势，2017 年戴岚欣等在九寨沟构建了多因子耦合的易发性评估框架[64]。文海家等 2018 年基于逻辑回归模型对滑坡历史灾变数据实施深度挖掘，证实了预测模型结果的统计显著性[65]。2019 年王慧芳等选取甘肃礼县作为典型区域，不仅完成滑坡易发性分级评价，更引入 AUC 指标进行预测模型验证[66]。2020 年成为研究突破年，李明波等基于雪峰山地区的降雨数据与统计学相结合的方法，为该区域精准化滑坡预警做出了贡献[67]，同期陈平等针对雪峰山降雨型滑坡完成易发区划，并精确测定当地降雨阈值参数[68]。

经系统性梳理可见，我国滑坡地质灾害预警技术发展呈现显著迭代特征。同时人工智能，特别是机器学习技术与滑坡预测方面越来越紧密相关，正推动该领域向智能化方向快速演进。但以上研究存在一个不足，就是基于随机森林等算法的诱发滑坡降雨阈值评价流程最终没有将先前开展的研究转换成应用软件且边坡稳定性系统与降雨阈值结合不足，而开展此研究的最终目的是为了解决现实问题。因此本文将随机森林引入到诱发滑坡降雨阈值模型中，开展基于诱发滑坡降雨阈值模型的边坡稳定性评价系统研究，这具有重要的理论与实践意义。

## 1.3 研究内容与技术路线

针对当前随机森林分类模型精度不高、区域 *I-D* 研究存在显著差异及边坡稳定性系统与降雨阈值模型耦合不足等问题，本文在系统分析国内外的诱发滑坡降雨阈值研究及随机森林在降雨诱发滑坡降雨阈值模型的基础上，通过对滑坡影响因子和降雨资料的收集，采用理论分析与数值模拟相结合的方法，建立了基于随机森林的降雨诱发滑坡降雨阈值模型。同时结合 PyQt 技术，搭建一个基于诱发滑坡降雨阈值模型的边坡稳定性评价系统。具体内容如下:



2025.04.10.22.12.207791

（1）论文建立了均质土质边坡，以非饱和土为研究对象，以降雨边坡相互作用为研究核心，以饱和/非饱和土力学为基础，研究降雨诱发滑坡机理。通过使用有限元仿真软件 GeoStudio，模拟并分析了滑坡在降雨下土体渗流场与稳定性的变化情况

（2）建立了以有限元 GeoStudio 模拟生成的数据集为训练集，以边坡高度、边坡倾角、内摩擦角、粘聚力、降雨强度、降雨历时 6 个变量为特征输入，安全系数 Fs 为目标输出的样本数据集，构建基于 RF 算法的边坡安全系数预测模型，验证了随机森林在边坡应用中的准确性。

（3）为了分析边坡的特征输入与降雨阈值曲线之间的非线性关系，基于随机森林的理论，采用全局寻优与交叉验证将结合的方法对随机森林模型进行优化调参，最后建立了基于随机森林的降雨诱发滑坡降雨阈值的模型，通过随机森林这个“黑匣子”成功的表述了边坡的特征输入与降雨阈值曲线之间的非线性关系，对不同地区由降雨诱发滑坡的灾害预警具有重要的参考价值。

（4）通过对前期所做工作进行总结，结合 PyQt 技术，对前文研究内容进行整合。根据系统需求分析，完成了基于诱发滑坡降雨阈值模型的边坡稳定性评价系统的整体架构设计以及系统相关业务功能设计等部分。使前面所研究的内容进行可视化操作。

本文技术路线如下图所示：

送审稿—长沙理工大学



2025.04.10.22.12.207791

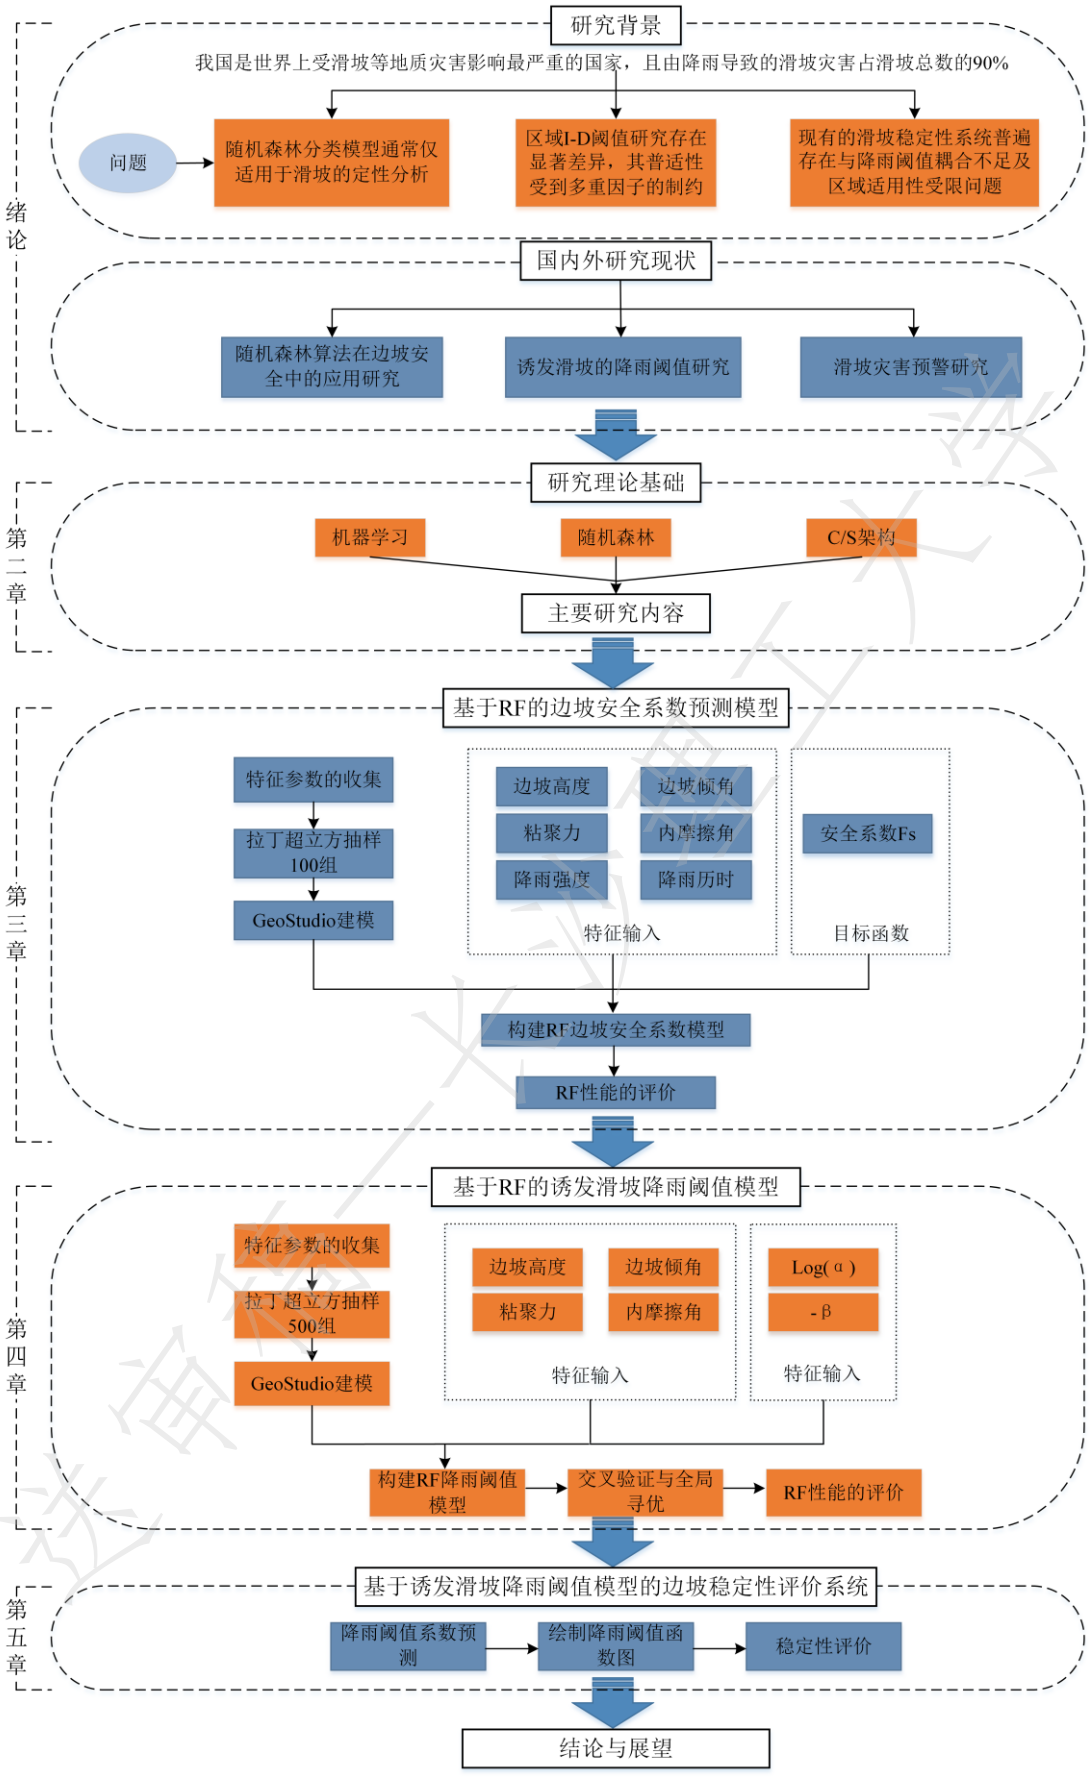



图 1.1 技术路线图



2025.04.10.22.12.207791

# 第2章 随机森林算法基本原理

## 2.1 机器学习的原理

机器学习算法通常可划分为三大类别：监督式学习、非监督式学习以及强化学习[69]。在滑坡灾害预测领域，降雨阈值分析主要采用监督学习范式，因此本文重点阐述该方法的理论基础。监督学习区别于其他方法的核心特征在于每个训练样本均包含对应的目标变量作为监督信号。作为基础模型之一，线性回归常用于阐释机器学习的基本原理与实现过程。

研究首先构建带噪声的线性关系表达式： $y=2.5x+3.5+\delta(x=1,2,3,...,20)$；其中 $\delta$ 代表服从标准正态分布的随机噪声项。将输入特征 $x$ 导入系统后，随机初始化回归系数（包括斜率项 $\theta_1^0$ 与截距项 $\theta_2^0$）进行首次计算。此时模型输出预测结果，其与真实值之间需要通过评估指标量化差异程度。该评价准则定义为损失函数，其数学表达式表征为预测值与实际观测值的偏差度量：

$$\sum_{i=1}^{m}(\hat{y}_i-y_i)^2 \tag{2.1}$$

在监督学习框架中，$m$ 表征训练集的样本容量，该参数本质上是确定量，因为输入特征 $x$ 及其对应的目标变量 $y$ 均已被观测记录。上式中不确定的项是参数和截距，因此损失函数本质上是关于这两个参数的函数，可以表示为 $f(\theta_1,\theta_2)$；进一步简化这个式子，将参数和截距转化为向量形式，即 $\Theta(\theta_1,\theta_2)$。综上所述，提升模型精度的目标就是使 $f(\Theta)$ 的值达到最小。$f(\Theta)$ 在某一点的导函数 $\nabla f(\Theta)_{1(\Theta_1^0,\Theta_2^0)}$ 代表了该点函数值变化最快的方向。为了使模型朝着 $f(\Theta)$ 的最小值方向学习，我们应沿着导数的反方向调整参数，这样就能得到新的参数值 $\Theta^1(\theta_1^1,\theta_2^1)$，即：

$$\Theta^1=\Theta^0-\alpha\times\nabla f(\Theta)_{1\Theta^0} \tag{2.2}$$

若无法使目标函数值降至最小，则需持续执行前述步骤。依据梯度的反方向对参数进行调整，从而获取更新后的参数值，具体如下：



2025.04.10.22.12.207791

$$\Theta^2 = \Theta^1 - \alpha \times \nabla f(\Theta)_{1\Theta^1} \tag{2.3}$$

在公式中，学习效率用$\alpha \in (0,1)$表示。计算机反复进行上述计算过程，不断减小损失函数*f(Θ)*，直到达到某个临界值，此时参数固定。此外，计算机获得的参数$\Theta(\theta_1^n, \theta_2^n)$（其中 $n$ 表示总迭代次数）使得预测值最接近真实标签 $\hat{y}$。这种方法称为梯度下降法，即沿梯度反方向调整参数。

对于线性回归问题，将预测值 $\hat{y}$、训练样本 $x$、参数$(\theta_1, \theta_2)$和真实标签 $y$ 表示为矩阵形式：

$$\hat{Y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_m \end{pmatrix} \tag{2.4}$$

$$X = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_4 & 1 \end{pmatrix} \tag{2.5}$$

$$\Theta = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \tag{2.6}$$

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix} \tag{2.7}$$

因此，损失函数可以表示成为：

$$f(\Theta) = \frac{1}{2m}(X \cdot \Theta - Y)^T (X \cdot \Theta - Y) \tag{2.8}$$

其中，$m$ 表示每个数据集包含的样本数量。常数项 1/2 的设置是为了简化后续求导过程，避免出现多余的常量项。损失函数的导函数表达式如下:

$$\nabla f(\Theta) = \frac{1}{m} X^T (X \cdot \Theta - Y) \tag{2.9}$$

## 2.2 机器学习工作流程



2025. 04. 10. 22. 12. 207791

（1）构建数学模型以映射现实需求

将实际问题转化为具有数学关系的问题，是整个流程的起始步骤。明确该问题适用于机器学习中的哪一类方法，思考能够获取关于问题的哪些数据，确定哪些数据可作为该问题的特征值，以及判断应采用监督学习还是非监督学习的方法。

（2）数据采集与清洗

行业共识“算法决定性能下限，数据质量限定模型上限”深刻揭示了数据要素的核心地位。

（3）数据特征处理与特征工程

该阶段聚焦于将原始数据转化为有效特征向量，涵盖标准化、离散化、独热编码等预处理技术。特征预处理的重要性在于，它能通过提升数据中的信噪比，进而提高机器学习模型的准确性。而特征工程则是从现有特征出发创建新特征的过程，例如可将两个或多个特征组共同合成一个新特征，这一过程能够为模型提供更多关于数据的信息，从而提升模型的准确性。

（4）模型构建与超参数优化

基于选定算法框架进行参数学习，通过迭代训练捕捉数据内在规律。采用全局寻优、贝叶斯优化等方法系统化调整超参数，通过系统化实验筛选最优超参数组合。典型机器学习方法涵盖集成学习体系（如随机森林、梯度提升树）、线性分类器（逻辑回归）、支持向量机以及深度神经网络等。

（5）模型评估

模型评估是衡量机器学习模型性能的重要环节，它在机器学习中作为最后的关键步骤。通过模型评估，可以了解模型在未知数据上的表现，并有助于发现模型中可能存在的潜在问题。根据任务类型选用差异化评价体系：回归问题采用均方根误差（MSE）、可决系数（$R^2$)等指标；分类任务则需综合考察精确率-召回率平衡，引入 AUC-ROC 曲线进行多维度分析。该过程可有效诊断模型缺陷，指导后续优化方向。

## 2.3 随机森林理论

经典线性回归方法通常基于一系列严格的假设条件，其数学表达式往往具有明确的解析形式。然而现实数据往往呈现出复杂的非线性关系和异质性分布特征，难以通过预设的函数形式或统计假设进行有效描述。与传统参数化方法不同，机器学习算法不依赖



2025.04.10.22.12.207791

先验分布假设，凭借强大的非线性拟合能力在复杂数据建模中展现出显著优势。在众多机器学习算法中，随机森林凭借其独特的集成策略和稳定的预测性能备受关注。该算法可根据因变量属性构建不同模型：当因变量为离散型变量时建立分类模型；当处理连续型响应变量时则形成回归模型；若未指定响应变量，则构成无监督学习框架。值得注意的是，目前国内学术界对随机森林分类算法的研究成果较为丰富，但针对回归建模的系统性研究相对匮乏。鉴于降雨阈值属于连续型数值变量，本研究将重点构建基于随机森林的回归预测模型。本章节将深入阐述随机森林回归的理论体系与实现机制。

### 2.3.1 随机森林基础分析

随机森林是一种集成学习模型，通过综合多个学习器来共同完成学习任务。其构建过程是先是成一组基学习器，再运用组合策略将这些学习器整合。决策树常被选作基学习器，因其本身是弱学习器，但集成后往往能成为具有强大预测能力的强学习器。随机森林就是一种以 CART 决策树为基础的集成模型，凭借良好的预测效果和稳定性被广泛应用[70]。

Bagging 作为并行集成学习的重要范式，其运行机制包含以下关键步骤：给定包含 $n$ 个样本的数据集，执行 $n$ 次可重复的随机抽样，即可获得容量为 $n$ 的子样本集。通过 $X$ 次迭代抽样可生成 $X$ 个独立子样本，每个子样本分别训练对应的基学习器。预测阶段，分类任务采用多数表决机制确定最终结果，即选择出现频次最高的类别作为集成输出；回归任务则对各基学习器预测值进行算术平均处理[71]。该方法通过样本空间的随机采样，有效增强模型泛化性能并抑制过拟合风险。值得注意的是，随机森林在继承 Bagging 框架的基础上，进一步引入特征空间的随机选择机制，这种双重随机性设计使其在回归预测中具有独特的抗过拟合优势。

从算法本质分析，随机森林通过独立生成多棵基于随机向量的决策树构建预测系统。每棵决策树在构建过程中均保持最大生长状态而不进行剪枝操作，对于回归问题，最终输出结果为所有决策树预测值的简单的均值处理[72]。相较于传统多元线性回归模型，随机森林的非线性建模特性使其能更有效地捕捉复杂数据关系。这种基于决策树集成的算法架构，通过多棵弱相关决策树的协同作用，形成了具有强大泛化能力的预测体系。

### 2.3.2 随机森林回归基本原理

基于自助法（bootstrap）的重复采样技术[73]，随机森林回归器构建了集成学习框架。



2025.04.10.22.12.207791

设特征向量 $X$ 构成模型的输入空间，目标响应变量 $Y$ 作为监督学习的基准，通过随机的行和列向量组合构建模型，即利用决策树将数值型变量转化为预测变量，从而建立起多元非线性的随机森林模型。每棵决策树 $\{h(X,\vartheta_k)\}$ 的预测值汇总后取平均，得到随机森林模型的最终预测结果。此外，组合模型应由相互独立的训练集构成随机森林。随机抽取的向量 $Y$ 和 $X$ 以及数值型预测向量的推广误差均方为：

$$E_{X,Y}(Y-h(X)) \tag{2.10}$$

随机森林回归器具备以下理论特性：

（1）渐进收敛特性：当决策树数量趋向于无穷大时，随机森林模型的预测结果几乎必然满足收敛条件，其数学表征为

$$E_{X,Y}(Y-av_k h(X,\vartheta_K))^2 \to E_{X,Y}(Y-E_\vartheta h(X,\vartheta))^2 \tag{2.11}$$

此时回归器的数学表达式可形式化表述为（在模型评估阶段，可通过设定极大化决策树规模参数 $k$ 实现）

$$Y=av_k h(X,\vartheta_k) \tag{2.12}$$

从泛化误差的角度分析，定义 $PE^*$表征集成系统的整体泛化误差，则单棵回归树的平均泛化误差可量化为：

$$PE^*(tree)=E_\vartheta E_{X,Y}(Y-h(X,\vartheta))^2 \tag{2.13}$$

（2）若对所有的 $\vartheta$，都满足 $E(Y)=E_X h(X,\vartheta)$，则

$$PE^*(forest)\le \bar{\rho}PE^*(tree) \tag{2.14}$$

其中，$\bar{\rho}$ 为不同余项之间的加权相关系数，且各相关项之间相互独立。这表明随机森林模型的泛化误差相较于分类树降低了 $\bar{\rho}$ 倍，而引入随机化变量 $\vartheta$、$\vartheta^*$ 的目的正是为了实现这一误差的降低。

随机森林算法采用自助抽样法（Bootstrap Sampling），在构建每棵决策树时，对原始输入样本集的行和列进行随机采样，实现样本和特征的随机性，降低了过拟合的风险。与某些算法不同，它对数据的纯净度要求相对较低，无需进行归一化处理，这对于降雨阈值样本数据来说非常适用，因为这类数据通常具有类型复杂、特征变量众多的特点。



2025.04.10.22.12.207791

此外，随机森林由多个独立的决策树模型组成，这种集成学习的方式赋予了它强大的泛化能力，使其能够更好地应对各种不同的数据分布和噪声干扰。同时，它对不平衡样本数据集具有一定的鲁棒性，可以通过调整样本权重等方式来平衡模型的误差，进一步提高模型的性能和稳定性。随机森林的抗干扰能力强、无过度拟合现象等优点，都充分证明了其在降雨阈值模型研究中的适用性和有效性，为该领域的研究提供了可靠的工具和方法。

### 2.3.3 随机森林优缺点

Bagging 集成方法通过聚合弱学习器构建强模型，其中各基分类器权重均等。随机森林（RF）作为其典型实现，以决策树为基分类器，通过多数表决机制确定最终预测结果。

优势：

1）计算效率优于神经网络等复杂模型，适用于大规模数据。

2）支持高维特征分析（达千维），提供特征重要性评估模块。

3）内置缺失值处理机制，对噪声数据具有鲁棒性。

4）传统认为过拟合风险较低。

局限性：

1）对类别分布失衡敏感，易降低少数类预测精度。

2）噪声数据可能引发过拟合。

3）特征量纲差异显著时，重要性评估可靠性下降。

## 2.4 C/S架构

“架构”概念最初由美国 Borland 公司提出，特指基于网络环境的软件开发范式。在该技术框架中，C 代表 Client（用户端），S 表示 Server（服务端），由此形成的 C/S 体系即客户机/服务器的交互模型，该模式主要应用于局域网环境[74]。如图 2.1 所示，C/S 模式通常包含两层结构：客户端与服务器。服务器承担着响应客户端请求的任务，并负责存储与管理整个应用的系统资源，其中系统的数据库通常配置在服务器端；而客户端则侧重于与用户的交互，由于其负责主要的用户界面展示以及多数业务逻辑，C/S 架构因此也被称作胖客户端模式。



2025.04.10.22.12.207791

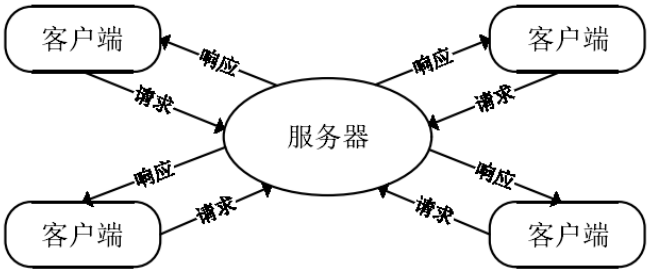



图 2.1 双层 C/S 架构

在 C/S 架构中，客户端与服务器协同完成任务。客户端负责将用户的请求发送至服务器，服务器处理后将结果回传给客户端，最终呈现给用户。对于一些简单的任务，客户端可先进行预处理，再将复杂部分提交给服务器，如此既能有效降低服务器的负载，又能减少网络传输的总流量。

C/S 架构的快速响应能力源于其直接的网络交互方式，客户端与服务器通过网络直连，无需经过其他中间环节，这使得请求处理更为迅速。其特有的"胖客户端"设计架构为复杂业务逻辑的实现提供了坚实基础，进而强化了系统的多任务处理效能。在系统研发阶段，开发者可基于明确的用户画像进行需求建模，这使得客户端交互界面能够实现高度定制化开发，在视觉呈现维度达成统一性、易用性与多样性的有机平衡，人机交互友好性显著提升。此外，由于系统用户群体具有可预见的稳定性，可以对信息数据的存取设置多层权限校验，从而更易于保证系统的安全性，对于保密性要求较高的系统，采用 C/S 结构通常是更优的选择。



2025.04.10.22.12.207791

# 第3章 基于随机森林的边坡安全系数预测模型研究

在边坡安全系数预测方法研究领域，传统技术路线多采用采集实际工程参数构建训练样本与测试样本。然而，受制于现场实测数据获取难度较大，普遍存在样本规模有限的问题，这将直接影响随机森林模型的泛化能力与预测精度。针对这一技术瓶颈，KARDANI 等学者[75]创新性地引入数值模拟方法，通过分析有限元软件批量生成的边坡失稳数据集，同时采用实测工程案例组建验证集进行模型性能评估。受此方法学启示，本研究采用数值模拟构建样本数据集，结合随机森林算法建立土质边坡安全系数预测模型，实现不同工况下边坡安全系数的预测。同时，引入均方误差、均方根误差、决定系数回归性能度量指标来评估模型的泛化性能，以期为边坡安全系数预测提供新的思路。

## 3.1 模型方案设计

### 3.1.1 数据集的建立

降雨是滑坡的重要诱因，其影响因素复杂多样，主要涉及地层岩性组合、地质构造特征、岩土体结构特性、水文地质条件以及坡体几何形态等多重要素。受限于数据采集的完整性和可靠性，难以实现全要素的综合考量。本研究聚焦典型土质边坡的稳定性分析，其失稳模式主要表现为近似圆弧状滑移，这类边坡形态在工程实践中具有广泛代表性。根据参数敏感性、数据稳定性、指标独立性及易获取性等筛选准则，同时借鉴既有研究成果，最终确定将重度 γ、黏聚力 c、内摩擦角 ϕ、边坡倾角 Φ、坡高 *H*、降雨强度 *I* 和降雨历时 *D* 这 7 个关键影响因子作为预测模型的特征输入集（其中容重 γ、内聚力 c、内摩擦角 ϕ、边坡倾角 Φ、边坡高度 *H* 为边坡特征参数，降雨强度 *I* 和降雨历时 *D* 为降雨参数），以边坡安全系数 *Fs* 作为模型的输出。

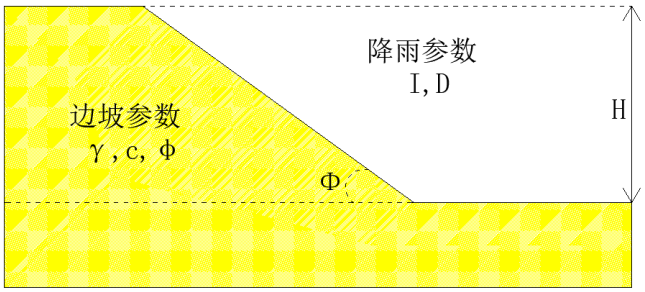



图 3.1 边坡特征参数和降雨参数

考虑到土工参数中容重 γ 的变异性较小，将其取为定值 γ =20kN/m$^3$，故本研究采用



2025.04.10.22.12.207791

土体容重 $\gamma$ =20kN/m$^3$ 的均质边坡。故最后确定模型的输入参数为粘聚力 c、内摩擦角 ϕ、边坡倾角 Φ、边坡高度 $H$ 、降雨强度 $I$ 和降雨历时 $D$ 共六个因素。

本研究中使用的边坡高度和边坡倾角是根据 Toll 等[76]人在 1999 的工作选择的，他们认为在新加坡调查的 35 个失效边坡几乎都有大于 27º 但小于 70° 的坡角，这些失效边坡的高度大多在 5-40m 的范围内。基于从文献中获取的滑坡案例和规范[75,78]确定粘聚力取值为 5-40kPa，内摩擦角取值为 10-35º。而土壤颗粒则采用普遍常见的细粒粉质砂土，其渗透系数 $Ks$ 为 36mm/h。通过拉丁超立方抽样，对四个边坡特征输入进行均匀设计抽取 100 组样本点。

为了得到随机森林模型的原始样本数据集，本文通过有限元软件 GeoStudio 计算 100 组模型在不同的降雨强度 $I$ 下达到临界失稳时的降雨历时 $D$，此时一共有 100 组模型，每个模型有 25 种降雨强度 $I$ ，而每种降雨强度则有 241 个小时，每个小时对应一个安全系数 $Fs$ 的输出，所以最终共有 $100\times25\times241=602500$ 组原始样本数据集，如下表 3.1 所示。

表 3.1 边坡安全系数的样本数据集

| | 边坡高度 | 边坡倾角 | 粘聚力 | 内摩擦角 | 降雨强度 | 降雨历时 | *Fs* |
|---|---|---|---|---|---|---|---|
| 1 | 17.55 | 29.09 | 10.31 | 17.67 | 0.33 | 0 | 1.317341 |
| 2 | 17.55 | 29.09 | 10.31 | 17.67 | 0.33 | 1 | 1.316571 |
| …… | …… | …… | …… | …… | …… | …… | …… |
| 6025 | 17.55 | 29.09 | 10.31 | 17.67 | 12.50 | 240 | 0.705819 |
| 6026 | 6.86 | 50.48 | 5.54 | 21.11 | 0.33 | 0 | 1.698905 |
| 6027 | 6.86 | 50.48 | 5.54 | 21.11 | 0.33 | 1 | 1.697167 |
| …… | …… | …… | …… | …… | …… | …… | …… |
| 12050 | 6.86 | 50.48 | 5.54 | 21.11 | 0.33 | 240 | 0.69958 |
| 12051 | 29.19 | 53.34 | 12.88 | 30.94 | 0.33 | 0 | 1.239099 |
| …… | …… | …… | …… | …… | …… | …… | …… |
| 602498 | 38.85 | 62.74 | 19.89 | 32.19 | 12.50 | 238 | 0.706618 |
| 602499 | 38.85 | 62.74 | 19.89 | 32.19 | 12.50 | 239 | 0.706419 |
| 602500 | 38.85 | 62.74 | 19.89 | 32.19 | 12.50 | 240 | 0.705819 |



2025.04.10.22.12.207791

### 3.1.2 数据集可视化分析

不同边坡特征参数具有差异性，采用概率密度分布图进行特征参数的可视化分析，可以反映出边坡处于不同状态下的情况，同时，一定程度上可以定性分析边坡状态。

此时，我们对样本数据集进行如下处理：

（1）对通过有限元软件 GeoStudio 计算得来的安全系数 *Fs* 进行分类判定，采用 Matlab 对 *Fs* 大于 1 的模型标记为稳定，在目标函数中记为“1”；当 *Fs* 小于 1 的模型标记为不稳定，在目标函数中记为“0”。

（2）将进行判断后的 *Fs* 写入新的表格中（如下表 3.2），使用 Python 的 seaborn 库绘制概率分布图和相关系数热力图。

表 3.2 边坡稳定性的分类样本数据集

| | 边坡高度 | 边坡倾角 | 粘聚力 | 内摩擦角 | 降雨强度 | 降雨历时 | 边坡状态 |
|---|---|---|---|---|---|---|---|
| 1 | 17.55 | 29.09 | 10.31 | 17.67 | 0.33 | 0 | 1 |
| 2 | 17.55 | 29.09 | 10.31 | 17.67 | 0.33 | 1 | 1 |
| 3 | 17.55 | 29.09 | 10.31 | 17.67 | 0.33 | 2 | 1 |
| 4 | 17.55 | 29.09 | 10.31 | 17.67 | 0.33 | 3 | 1 |
| …… | …… | …… | …… | …… | …… | …… | …… |
| 6025 | 17.55 | 29.09 | 10.31 | 17.67 | 12.50 | 240 | 0 |
| 6026 | 6.86 | 50.48 | 5.54 | 21.11 | 0.33 | 0 | 1 |
| 6027 | 6.86 | 50.48 | 5.54 | 21.11 | 0.33 | 1 | 1 |
| …… | …… | …… | …… | …… | …… | …… | …… |
| 12050 | 6.86 | 50.48 | 5.54 | 21.11 | 0.33 | 240 | 0 |
| 12051 | 29.19 | 53.34 | 12.88 | 30.94 | 0.33 | 0 | 1 |
| 12052 | 29.19 | 53.34 | 12.88 | 30.94 | 0.33 | 1 | 1 |
| 12053 | 29.19 | 53.34 | 12.88 | 30.94 | 0.33 | 1 | 1 |
| …… | …… | …… | …… | …… | …… | …… | …… |
| 602498 | 38.85 | 62.74 | 19.89 | 32.19 | 12.50 | 238 | 0 |
| 602499 | 38.85 | 62.74 | 19.89 | 32.19 | 12.50 | 234 | 0 |
| 602500 | 38.85 | 62.74 | 19.89 | 32.19 | 12.50 | 240 | 0 |



2025.04.10.22.12.207791

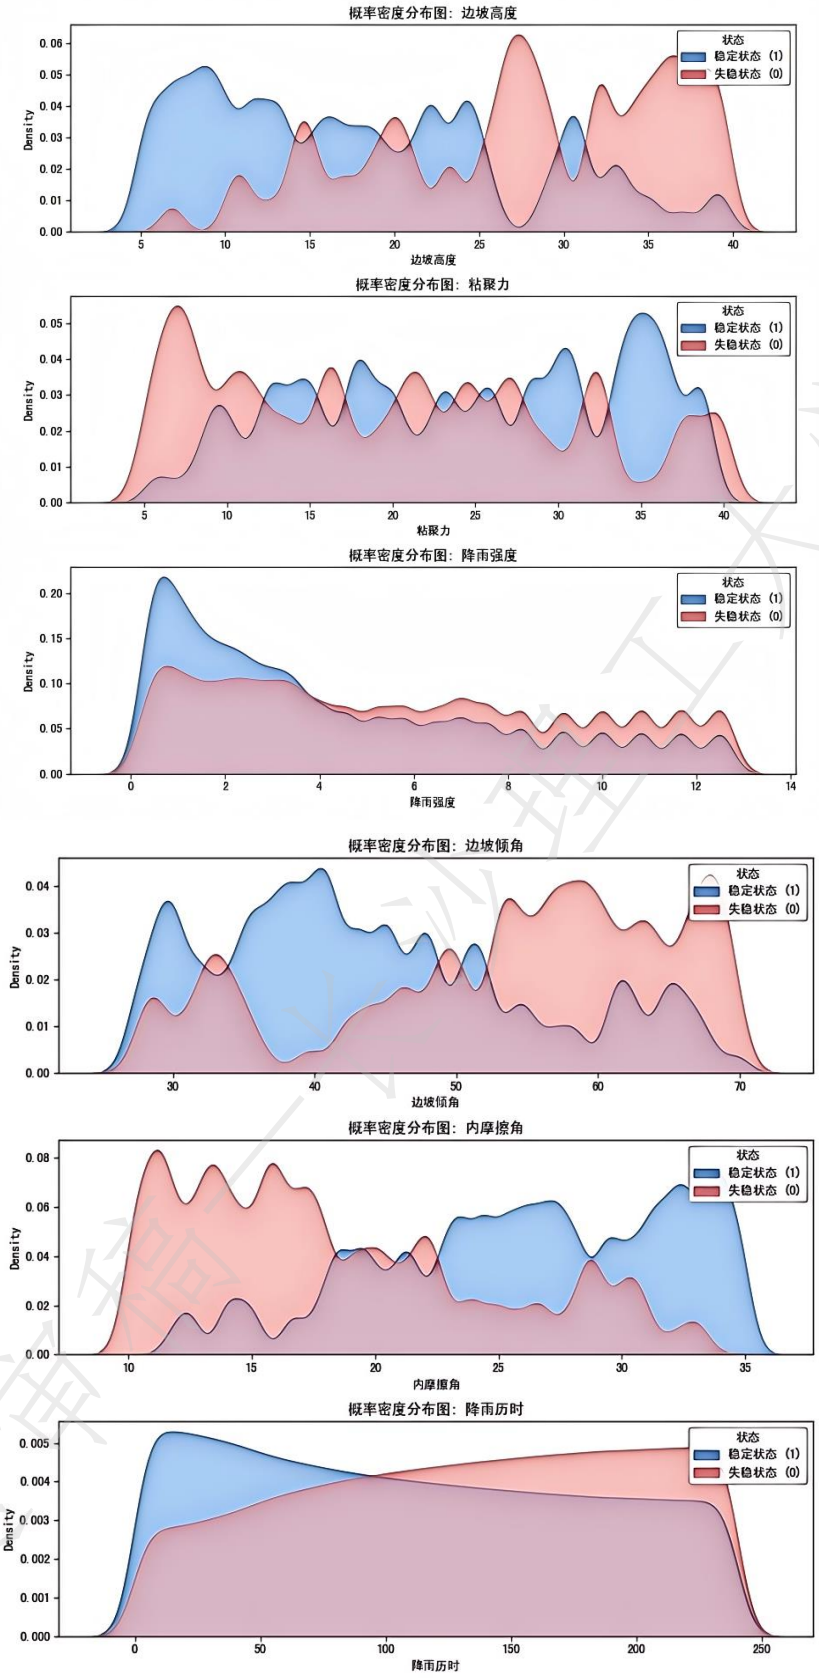



图 3.2 特征输入的概率密度分布图

由上图可知，纵坐标表示概率，横坐标表示 6 个特征输入的范围，蓝色代表稳定状



2025.04.10.22.12.207791

态，红色代表失稳状态。在边坡高度概率密度分布图中可以看出，在随着边坡高度的增加，边坡稳定状态的概率逐渐减小，边坡失稳状态的概率逐渐增大。在粘聚力概率密度分布图中可以看出在随着粘聚力的增加，边坡稳定状态的概率有变大的趋势，边坡失稳状态的概率有减小的趋势。而在降雨强度概率密度分布图中可以看出，在降雨强度低的范围里，趋于稳定的边坡数目多于失稳边坡数目，在高降雨强度范围里则相反。在边坡倾角概率密度分布图中可以看出，在随着边坡倾角的增加，边坡稳定状态的概率逐渐减小，边坡失稳状态的概率逐渐增大。在内摩擦角概率密度分布图中可以看出，在随着内摩擦角的增加，边坡稳定状态的概率逐渐增大，边坡失稳状态的概率逐渐减小。在降雨历时概率密度分布图中可以看出，边坡失稳通常发生在持续长降雨的情况下。经系统性分析发现，不同特征指标对应的稳定态与失稳态样本数据呈现相近的概率分布形态，其核密度估计曲线未出现显著异常偏移，表明数据集具备良好的构建质量。

为深入探究变量间的线性关联特性，本研究将基于 Python 平台构建了特征参数的 Pearson 相关性检验热力图（图 3.3）。根据统计学判别标准：当相关系数处于 0.4 至 0.7 区间时呈现中度相关，0.2 至 0.4 区间表征弱相关，低于 0.2 则视为无显著相关性。结合图 3.3 样本数据可视化结果可见，所选六个特征参数间的关联度普遍较弱，仅边坡高度与倾角参数的相关系数达到 0.19，其余参数组合的关联强度均严格低于常规显著性阈值。即特征之间呈现弱相关性，不存在强相关性。这也表明边坡为复杂的非线性系统，所以选取参数独立性较合理。

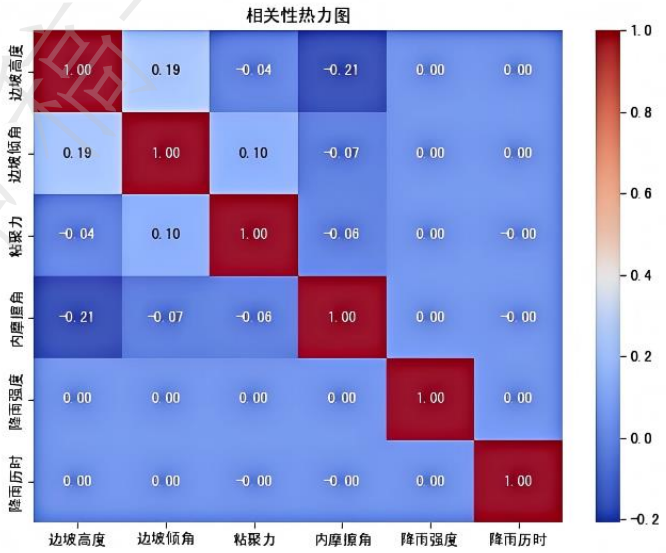



图 3.3 相关热力图



2025.04.10.22.12.207791

## 3.2 降雨诱发滑坡机理研究

### 3.2.1 数值模拟软件的介绍

围绕边坡稳定性数值模型构建方法，本研究采用成熟的岩土工程数值分析平台 GeoStudio 开展系统性研究。该平台整合了环境和岩土工程领域八大核心功能子系统，涵盖固体力学响应分析、多相渗流模拟、污染物扩散追踪等关键技术模块，支持多物理场耦合运算以满足复杂工程问题的求解需求。本研究重点运用 SEEP/W 渗流分析子系统与 SLOPE/W 稳定性评估子系统，构建降雨-边坡相互作用数值模型。其中 SEEP/W 子系统负责实施边坡初始状态及降雨入渗过程的孔隙水压力场模拟，SLOPE/W 子系统则基于极限平衡法开展边坡安全系数动态评估。

### 3.2.2 数值模型构建与参数选取

本节综合既有研究成果，重点探讨坡体几何特征与土体力学参数对滑坡稳定性的作用机制。为系统分析降雨工况下边坡渗流场与稳定性变化规律，本研究采用 GeoStudio 软件平台中渗流计算模块与极限平衡模块的协同分析方法。根据 Rahardjo 建议的边坡模型为建模准则，构建均质土质边坡基准模型以消除异质材料对模拟结果的干扰。模型几何参数按以下原则设置：坡趾距右侧边界、坡肩距左侧边界及坡顶到基底距离均取 3 倍坡高值，坡址至基底距离设定为 2 倍坡高。在坡址下方 5m 处预设地下水位线（标记为 he），其空间方位与水平面呈 7°夹角，基准模型详细构造见图 3.4。在渗流场模拟环节，各边界条件按如下方式定义：ab、bc、cd 边界定为流量边界以模拟降水入渗过程；ah、de、fg 边设为不透水边界；ef、gh 边则采用水头边界，其总水头值分别对应 e、h 节点高程值。

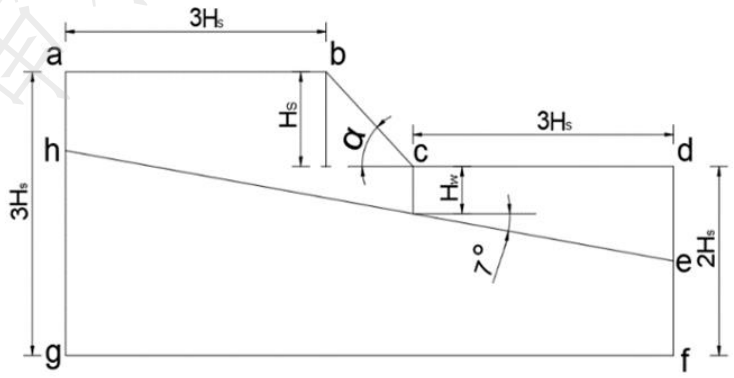



图 3.4 标准化数值分析模型

坡体几何参数设计依据 Toll 等学者对新加坡地区 35 处滑坡案例的统计分析结果，



2025.04.10.22.12.207791

选取具有代表性的坡角区间 27-70°与坡高范围 5-40m，此范围是调查统计中土体发生滑坡时参数的取值范围。再结合前文研究成果，土体粘聚力取值范围设定为 5-40kPa，内摩擦角区间确定为 10-35°。实验材料选用 $f_{50,0.036}$ 型土样（参数表征土水特征曲线拟合参数 $a$=50kPa，饱和渗透系数 0.036m/h），该参数体系可较好反映典型排水性土体特征，确保研究成果的普适性与可对比性。所有工况初始条件均设置为静水压力状态，初始孔隙水负压由地下水位埋深决定。为控制变量影响，统一取初始地下水位埋深 $H_w$=5m。

而对于降雨参数（即降雨强度和降雨历时）的设计，在第四章将进行具体的阐述与分析，此处不过多赘述。确定降雨历时为 0-10 天，以每一个小时为步数间隔；确立降雨强度分为 0.3mm/h~15mm/h，同时在此基础上，为了避免后期函数进行拟合时点过少造成准确度过低，故本次研究降雨强度从小到大共设置 25 组降雨强度。

### 3.2.3 模型边界条件设计

由上小节的标准化数值分析模型可知，gh 为模型的上水头，ef 为模型的下水头，gh 与 ef 共同组成模型的地下水位线，abcd 则为边坡上施加的降雨条件，如图 3.5 所示。

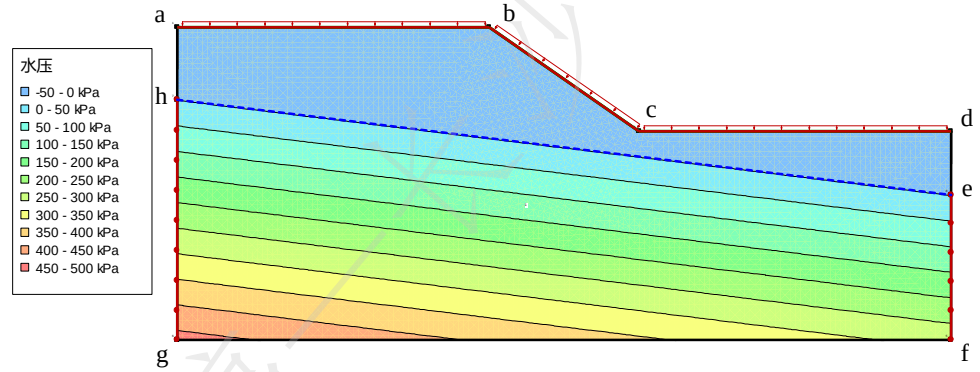



图 3.5 seep 模块边界条件图

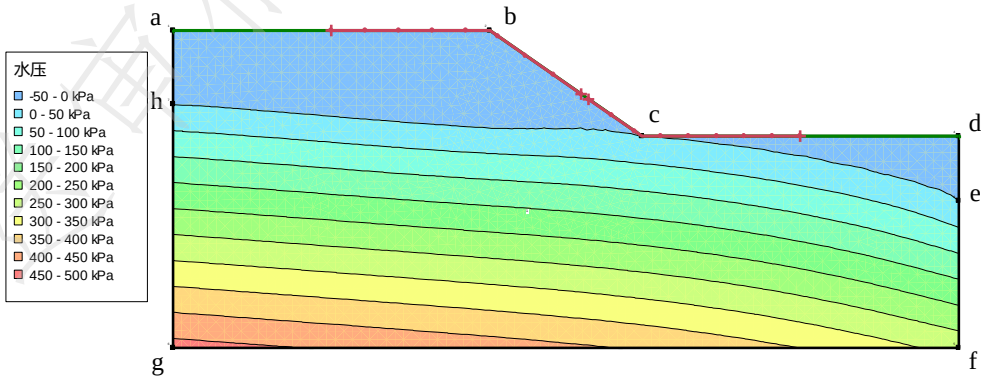



图 3.6 slope 模块边界条件图

图 3.6 则表示在 SLOPE/W 模块，滑移面选择为滑入与滑出模式，发生滑坡时滑移



2025. 04. 10. 22. 12. 207791

面上端进口的位置为 ab 的中点处，滑移面上端出口位置为 0.6 倍 bc 处。滑移面下端进口位置设定为 0.65 倍 bc 处，滑移面下端出口位置设定为 cd 的中点处。

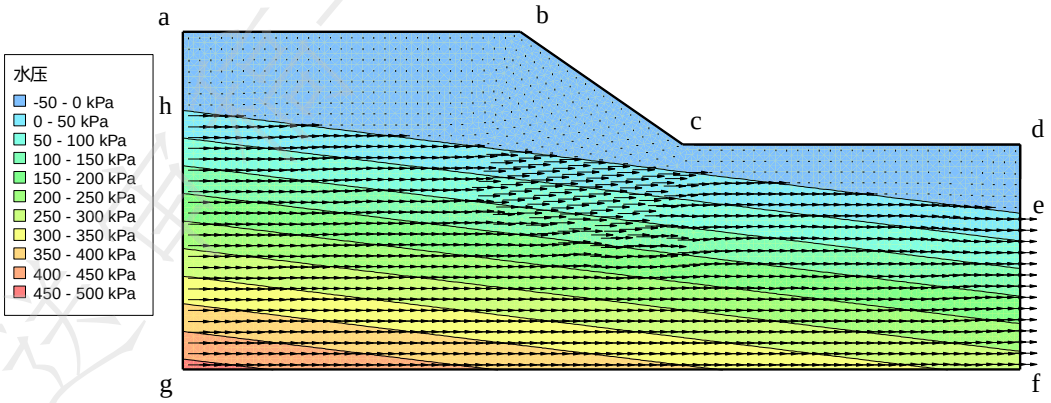
### 3.2.4 数值模拟结果与分析

为检验模型选取相关参数和边界条件的准确性及深入分析由降雨导致的边坡稳定性破坏机制，本小节选取 100 组中的其中一组进行分析，其中选取的代表组中四个边坡输入参数分别为边坡高度 $H$=20.8m，边坡倾角Φ=34.75°，粘聚力 c=22.76kPa、内摩擦角ϕ=12.39°。按照图 3.4 标准化数值分析模型建模。

首先在 SEEP/W 模块里建立瞬态渗流场，设定分析时间为 240h，初始水头设定来源于地下水位线。然后输入模型的材料参数，最后施加相关的边界条件及降雨条件，至此 SEEP/W 模块的第一步完成。重复此步骤建立 25 种降雨条件，共 25 种渗流场。完成 SEEP/W 模块后，在每一个 SEEP/W 后建立 SLOPE/W 模块进行耦合，对其进行稳定性分析。在 SLOPE/W 模块采用 Bishop 法进行圆弧滑动分析，接着输入的抗剪强度等参数，最后绘制好滑移面的滑入与滑出线。至此所有的建模工作已经完成，点击运行即可查看数模结果。

（1）渗流分析

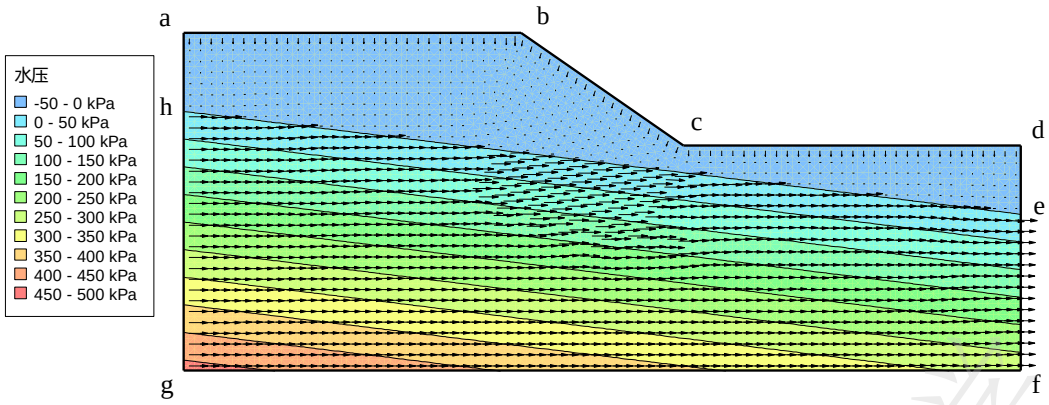
采用 GeoStudio 软件中的 SEEP/W 模块分析浸润线与孔隙水压的变化。以降雨强度 $I_s$=12.5mm/d 为例，图 3.7 为降雨强度为 12.5mm/h 下，降雨时长为 10d，不同时刻下的渗流场分布。



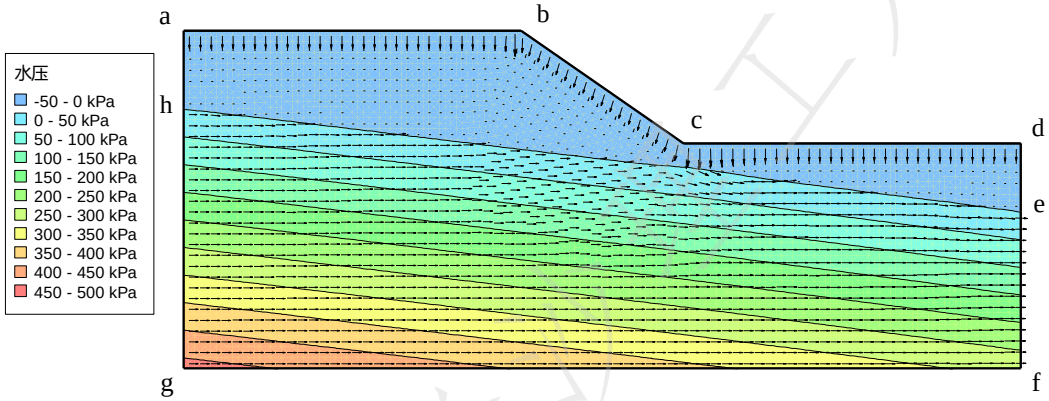

a） 初始渗流场



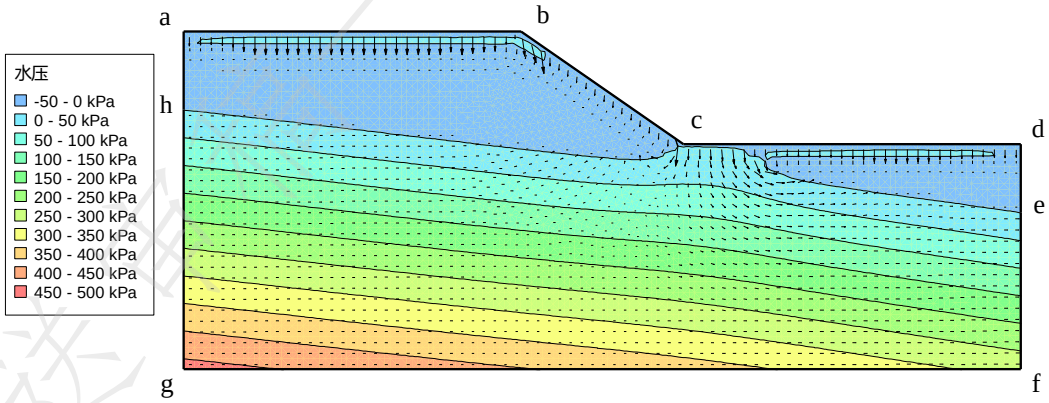
2025.04.10.22.12.207791




b） 第 3h 渗流场



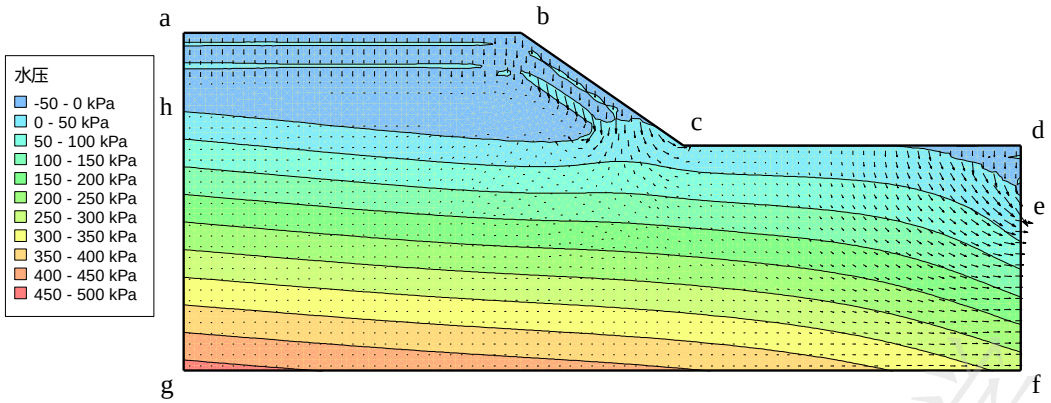

c） 第 1 天渗流场



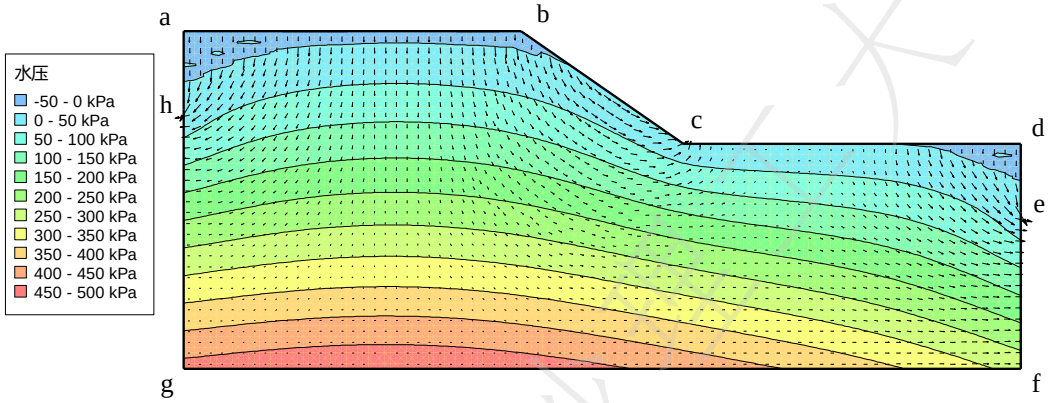

d） 第 1.5 天渗流场



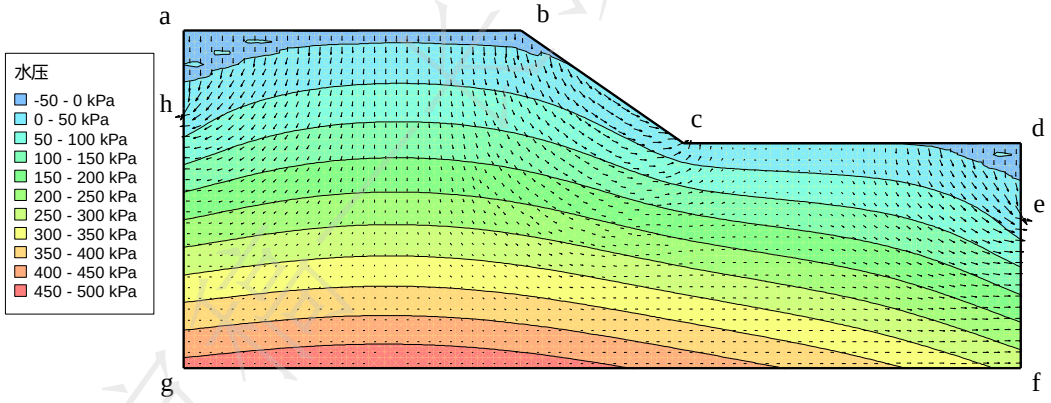
2025.04.10.22.12.207791




e） 第 3 天渗流场




f） 第 5 天渗流场




g） 第 10 天渗流场

图 3.7 不同时刻渗流场分布图

降雨因素作用下，可将边坡渗流二维数值模型在垂向上划分为三个典型区域：暂态饱和区、非饱和区和毛细吸力饱和区。基于不同降雨强度条件下的渗流场演化规律研究发现，边坡土体初始孔隙水压分布呈现由基底向坡表递减的趋势。图中蓝色虚线标识的是地下水位线，地下水位线下方土体孔隙水压呈正压状态且达到饱和含水条件，而上部区域则表现为负孔隙水压，反映非饱和土体特有的基质吸力特性。随着降雨强度等级提



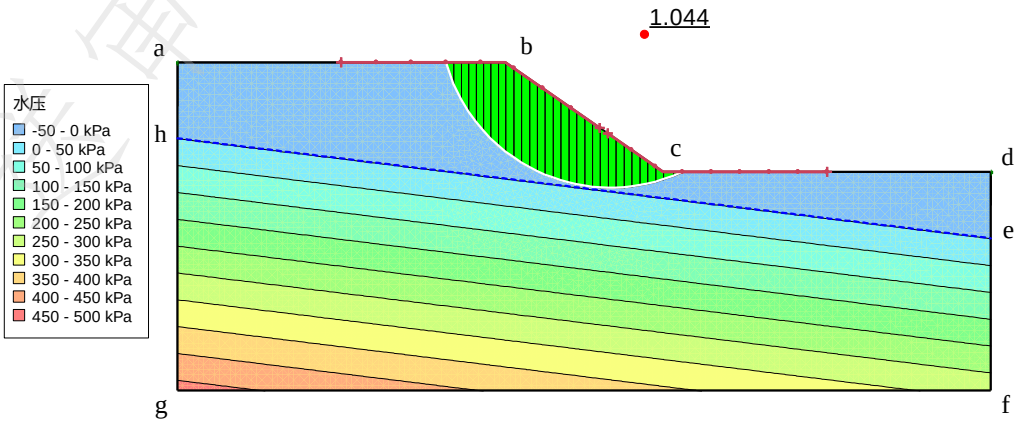
2025.04.10.22.12.207791

升，表层土体水分入渗流量显著增加，导致浅层孔隙水压力增幅更为突出。试验数据显示，在初始条件下坡顶区域孔隙水压为-50Kpa，当采用 12.5mm/h 降雨强度时，该区域水压响应呈现明显变化特征。由于降雨作用，在第 3h 雨水由坡顶 abcd 处逐渐向下渗流，如（图 3.7 b）所示。土体中箭头的大小表示渗流量的大小，可以看出随着降雨时间的增加，由于土体上部大部分地区还未达到饱和，在第一天时渗流量也逐步增加（图 3.6 c）。伴随着降雨时间的持续增加，在第 1.5 天左右，土体上部某些区域相比于其他区域率先达到饱和，出现暂态饱和区（图 3.6 d），并且此时由于大部分区域都快趋近饱和，所以土体内部渗流量相比于第一天有所减小。当时间来到第 3 天，土体内部暂态饱和区不断扩大，达到最大值（图 3.6 e），浸润线也有最开始的土体下方逐渐向上移动。在降雨持续到第 5 天时，由于雨水的长期侵入作用，土体基本达到饱和，此时浸润线上升到最高并贯穿整个斜坡（图 3.6 f），且坡底孔隙水压力的最大值范围大面积扩大，坡顶处也随着时间的推移孔隙水压力逐渐增大并达到峰值。当时间来到 10d 时，其浸润线和压力水头与第 5 天一样（图 3.6 g），说明在降雨第 5 天时土体已经全部达到饱和。

不难发现，对于同一边坡体，在降雨强度未达到土体入渗能力时，降雨强度越大，土体的雨水入渗速率越大。但当降雨强度均大于土体入渗能力时，这种入渗深度差异就会相应减小，甚至消失。同时，也可以看出，降雨主要对边坡表层的渗流场具有显著影响。随着深度的增加，这种影响逐渐减小，甚至在达到某一深度时，降雨不再对边坡的渗流场产生影响。

（2）稳定性分析

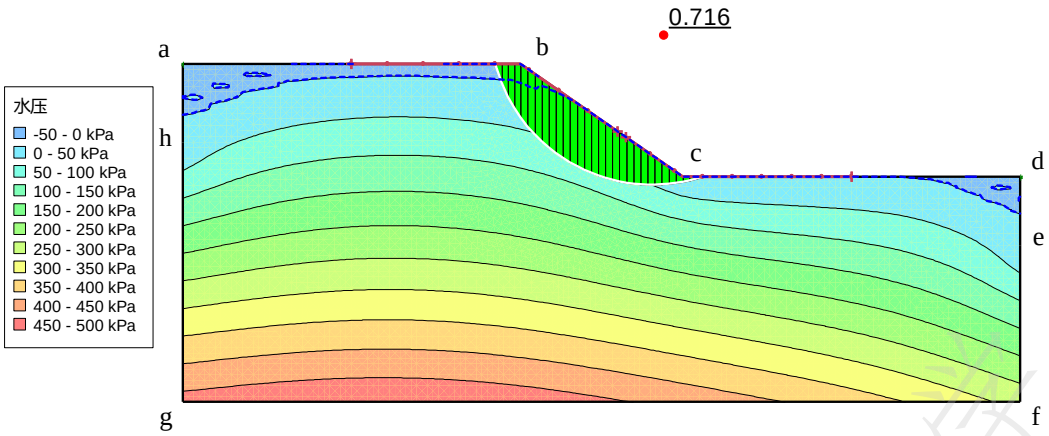
本节将基于（1）的瞬态渗流分析结果，利用 SLOPE/W 模块对各工况条件下的坡体剖面进行稳定性分析。




a） 初始时刻安全系数



2025. 04. 10. 22. 12. 207791




b） 第 10 天安全系数

图 3.8 不同时刻安全系数图

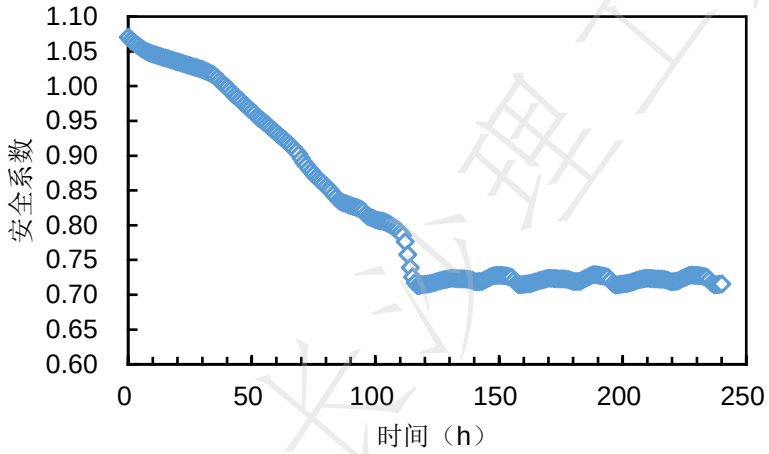



图 3.9 边坡临界滑面安全系数演化

降雨也是影响边坡稳定性的重要影响因素，从图 3.8 可知，初始时刻的安全系数为 1.044，而在经历 10d 降雨后，边坡安全系数下降到 0.716，发生破坏。为深入研究安全系数随时间的变化规律，在 SLOPE/W 模块选取每小时的安全系数值，将其导出到 excel 中进行绘制。如图 3.9 所示，随着降雨时间的持续，安全系数出现了先缓降，后陡降，最后保持平稳不变的趋势。由于降雨初期，土体大部分区域都处于非饱和区，浸润线未接近斜坡处，故此时安全系数下降缓慢；当土体大部分被雨水浸润，土体饱和区不断增大，持续降水渗入坡体内部，导致土体的抗剪强度持续降低，边坡稳定状态随之衰减，安全系数呈加速递减趋势。至第五天前后，土体整体达到含水饱和状态，故其安全系数保持不变，这也与渗流场分析结果相呼应。

## 3.3 模型性能指标



2025. 04. 10. 22. 12. 207791

随机森林算法在边坡安全系数评估中的精度通常较高，这是因为其作为集成学习方法能够有效处理大量输入变量之间的复杂关系，并且对于非线性和交互效应有较好的捕获能力。随机森林通过平均多个决策树的结果，降低了单个树的过拟合风险，提高了整体预测的稳定性和泛化性能。

然而，随机森林的精度会受到多种因素影响，如数据质量（噪声、缺失值）、特征选择的有效性、模型参数设置以及样本大小。在理想情况下，如果数据质量和特征组合得当，随机森林可以达到相当高的预测精度，甚至有时优于其他单一预测模型。

具体数值需要依赖于实际的实验研究，不同的边坡条件和实施细节可能导致不同的精度水平。为了得到准确的精度评价，研究人员通常会通过交叉验证和独立测试集来进行评估并报告预测误差指标，如均方误差、均方根误差、和决定系数。

### 3.3.1 均方误差

MSE 是最常用的评价指标之一，可以评估随机森林预测结果的平均误差大小。它是目标变量的预测值与实际值之间的平均平方差。MSE 的计算公式为：

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{3.1}$$

其中，$y_i$ 是实际值，$\hat{y}_i$ 是预测值，$n$ 是样本数量。MSE 对较大的错误比较敏感，因此当数据中存在异常值时，MSE 可能会被这些异常值主导。

### 3.3.2 均方根误差

RMSE 作为 MSE 的算术平方根，它比均方误差更常用。RMSE 更容易解释，因为它表示了预测值与真实值之间的平均标准差。RMSE 的计算公式为：

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{3.2}$$

### 3.3.3 决定系数

$R^2$ 可以评价随机森林预测结果的拟合程度。它的范围在 0 到 1 之间，越接近 1 表示拟合程度越好。$R^2$ 计算的是预测值与真实值之间的相关系数的平方。

$$R^2=\text{回归平方和/总平方和} \tag{3.3}$$

$R^2$ 的值越高，表示自变量对因变量的可解释性变异性越大；当 $R^2=0$ 时，表示自变量无法解释因变量的任何变异性；当 $R^2=1$ 时，表示自变量完全解释因变量的所有变异



2025.04.10.22.12.207791

性。在回归分析中，$R^2$ 常被用作评估模型拟合程度的一个重要指标；一般来说，$R^2$ 大于等于 0.8 被认为是模型拟合优良。

## 3.4 安全系数预测模型

### 3.4.1 预测模型的构建及结果分析

边坡安全系数预测本质上是一种回归任务。为实现此类预测目标，需基于特征变量与目标值之间的映射关系构建数学模型。本研究采用数据分组策略，将原始样本库划分为训练集与测试集两个独立子集。训练集的选取需确保样本代表性，若训练样本量不足将导致模型欠学习，而过度增加建模样本比例则会引发过拟合现象。本研究中，训练集和测试集的比例分别为 80%和 20%，以确保模型有足够学习能力并获得更准确的结果。此处采用随机抽样法将样本数据库划分为占总量 80%的训练集和 20%的测试集。基于 Python 编程环境搭建的预测算法框架中，首先利用训练集完成模型训练，继而通过测试集输入模型参数获取预测值，并与实际安全系数进行量化比对。为系统评估随机森林模型的预测效能，使用均方误差、均方根误差和决定系数等评价指标对模型的预测能力进行评价。

在应用随机森林算法过程中，需重点优化两个核心超参数：集成决策树数量（n_estimators）与随机种子数（random_state）。当预设决策树数量偏低时，模型难以达到理想的学习深度；反之，过量设置则会显著增加计算负荷。经过综合分析，本研究最终确定将决策树数量为 100，随机种子数固定为 42。

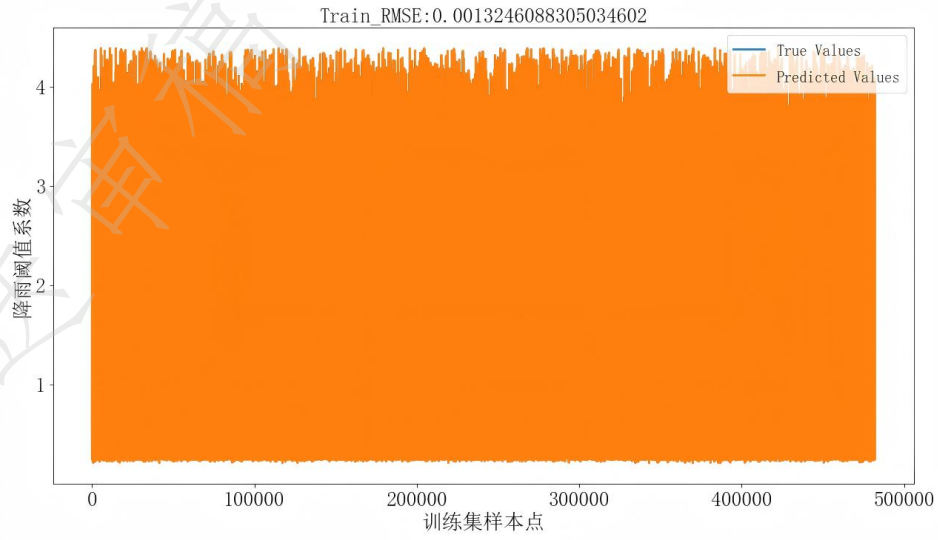



图 3.10 训练集上安全系数预测拟合情况（折线图）



2025.04.10.22.12.207791

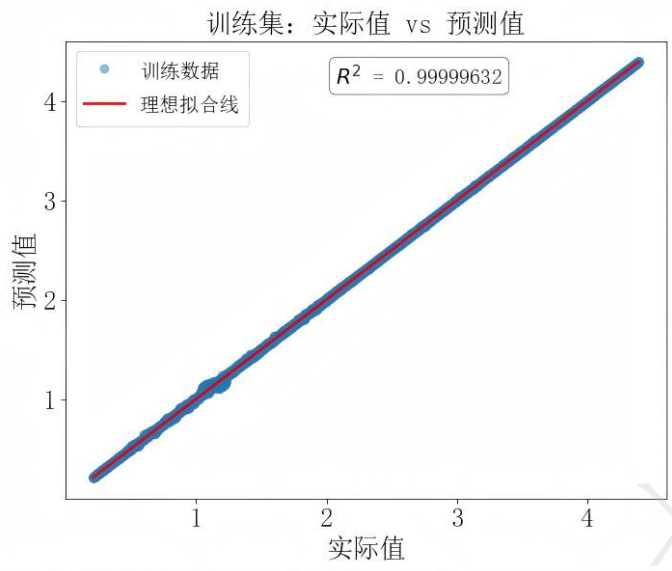



图 3.11 训练集上安全系数预测拟合情况（散点图）

如图 3.10 和图 3.12 所示，从折线图可以看出，在训练集和测试集上，所建立的 RF 模型能够较好地拟合样本点，安全系数 *Fs* 预测值和实际值总体几乎重合，在图中呈覆盖趋势，即预测准确度较高，仅有部分预测值偏离真实值，但偏离程度较小，误差较小，可以满足于工程实际误差要求。通过计算相关回归性能等指标，模型在训练集上的均方根误差为 0.00132 远小于 1，可决定系数 $R^2$ 为 0.99999632。说明模型的训练效果较好；测试集上，均方根误差为 0.0028，可决定系数 $R^2$ 为 0.99998361。说明模型的泛化性能较好。

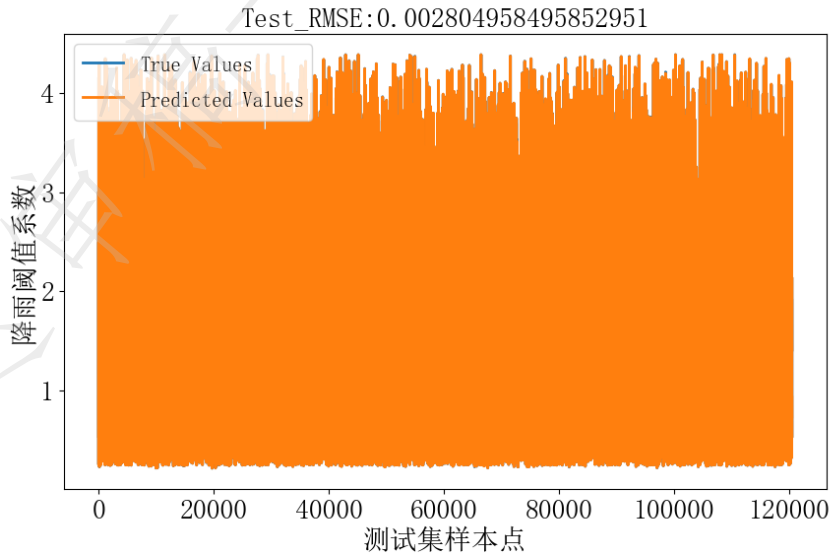



图 3.12 测试集上安全系数预测拟合情况（折线图）



2025.04.10.22.12.207791

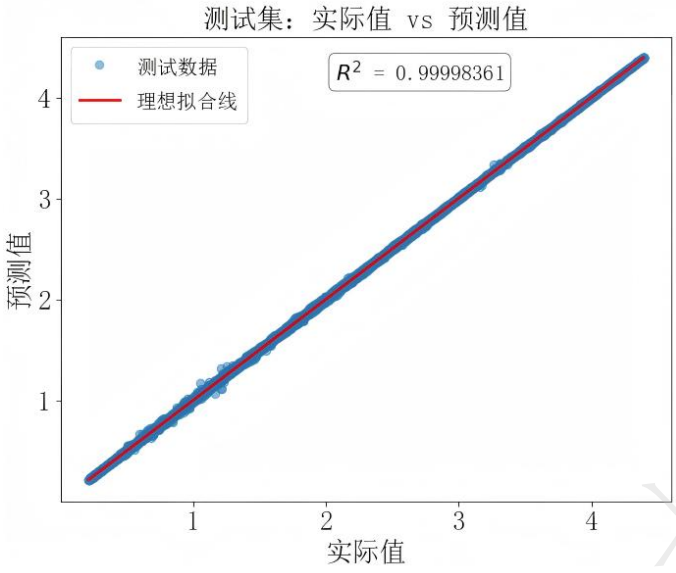



图 3.13 测试集上安全系数预测拟合情况（散点图）

由图 3.11 和图 3.13 散点图可看出，在训练集和测试集上，60 万个样本点在 $Fs_{(实际)} = Fs_{(预测)}$ 的直线两侧均匀紧密分布，回归效果理想，由此可见，所建立的 RF 模型能够很好地拟合样本点，可以准确描述安全系数与影响因素的映射关系。

由于样本集较多，有 60 万个，为了更好观察到样本集内部得分随样本集数量的变化趋势，此处随机从测试集抽取 30 组进行边坡安全系数的预测，得到的结果如下图所示。

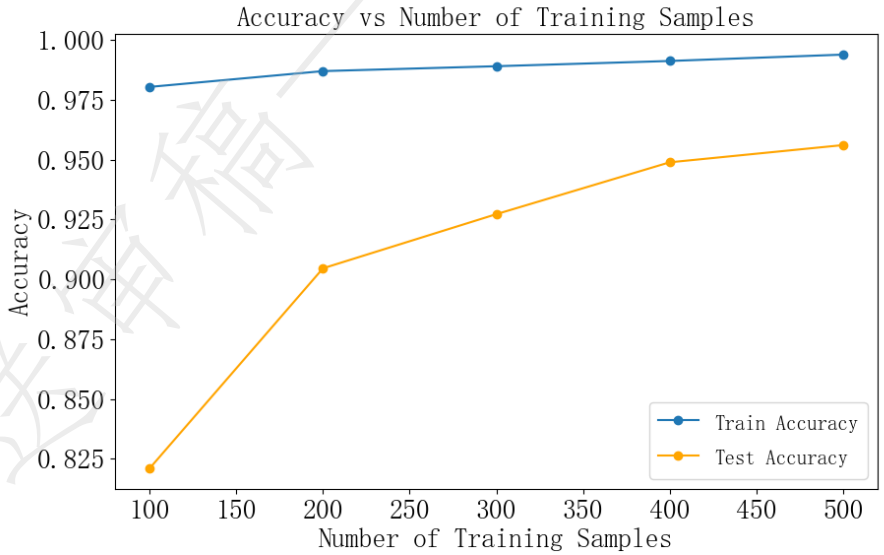



图 3.14 准确率随样本数量的变化图

从图 3.14 可知，纵坐标表示可决定系数 $R^2$ 的得分，横坐标表示样本的数目。可以



2025.04.10.22.12.207791

看到测试集和训练集的准确率随着样本数的增加而增加，训练集趋势较为平坦，都在0.975 以上。而测试集在只有 100 个样本作为测试时，得分只有 0.825，随着样本数目的增加，得分急剧增加，并于样本数目达到 400 组后趋于稳定，得分有 0.95 以上。所以当样本集有数十万后，其得分都稳定在 0.99 以上，与前面算出来的得分相吻合。同时也表明了随机森林算法在边坡安全应用中的高精度性。

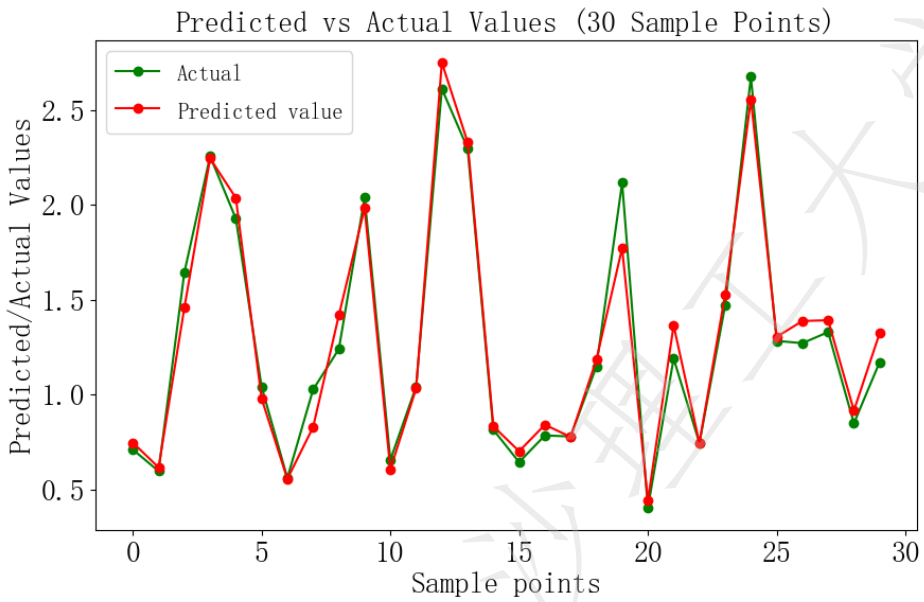



图 3.15 测试集中样本准确率的变化图

随后选取测试集中任意 30 个样本做单个随机森林安全系数模型预测，结果如图 3.15 所示，该横坐标表示样本的数量，纵坐标表示安全系数的值，绿色代表样本的安全系数真实值，红色则表示随机森林模型预测出来的安全系数值。可以看出其预测值与实际值是高度吻合，只有极个别点出现了一定误差。最后计算出这 30 组的决定系数 $R^2$ 为 0.968，MSE 为 0.0123，结果优秀，说明用此 RF 预测模型合理。

### 3.4.2 特征重要性分析

在滑坡防治研究中，明晰特征重要性及其对边坡安全系数的作用极为关键，相关分析可为治理举措的制定供应参照。PFI 算法（即排列特征重要性算法）的运作原理是：经由随机扰乱特征值顺序，继而计算并比对模型性能的下降幅度，以此评定特征的重要性。针对已训练完成的 RF 模型，若多次施行特征重要性剖析，便能求得特征权重系数的均值，其结果如图 3.16 所呈现。



2025. 04. 10. 22. 12. 207791

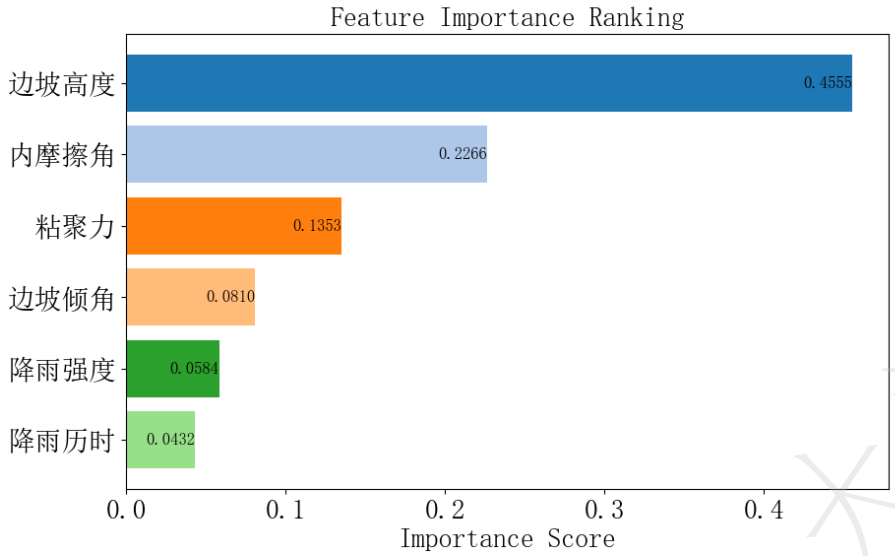



图 3.16 特征重要性分值（重复次数:10 次）

其中，横坐标为特征权重系数均值，纵坐标为各个特征。显然，影响边坡稳定性最敏感的因素是边坡高度，内摩擦角次之，其余特征输入的权重系数均值相差不大，从大到小分别为边坡倾角、粘聚力、降雨强度和降雨历时。由于边坡稳定性受这些特征的显著影响，将它们作为模型输入是合理的。

## 3.5 本章小结

（1）通过分析特征输入粘聚力 c、内摩擦角 ϕ、边坡倾角 Φ、边坡高度 $H$、降雨强度 $I$ 和降雨历时 $D$ 及目标函数 $Fs$ 的相关热力图，研究表明，边坡具有高度复杂性，其各属性变量相互关联并与边坡稳定状态之间呈现显著的非线性耦合效应。

（2）以有限元数值仿真软件 GeoStudio 进行仿真模拟，分析得到了降雨诱发滑坡的原因：降雨主要对边坡表层的渗流场具有显著影响，随着深度的增加，这种影响逐渐减小，甚至在达到某一深度时，降雨不再对边坡的渗流场产生影响。故降雨初期，安全系数下降缓慢，随着降雨持续渗透进入边坡内部，导致土体抗滑能力逐步减弱，进而使得边坡的稳定性状况随之降低，最终表现为安全系数的下降速率变快。最后由于土体达到饱和，其安全系数保持不变。

（3）本文通过建立 RF 边坡安全系数预测模型，得到测试集上的可决定系数 $R^2$ 为 0.99998361，均方根误差为 0.00132，其模型对数据的拟合程度高。而测试集是用于评估模型的最终性能，说明该随机森林模型拟合优秀，在实际的边坡稳定性预测工作中，可



2025.04.10.22.12.207791

将 RF 模型作为一种有效的分析工具。

（4）在边坡稳定性诸多影响因素中，边坡高度的特征权重系数最为显著，对边坡稳定性起着决定性作用。紧随其后的是内摩擦角，它对边坡稳定性的影响力仅次于边坡高度。从整体上看，其他特征的权重系数相对接近，但在边坡稳定性方面，它们各自发挥着独特且不可忽视的作用。因此，在进行边坡稳定性预测时，应综合考虑所有特征因素，以提高预测的准确性和可靠性。

送审稿—长沙理工大学



2025.04.10.22.12.207791

# 第4章 基于随机森林的诱发滑坡降雨阈值模型

前章研究表明，随机森林算法在边坡安全系数预测中展现出良好的适用性（$R^2$=0.99，RMSE=0.0028）。然而，边坡稳定性研究的核心问题在于失稳时间的精准预测。当前业界普遍采用区域降雨阈值作为判断依据，但现有研究多侧重于区域性统计阈值，未能充分考虑单体滑坡的地质特征差异性。为此，本章通过构建单体滑坡特征参数体系，建立基于随机森林算法的降雨阈值预测模型。该模型通过建立降雨参数与边坡特征参数的非线性映射关系，可输出特定边坡的降雨强度-历时阈值曲线。相较于传统区域性阈值，本研究建立的单体化阈值模型具有更高的工程适用价值，可为降雨型滑坡的精准预警提供理论支撑。

基于第三章建立的基于随机森林的安全系数预测模型，本研究选取边坡几何参数（高度 $H$、倾角 Φ）与岩土力学参数（粘聚力 c、内摩擦角 φ）构建四维特征空间，以临界降雨强度（$I$）与临界降雨历时（$D$）为双输出量，建立多输入-多输出的随机森林回归模型。该模型通过随机森林算法挖掘边坡特征与降雨阈值间的复杂非线性关系，最终实现基于边坡特征的个性化降雨阈值预测。

## 4.1 诱发滑坡的降雨强度-历时阈值曲线

### 4.1.1 降雨强度-降雨历时阈值模型介绍

当前，国内外在统计型降雨阈值模型的构建中，普遍关注累积降雨量（$E$）、降雨强度（$I$）与降雨持续时间（$D$）之间的关系进行分析。通过合理的坐标系选择，如对数坐标系或笛卡尔平面直角坐标系，借助数据分析软件对所有数据点进行拟合，得到下限曲线，通常表现为幂指曲线或线性直线。此时，该下限值可作为判断降雨是否触发滑坡的直观依据。现阶段，主流的经验性降雨阈值模型主要包括以下三种类型：其一是基于累积降雨量-持续时间（$E$-$D$）的关系阈值；其二是降雨强度与累积降雨量（$E$-$I$）的关联模型；其三则是应用最为广泛且精度更优的降雨强度-持续时间（$I$-$D$）阈值模型。其数学表达式为：$I=c+\alpha\times D\beta$。其中，$I$ 代表降雨强度，对于短时降雨可取峰值强度，长时降雨则取平均强度，单位为 mm/h；$D$ 为降雨历时，单位为小时（h）；$\alpha$、$\beta$ 为统计系数，c 为常数。表 4.1 列举了全球部分地区的经验性降雨阈值模型。



2025.04.10.22.12.207791

表 4.1 文献中常用的 *I-D* 曲线

| 类型 | 适用国家和地区 | 公式形式 | 取值条件 |
|---|---|---|---|
| 降雨强度-历时 | 世界范围 | $I=14.82\times D^{-0.39}$ | 0.167<D<500 |
| | 世界范围 | $I=2.20\times D^{-0.44}$ | 0.1<D<1000 |
| | 台湾地区 | $I=115.47\times D^{-0.80}$ | 1<D<400 |
| | 波多黎各 | $I=91.46\times D^{-0.82}$ | 2<D<312 |
| | 牙买加 | $I=53.531\times D^{-0.602}$ | 1<D<120 |
| | 西雅图地区 | $I=82.73\times D^{-1.13}$ | 20<D<300 |
| | 四国岛 | $I=1.35\times D^{-1}$ | 24<D<300 |
| | 浙江宁海县 | $I=26.5939\times D^{-0.545}$ | 1<D<48 |
| | 世界范围 | $E=14.82\times D^{0.61}$ | 0.167<D<500 |
| | 世界范围 | $E=4.93\times D^{0.504}$ | 0.1<D<100 |
| | 里斯本地区 | $E=70+0.2625\times D$ | 0.1<D<2400 |
| | 托斯卡拉地区 | $E=1.0711+0.1974\times D$ | 1<D<30 |
| | 四国岛 | $I=1000\times E^{-1.23}$ | 100<E<230 |
| | 川北地区 | $I_{24}=235-0.96\times E$ | 0<E |

（注：$I_{24}$ 为日降雨量）

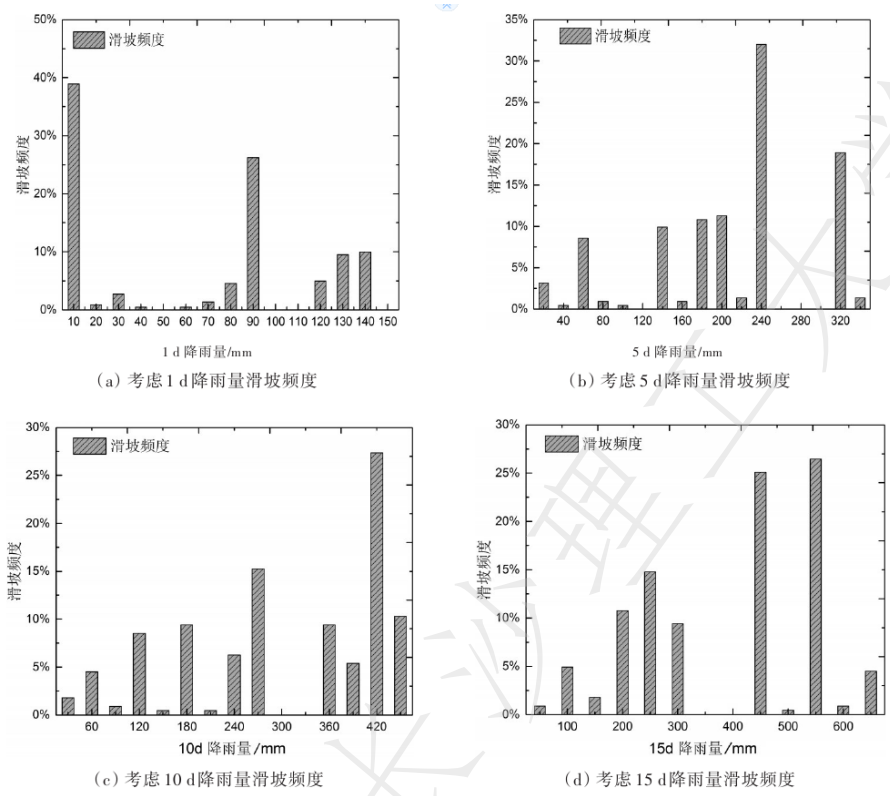
### 4.1.2 降雨历时的确定

为了认识滑坡与日降雨量关系，本文根据查阅相关文献和资料，分析了累积 1d、5d、10d 和 15d 降雨量与滑坡频度关系见图 4.1，此图横坐标为降雨量，纵坐标为发生滑坡的频率。从整体趋势来看，前期降雨量持续时间越长，累积降雨量越多，滑坡发生的概率也随之增大。（图 4.1a）揭示的“双峰”分布特征表明，单日降水量与边坡失稳频度未呈现显著关联性：当日降水量为 10 毫米时，边坡失稳频率达 38%左右；当单日降雨增至 90 毫米时，失稳频率反而降至约 28%。深入分析表明，这种异常现象源于两者触发机制的差异——前者对应持续性中小降雨引发的滑移，后者则表征短历时强降水诱发的浅层失稳。（图 4.1b-d）系统展示了不同观测周期（5 日、10 日、15 日）累积降雨与边坡失稳的响应规律。研究数据显示，边坡失稳概率峰值随累积雨期的延长呈现滞后特征：5 日累积雨量峰值约 240 毫米，10 日和 15 日分别达到 420 毫米和 550 毫米。值得注意的是，10 日与 15 日累积雨量差异较小，这种现象可能与边坡稳定性阈值有关——当累积降雨达到 10 日量级时，多数地质条件较差的边坡已处于临界状态。对比不同统计周期可见，随着考虑的降雨天数逐渐增加，累积降雨量也在不断增大，尽管降雨量的增加幅度逐渐降低，但滑坡频度的降低幅度相对较小。这说明前驱降雨量是控制边坡稳定性的主导因



2025.04.10.22.12.207791

素，当累积周期超过 10 日后，后续降雨对结构完整边坡的扰动效应已显著减弱。该发现为建立基于降雨历时特征的边坡预警模型提供了重要理论依据。故此次研究选取降雨历时为 10d。而为了揭示不同时刻降雨对土体的渗流影响，所以在 GeoStuodio 软件中以每 1 个小时设置一步，将 10d 分成 240h，共 240 步进行数值模拟。




（a）考虑 1 d 降雨量滑坡频度　（b）考虑 5 d 降雨量滑坡频度

（c）考虑 10 d 降雨量滑坡频度　（d）考虑 15 d 降雨量滑坡频度

图 4.1 滑坡与日降雨量对应关系

### 4.1.3 降雨强度初步确定

本小节的分析主要依据我国大陆地区具有广泛参考价值的历史降雨记录，以及我国大陆地区降雨等级划分标准。具体来说，我们重点关注小雨、中雨、大雨和这三个降雨等级，它们在滑坡引发机制中扮演着重要角色。具体方案如下表 4.2 所示。

表 4.2 降雨方案设计

| 降雨等级 | 小雨 | | | 中雨 | | | 中雨 |
|---|---|---|---|---|---|---|---|
| 降雨强度 mm/h | 1.67 | 2.08 | 2.50 | 2.92 | 3.33 | 3.75 | 4.17 |
| 降雨等级 | | | | 中雨 | | | |
| 降雨强度 mm/h | 4.58 | 5.00 | 5.42 | 5.83 | 6.52 | 6.67 | 7.08 |
| 降雨等级 | | | 中雨 | | | 大雨 | |
| 降雨强度 mm/h | 7.50 | 7.92 | 8.33 | 9.17 | 10.83 | 11.67 | 12.50 |



2025.04.10.22.12.207791

基于此降雨方案，通过查阅相关文献，分析所考虑的降雨强度对边坡稳定性影响的规律。初步确立降雨强度分为为 0.3mm/h~15mm/h，此降雨范围包含了从小雨到大雨的范围，这符合我国大部分地区的降雨情况。且过小的降雨强度在数值模拟及实际工况下无论施加多久的降雨都不会发生滑坡，而过大的降雨强度在数值模拟及实际工况下通常在降雨几小时内就发生滑坡，研究意义不大。

在我们确立好降雨强度 $I$ 和降雨历时 $D$ 之后，通过对边坡失稳模型的临界降雨参数进行拟合分析，可观察到降雨历时与临界降雨强度之间呈现显著的幂律分布特征。如式（4.1）所示，这一发现与国内外同类型研究的理论框架基本吻合。

$$I = \alpha D^{-\beta} \tag{4.1}$$

式中：$I$ 表示降雨强度，单位 mm/h；$D$ 表示降雨历时，单位 h；$\alpha$ 和 $\beta$ 是常量。

对式（4.1）两边取对数，能够获得一个线性函数，该函数以 $-\beta$ 为斜率，以 $\log(\alpha)$ 作为截距，如式（4.2）所示。

$$\log(I) = -\beta \log(D) + \log(\alpha) \tag{4.2}$$

这样我们就能更加形象的从图形中看出 $\alpha$ 和 $\beta$，相比于直接观察曲线的曲率来表示不同滑坡的 $\alpha$ 和 $\beta$，直接转化为一次函数，用 $\log(\alpha)$ 和 $-\beta$ 更加直观。并且相对于直接用 $\alpha$ 和 $\beta$ 作为随机森林的输出，用 $\log(\alpha)$ 与 $-\beta$ 进行预测后期算均方根误差等指标更有优势，不会因为 $\alpha$ 过大而使结果毫无规律。

## 4.2 计算流程与样本构造

### 4.2.1 计算流程

利用随机森林模型建立诱发滑坡降雨阈值模型具体流程如下：

（1）分析由降雨影响滑坡发生的致灾参数，以此作为特征输入。

（2）通过查阅大量文献及规范确定好特征输入的取值范围。

（3）确定好特征输入的取值范围后，采用拉丁超立方抽样构造原始样本数据集样本，假设有 $D$ 个特征输入，然后采用数学家方开泰著的均匀设计法进行构造，批量生成 $N$ 组模型。

（4）基于由拉丁超立方抽样生成的 $N$ 组数据集，以有限元数值仿真软件 GeoStudio



2025.04.10.22.12.207791

进行仿真模拟，例如，在降雨条件下边坡稳定性方面，通常是将 SEEP/W 和 SLOPE/W 进行耦合，SEEP/W 模块主要是计算其降雨入渗过程中的渗流场结果，然后将计算后的渗流场结果与 SLOPE/W 进行耦合，可以计算得到不同降雨时间点边坡的稳定性，本文是选择 Bishop 法计算安全系数。

（5）通过对 GeoStudio 计算得来的 $N$ 组数值模型，利用商业数学软件 Matlab 采用插值法对 $N$ 组数值模型中发生临界破坏（$Fs$=1）的边坡所发生的降雨历时 $D$ 进行批量提取。

（6）对提取出来的降雨历时 $D$ 及它此时的降雨强度 $I$ 进行对数化处理，得到以 $\log(D)$ 为自变量，$\log(I)$ 为因变量，以 $-\beta$ 为斜率、以 $\log(\alpha)$ 为截距的 $n$ 组线性函数。

（7）将得到来的 $n$ 组 $-\beta$ 、$\log(\alpha)$ 作为随机森林的两个目标变量，并以其 $n$ 组目标变量所对应的 $n$ 组特征输入作为组成 $n$ 组原始样本数据集。

（8）建立 RF 模型，并分别采用普通调参与全局寻优的方法对超参数进行优化，对比两种调参方法的精确度，确定其以优化调参的方法对 RF 模型进行优化。

### 4.2.2 模型参数选取及范围确立

边坡稳定性受到地形地貌、地质构造、地层岩性、水文条件、自然条件以及人为活动等多种内外部、静动态因素的共同影响。根据理论研究和工程实践，可将主要影响因素归类为边坡物理力学参数、几何结构参数和水文条件。基于各参数的敏感性、稳定性、相互独立性以及易获得性等原则，并结合前人研究成果，本文选取容重 γ 、内聚力 c、内摩擦角 ϕ 、边坡倾角 Φ、边坡高度 $H$ 五个影响因素作为模型的输入。其中，γ 、c 和 ϕ 这 3 个指标表征边坡的基本物理力学参数，Φ 和 $H$ 这 2 个指标表征边坡的几何结构参数边坡剖面及模型特征参数如图 4.2 所示。

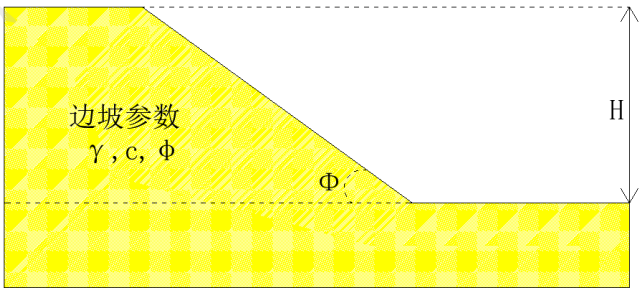



图 4.2 边坡特征参数

考虑到土工参数中容重 γ 的变异性较小，将其取为定值 γ =20kN/m$^3$,故本研究采用



2025. 04. 10. 22. 12. 207791

土体容重 γ =20kN/m$^3$ 的均质边坡。故最后确定模型的输入参数为粘聚力 c、内摩擦角 ϕ、边坡倾角 Φ、边坡高度 *H* 共四个因素。

本研究中使用的边坡高度和边坡倾角是根据 Toll 等[76]人在 1999 的工作选择的，他们认为在新加坡调查的 35 个失效边坡几乎都有大于 27º 但小于 70º 的坡角，这些失效边坡的高度大多在 5-40m 的范围内。基于前文的研究，确定粘聚力取值为 5-40kPa，内摩擦角取值为 10-35º。而土壤颗粒则采用普遍常见的细粒粉质砂土，其渗透系数 *Ks* 为 36mm/h。

### 4.2.3 样本构造方法

在随机森林训练过程中，需构建一系列样本点，这些样本点由已知的特征输入值与功能函数值组成。样本点被区分为训练样本和测试样本，前者用于 RF 模型的构建，后者则用于评估模型的准确性。本研究统一采用拉丁超立方抽样法生成训练样本和测试样本。

基于上一小节，对此我们选取内聚力 c、内摩擦角 ϕ、边坡倾角 Φ、边坡高度 *H* 共四个因素作为输入。基于 python 进行拉丁超立方抽样，python 语言部分代码如下：

首先定义好参数个数 *D*=4，拉丁超立方层数 *N*=500，即对应生成 500 组数据。

:param *D*:参数个数

:param *N*:拉丁超立方层数

然后，分别在每个维度采样 *N* 个值（你可以理解成把单维度（一条线）分成 *N* 份，在每个范围都随机取一个值出来），完成这一步我们就有 *D* 个 *N* 维的值（每个维度有一个），然后随机组合（在每个维度随机拿一个，就组成了一个 *N* 维空间的点），那么总的就能有 *N* 个点了，这里四个输入服从均匀分布，即保证我每一个大范围里的小范围都是均匀分布并采样得到，将得到样本数据进行拉伸。

```
#将数据进行分层，均匀分布采样
result = np.empty([N, D])
    temp = np.empty([N])
    d = 1.0/N
#对样本数据进行拉伸
b = np.array(bounds)
```



2025.04.10.22.12.207791

```
    lower_bounds = b[:,0]
    upper_bounds = b[:,1]
    if np.any(lower_bounds > upper_bounds):
        print('范围出错')
        return None
    #    标准范围缩放
    np.add(np.multiply(result,
                       (upper_bounds - lower_bounds),
                       out=result),
           lower_bounds,
           out=result)
    return result
```

接着把参数个数 *D*=4，拉丁超立方层数 *N*=500 以及 4 个特征输入的范围写入代码中。

```
if __name__ =='__main__':
    D=4
    N=500
    bounds = [[5,40],[27,70],[5,40],[10,35]]
```

最后将生成的结果数据存储至 excel，至此拉丁超立方抽样的所有工作都已完成。

为了形象的展示 4 个特征输入的拉丁超立方抽样效果图，本小节采用 Origin 绘图软件统计分析 4 个特征输入的分布数据，绘制小提琴图如图 4.3 所示，小提琴图中的中间原点表示中位数，中间的箱线盒表示下四分位点到上四分位点的数据，从其延伸的黑线代表 1.5 倍四分位距的数据，外部形状表示核密度估计量。从图 4.3 中可以看出，4 个输入参数采用拉丁超立方抽样后，每个特征输入的每层都抽取很均匀，避免了使用像蒙特卡罗等抽样方法导致某些数据抽取不到的情况，而这些数据可能正好是导致发生降雨时发生滑坡的重要数据。拉丁超立方抽样方法能够把累计曲线划分为 *N* 个区间，每个区间的抽取概率都是相同的。分层抽样运用的是“抽样不替换”技术，意味着每个分层仅抽取一个样本，一旦从某个分层中抽取样本，该分层便不再参与后续抽取，从而有效防止



2025.04.10.22.12.207791

重复抽样。如此一来，所抽取的样本能够更精准地体现输入概率分布中的数值分布情况。

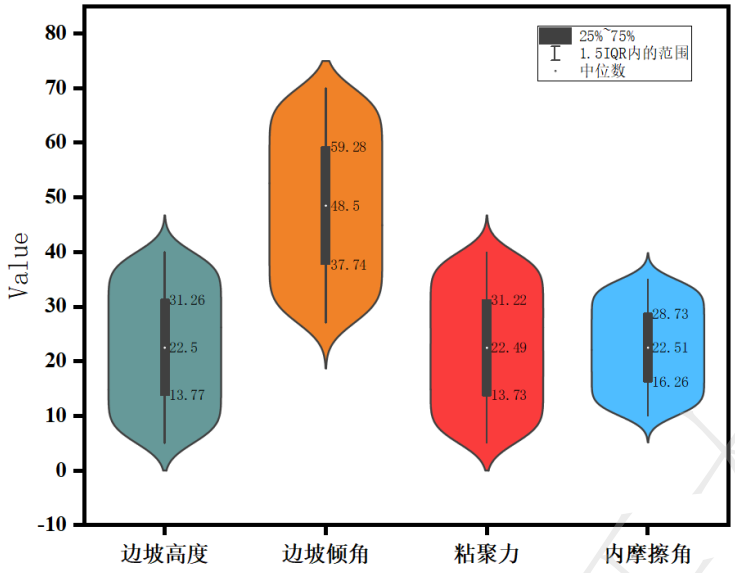



图 4.3 拉丁超立方抽样可视化

## 4.3 降雨诱发滑坡的降雨阈值研究

### 4.3.1 前期准备基础

聚焦降雨诱发滑坡的降雨阈值研究，本研究延续第 3 章的研究方法，采用 GeoStudio 专业数值仿真平台开展定量分析。值得注意的是，本项研究在模型构建方面实施了参数延续性设计策略：其一，边坡基准模型构建严格遵循 Rahardjo 提出的几何尺寸标准（具体几何形态详见图 3.4）；其二，数值模型的关键物理参数体系与前期研究保持严格一致；其三，在边界条件设置层面，本研究沿用了经过验证的流体力学边界设计方案（详细边界参数配置参见图 3.5 与图 3.6）。

在降雨工况的参数设定方面，本研究基于前期研究成果确定的 0.3-15mm/h 降雨强度范围进行优化。为提升后期函数拟合的数学精度，避免因样本量不足导致模型偏差，研究采用系统性梯度设计原则，将降雨强度划分为 25 个等差梯度（0.3-15mm/h）。通过利用有限元软件 GeoStudio 进行数值模拟试验，不断调整多种降雨强度的分布，使得试图寻找到最优的降雨强度分布体系。最终建立的降雨强度参数体系详见下表 4.3 所示。由表 4.3 可知，一共设置了小雨、中雨和大雨三种降雨类别，基本符合我国绝大部分地区的降雨情况。



2025.04.10.22.12.207791

表 4.3 模型降雨强度设置

| 降雨等级 | 小雨 | | | 中雨 | | | | |
|---|---|---|---|---|---|---|---|---|
| 降雨强度 mm/h | 0.33 | 0.83 | 1.25 | 1.67 | 2.08 | 2.5 | 2.92 | 3.33 |
| 降雨等级 | | | | 中雨 | | | | |
| 降雨强度 mm/h | 3.75 | 4.17 | 4.85 | 5 | 5.42 | 5.83 | 6.25 | 6.67 |
| 降雨等级 | | | 大雨 | | | 大雨 | | |
| 降雨强度 mm/h | 7.08 | 7.5 | 7.92 | 8.3 | 9.17 | 10 | 10.83 | 11.67 |

完成边坡数值模型的构建及边界条件设定后，本研究采用如下工作流程建立基准分析样本：首先基于拉丁超立方抽样方法获取典型样本数据集，从中选取具有代表性的边坡样本作为建模基准。在 GeoStudio 仿真平台中，依次完成几何建模、材料参数配置及边界条件加载等关键步骤，特别注意保持软件语言环境为英文模式以确保后续数据接口的兼容性。完成所有参数赋值后，通过调用内置求解器启动瞬态稳定性分析。上述流程建立的基准模型将作为后续降雨阈值模型研究的基础模板，通过系统化的参数替换机制实现批量仿真计算。

### 4.3.2 批量文件的处理与生成

完成了 4.3.1 的工作后，将所生成的模型结果进行另存为，存储格式选择“.xml”。接下来将使用商业数学软件 MATLB 进行批量计算，其步骤如下：

（1）读取原拉丁超立方抽样生成的 500 组数据表格，并对其表格中的几何点以及边界条件等进行赋值，部分代码如下；

```
[num,txt,raw]=xlsread('D:\桌面\test1.19.xlsx');
bc_id9=num(:,30);
bc_id10=num(:,31);
point_1x=num(:,6);
point_1y=num(:,7);
point_2x=num(:,8);
point_2y=num(:,9);
…….
```

（2）读取模型原始文件“.xml”，将“.xml”文件里面的几何点及边界条件等文本作为



2025.04.10.22.12.207791

一行字符存储在字符向量中。

```
path='C:\Users\alius\Desktop\1xin\model.xml';
point1_forth=char('<Point ID="1" X="');
point1_middle=char('" Y="');
point1_end=char('" Pinned="true" />');
…….
```

（3）创建批量文件名，采用 for 循环，将 test1.19.xlsx 里的数据逐个在“.xml”中替换并生成新的“.xml”并存储在“PLJS1.24”的文件中。

```
for i=1:500
left_hydhead=sprintf('%s%d%s',left_hydhead_forth,bc_id9(i),left_hydhead_end);
right_hydhead=sprintf('%s%d%s',right_hydhead_forth,bc_id10(i),right_hydhead_end);
point1=sprintf('%s%d%s%d%s',point1_forth,point_1x(i),point1_middle,point_1y(i),point1_end);
……
```

自此一共生成了 500 组的原始模型

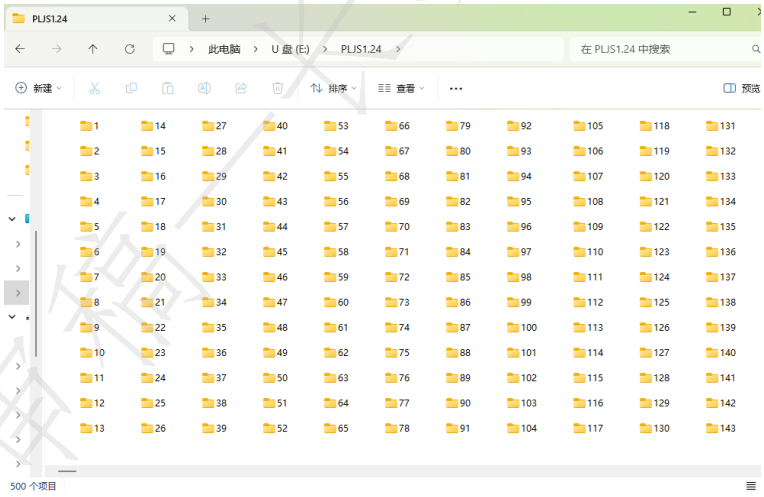



图 4.4 生成的 500 组模型

### 4.3.3 降雨阈值数据的提取与处理

本小节旨在研究降雨历时-降雨强度之间的关系，故需要了解在不同降雨强度下边坡发生临界破坏时所经历的降雨时长，而边坡发生临界破坏时是通过临界安全系数 *Fs* 来评判的。基于此，首先将 500 组模型进行数值模拟，每组模型计算后的结果文件如下

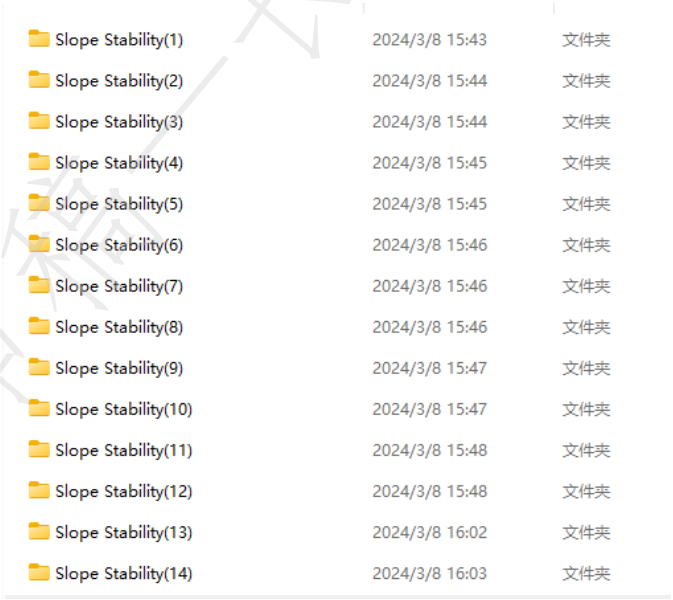


2025. 04. 10. 22. 12. 207791

图 4.5a 所示，共有 53 个子文件。我们只要对前 25 个文件，即边坡稳定性分析模块里的不同时间段的安全系数进行提取即可。对于每个边坡稳定性分析文件如图 4.5b 所示，一共有 240 个子文件，即每小时对应一个文件。我们需要对其每个单独的小时文件里的“lambdafos***.csv”中的最危险安全系数值进行提取。本小节采用商业数学软件 MATLB 进行提取，其中由于每小时文件里的“lambdafos***.csv”文件名不一样，故采用休止符*，*代表不同部分的字符。

相关脚本如下：

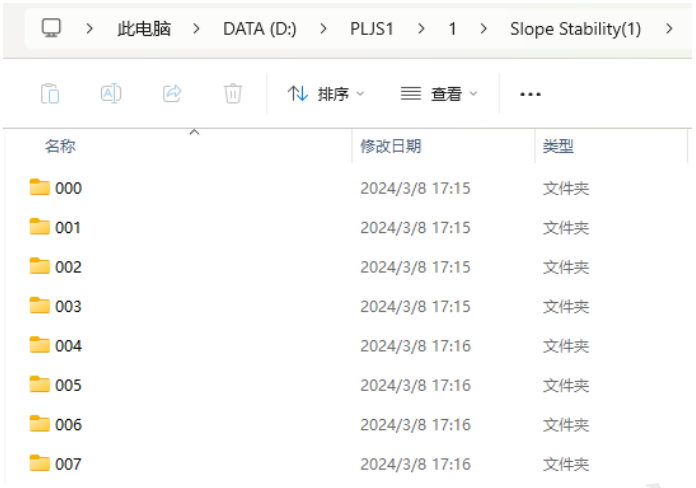
```
for j = 1 : min(241,length(subfolderpath))
    % 获取文件夹中匹配特定模式的文件列表
    fileList=dir(fullfile(folderPath,subfolderpath(j).name, 'lambdafos*.csv'));
    % 遍历匹配的文件列表
     for k = 1：length(fileList)
      % 获取文件路径
      filePath=fullfile(folderPath,subfolderpath(j).name, fileList(k).name);
      ……
      ……
```




a） 单组模型运行结果文件



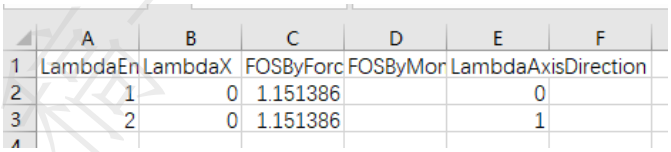
2025. 04. 10. 22. 12. 207791




b） 每组降雨强度下不同时刻结果文件




c） 每个时间下的结果文件



| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | LambdaEn | LambdaX | FOSByForc | FOSByMor | LambdaAxisDirection | |
| 2 | 1 | 0 | 1.151386 | | 0 | |
| 3 | 2 | 0 | 1.151386 | | 1 | |

d） 每个时间下最危险安全系数

图 4.5 安全系数存储位置

此时生成的表格数据仅仅只有每时刻的安全系数，接下来使用商业数学软件 MATLB 中的插值 interp1 进行安全系数 $F_s$=1 时的插值，其调用的格式为: $y_i$=interp1($x$，$y$， $x_i$,‘method’)，其中 $x$，$y$ 为插值点， $y_i$ 为在被插值点 $x_i$ 处的插值结果，此处 $y_i$ 取 1。$x$，$y$ 为向量，‘method’表示采用的插值方法，本次研究采用线性插值即可，将生成的结果写入新的.xlsx 文件。



2025. 04. 10. 22. 12. 207791

### 4.3.4 数据的拟合

将提取出来的降雨历时 $D$ 数据与其对应的降雨强度 $I$，分别进行对数化处理得到以 $\log(D)$ 为自变量，$\log(I)$ 为因变量的数量关系式，利用 excel 进行一次拟合。得到如图 4.6 所示的一次拟合图，由图可知 $\log(I)$ 随 $\log(D)$ 的减小而减小，呈现负相关趋势，并且其拟合效果 $R^2$ 为 0.9955，拟合效果优秀。通过拟合结果可知，该拟合一次曲线的斜率为-1.084，截距为 2.0792。根据式(4.2)，确定 $\log(\alpha)$ 为 2.0792，$-\beta$ 为 1.084。

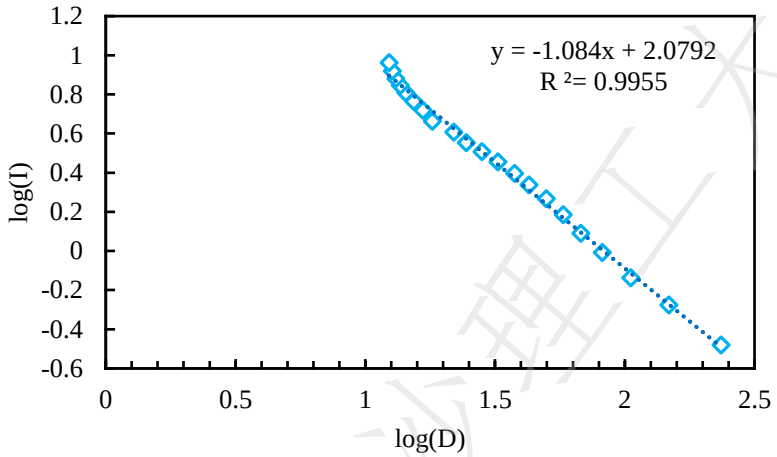



图 4.6 模型 1 数据拟合结果

重复以上工作，除去 500 组中恒稳定组（不论怎么施加降雨边坡都不会发生临界破坏）和恒失稳组（不施加降雨边坡都发生临界破坏）以及函数点较少的组，一共得到 143 组可用于随机森林训练的模型，提取拟合图像中的 $\log(\alpha)$，$-\beta$ 与其对应的模型输入参数作为 1 组随机森林的原始数据，重复此工作，最后得到 143 组随机森林原始数据组。如表 4.4，至此随机森林原始样本数据集的准备工作到此完成。

表 4.4 降雨阈值模型的随机森林样本数据集

| | 边坡高度 | 边坡倾角 | 粘聚力 | 内摩擦角 | $\log(\alpha)$ | $-\beta$ |
|---|---|---|---|---|---|---|
| 1 | 6.99 | 61.25 | 8.11 | 18.28 | 2.0792 | -1.084 |
| 2 | 35.36 | 31.66 | 34.76 | 13.51 | 3.7507 | -1.7261 |
| 3 | 12.23 | 40.40 | 10.62 | 13.92 | 2.8295 | -1.4144 |
| 4 | 34.20 | 46.56 | 21.68 | 23.63 | 3.8666 | -1.7838 |
| 5 | 24.24 | 41.37 | 23.95 | 17.65 | 4.2055 | -1.9339 |
| 6 | 25.20 | 31.07 | 23.95 | 17.65 | 3.5242 | -1.7797 |
| …… | …… | …… | …… | …… | …… | …… |



2025. 04. 10. 22. 12. 207791

续表 4.4 降雨阈值模型的随机森林样本数据集

| | 边坡高度 | 边坡倾角 | 粘聚力 | 内摩擦角 | log($\alpha$) | -$\beta$ |
|---|---|---|---|---|---|---|
| …… | …… | …… | …… | …… | …… | …… |
| 140 | 30.97 | 48.73 | 22.27 | 27.70 | 4.5423 | -2.1836 |
| 141 | 19.42 | 59.14 | 8.82 | 25.33 | 2.4534 | -1.3305 |
| 142 | 14.00 | 54.72 | 22.98 | 21.04 | 3.9669 | -1.9013 |
| 143 | 31.73 | 67.73 | 38.97 | 28.41 | 4.5183 | -2.1104 |

## 4.4 基于随机森林的诱发滑坡降雨阈值模型构建

### 4.4.1 随机森林的构建步骤

随机森林是一种基于决策树集成的算法，集成学习通过组合多个弱学习器来构建强学习器，旨在通过集合弱学习器的优势，实现优于单一弱学习器的学习效果。在众多集成策略中，bagging 和 boosting 是两种广泛应用的方法，而随机森林正是 bagging 方法中最具代表性的算法之一。

随机森林的构建过程如下：

（1）给定训练样本，其样本容量为 $n$，特征数为 $M$。

（2）设定输入特征的数量为 $m$，且满足 $m$ 远小于 $M$，用于决策树中前一节点的决策依据。

（3）采用自助采样法进行 $n$ 次有放回抽样，构建单棵树的训练集，未被抽取的样本构成袋外数据集（OOB），用于模型泛化能力的动态评估。

（4）节点分裂阶段，系统从 $M$ 维特征中随机选取 $m$ 个候选属性，基于基尼系数或信息增益准则，从候选特征中确定最优划分方案。

（5）将各决策树模型整合为一个随机森林模型。

### 4.4.2 数据准备与预测

（1）评价指标的选取

由 4.3.2 的内容得知，特征输入选取边坡高度、边坡倾角、土的粘聚力和土的内摩擦角对边坡岩体的稳定性影响最大。故本小节此 4 个控制因素作为随机森林预测模型的特征输入，如图 4.2 所示。

其中：$H$ ---边坡高度（m）；

Φ ---边坡倾角（°）；

$c$ ---潜在滑动面的内聚力（kPa）



2025.04.10.22.12.207791

$\varphi$---潜在滑动面的内摩擦角（°）；

（2）学习样本的构造

在构建基于随机森林的诱发滑坡降雨阈值预测模型时，首要任务是构建高质量的训练数据集。该算法的预测效能高度依赖于训练集的科学构建，其中样本质量的两个关键维度将直接影响模型性能：数据规模与典型性特征。样本规模需合理控制，数据量过大可能导致计算效率降低并引发过拟合现象。反之，样本规模不足则难以充分体现算法特性，进而影响模型的泛化性能。样本的典型性受原始数据质量制约显著，部分研究区域存在观测数据匮乏现象，直接影响样本集的代表性。对于数据完备的研究对象，建议优先选择包含极端值的样本组合以增强模型适应性。

本文使用的学习样本是 4.3.4 节通过 GeoStudio 有限元建模分析使用输入参数包括边坡高度、边坡倾角、粘聚力和内摩擦角，其中输出取无量纲$\log(\alpha)$、$\beta$得到的结果（见表 4.4）。该数据由 500 组数模分析得到，涵盖了广泛的坡度几何形状以及抗剪强度参数，最后共 143 可用于学习样本。与传统的区域降雨阈值预测相比，此方法更具专一性，适用于单个滑坡。同时也避免了某些地区由于资料缺失或不足造成滑坡事件，从而影响居民的人生财产与生命安全。

（3）降雨阈值预测模型的初步构建

当特征输入确定后，首先将数据集中的 143 个样本按照 2∶8 的比例随机划分产生测试集和训练集。其中训练集扮演着至关重要的角色。其主要功能是为模型提供相应的输入特征以及对应的目标值，通过这一过程，模型能够深入学习并掌握输入特征与目标值之间潜在的复杂映射关系。训练集要尽可能大，能涵盖输入和输出的全部范围；测试集是用于评估模型的最终性能，测试集必须是模型训练过程中未曾使用过的数据。随后建立随机森林回归模型，以其默认的 n_estimators=100 设置为决策树的数量，random_state=42 设置随机种子数来建立回归模型。然后训练模型，再使用模型进行预测，通过计算测试集中的决定系数与均方误差来判断模型的好坏。在监督学习模型评估体系中，均方误差与决定系数构成关键性评价指标。前者定义为样本观测值与模型输出结果之间残差平方和的均值，其数值与模型预测精度呈现负相关关系，即该指标越小表征模型预测偏差越小；后者作为统计学中的重要度量参数，通过计算模型可解释方差与总方差的比例来量化模型对观测数据的解释能力，其理论值域限定在[0,1]区间，当该系数趋



2025.04.10.22.12.207791

近于理论极大值时，表明回归模型能够充分捕捉数据集的变异特征。

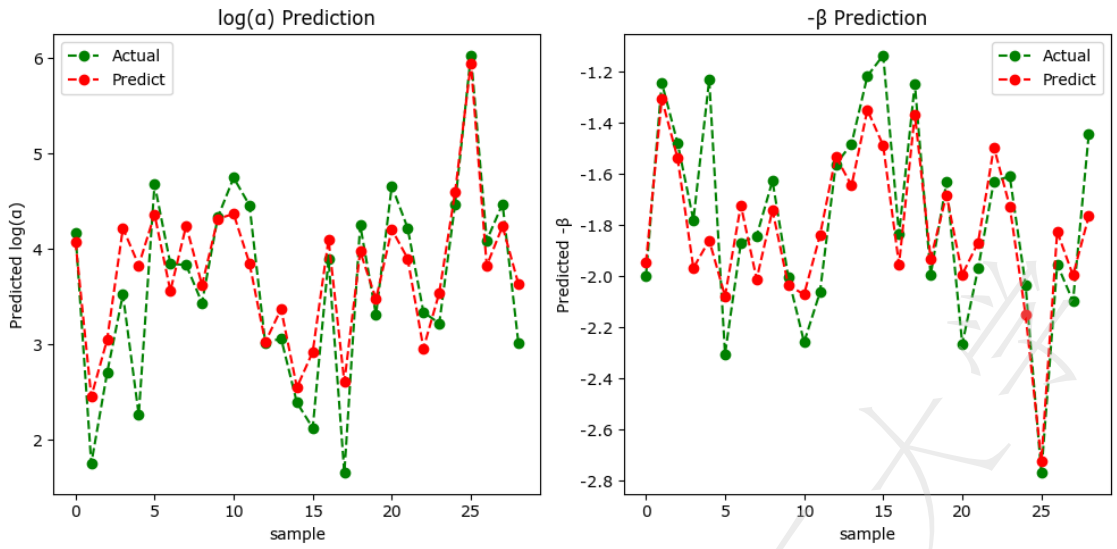



图 4.7 测试集实际值与预测值对比图

经训练后，rf_model 在测试集上的回归系数 $R^2$ 为 0.74，均方根误差 MSE 则为 0.145，其拟合效果在图 4.7 中得以呈现。该图横坐标为单个样本点，纵坐标为目标函数值，红色代表预测值，绿色代表真实值。由图可知，其拟合效果一般，图中存在不少个别点的预测值与实际值相差过大的情况，如样本点 4，$\log(\alpha)$ 实际值为 2.2，预测值 3.8；样本点 5，$-\beta$ 实际值-1.2，预测值-1.9。故后期需要对其模型进行调参优化，使其预测效果能得到提升。

### 4.4.3 随机森林模型的调优

随机森林调优旨在提升模型性能与泛化能力。核心的超参数包括树的数量（n_estimators）、最大深度（max_depth）、节点分裂最小样本量（min_samples_split）和特征选择数（max_features）等。通过网格搜索和全局寻优结合交叉验证，系统评估参数组合，平衡模型偏差与方差，避免过拟合。调优可提升预测精度、降低计算成本，并增强模型解释性。注意参数间的交互影响，最终选择验证集表现最优的配置，使模型在效率与准确率间达到最佳平衡。

优化模型性能的关键环节在于超参数调优，这在随机森林算法的改进过程中具有重要作用。工程应用时需基于数据特性实施参数优化策略，通过系统探索最佳参数配置使模型达到最佳性能表现。目前主流的调优技术包括网格搜索、随机参数探索以及智能优



2025. 04. 10. 22. 12. 207791

化算法。

具体实施时通常配合交叉验证技术以提升评估可靠性。该技术既能准确衡量模型泛化能力，又可有效抑制过拟合现象。五折交叉验证的具体实现过程为：将原始训练数据均等划分为五个互斥子集，每轮迭代使用四个子集构建模型，剩余一个用于验证模型效果。经过五轮迭代验证后，计算各轮次评估指标的均值作为最终性能判据，其原理下图 4.8 所示。本研究采用全局寻优与交叉验证协同应用的调优方案，确保参数选择的科学性与有效性。

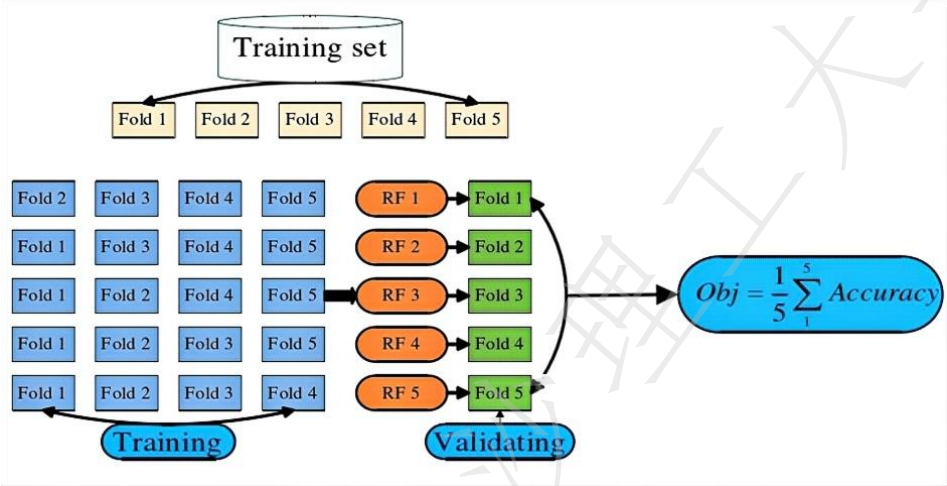



图 4.8 五折交叉验证原理图

根据各超参数对模型影响程度的不同，选取了影响较大的 3 个超参数进行调参，如上表 4.5 所示。

表 4.5 调整的超参数及其含义

| 超参数 | 解释 |
|---|---|
| n_estimators | 决策树的个数 |
| max_depth | 树的最大深度 |
| min_sample_split | 叶子节点所需最少样本 |

（1）随机森林初步调参优化

a）数据预处理

本文将使用计算机编程语言 python 对随机森林进行调参优化，首先导入机器学习的基础库 numpy 和 pandas。对相关字体进行可视化，然后使用 pd.read_excel 读取原始数据集，由于每个变量都有用，故不做删除无用变量处理；最后对原始数据集的特征输入和目标变量进行赋值。



2025.04.10.22.12.207791

b）数据标准化

鉴于样本数据各维度的量纲和单位存在差异，为消除特征尺度悬殊可能引发的潜在偏差，本文运用极值标准化方法对原始数据进行预处理。该方法的数学表达式如式(4.3)所示。通过实施数据规范化操作，一方面可有效提升优化算法的收敛速率，增强模型的训练效能；另一方面能显著改善算法的预测性能与泛化能力，使得模型具备更强的鲁棒性。

$$x_{norm} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \tag{4.3}$$

其中，$x$ 为特征原始数据，$x_{\max}$、$x_{\min}$ 分别为特征最大值和最小值；$x_{norm}$ 为归一化处理后的数据。

c）训练集与测试集的划分

完成归一化处理后，原始观测值被规约至单位区间[0,1]范围内。采用随机抽样策略将样本集按 8:2 的比例拆分为训练子集和测试子集，前者用于参数学习与模型训练，后者则负责检验模型泛化能力评估。

d）交叉验证与网格调参

从机器学习库中导入随机森林回归器 Random Forest Regressor 和网格调参 GridSearchCV。为了设置 n_estimators：树的数量、max_depth：树的深度和 min_samples_split：叶子节点所需最少样本数这 3 个参数。首先预设 n_estimators 范围及间距为（3，20，1），max_depth 范围为（2，10），min_samples_split 范围为（2，4），然后初始化随机森林，采用五折交叉验证的网格调参训练模型，最后输出最优模型的最优参数。得到树的深度 max_depth=5，树的数量 n_estimators=3，节点所需最少样本数 min_samples_split=4。

由于预设的范围太小，可能未包含最优情况下的超参数，故绘制学习曲线，可以通过绘制学习曲线，可视化的了解调参的过程，从而更加形象的看出整个全过程的得分变化情况。首先对网格进行调参，计算训练得分和测试得分；其次统计交叉验证的均值和标准差；最后进行绘制曲线。



2025.04.10.22.12.207791

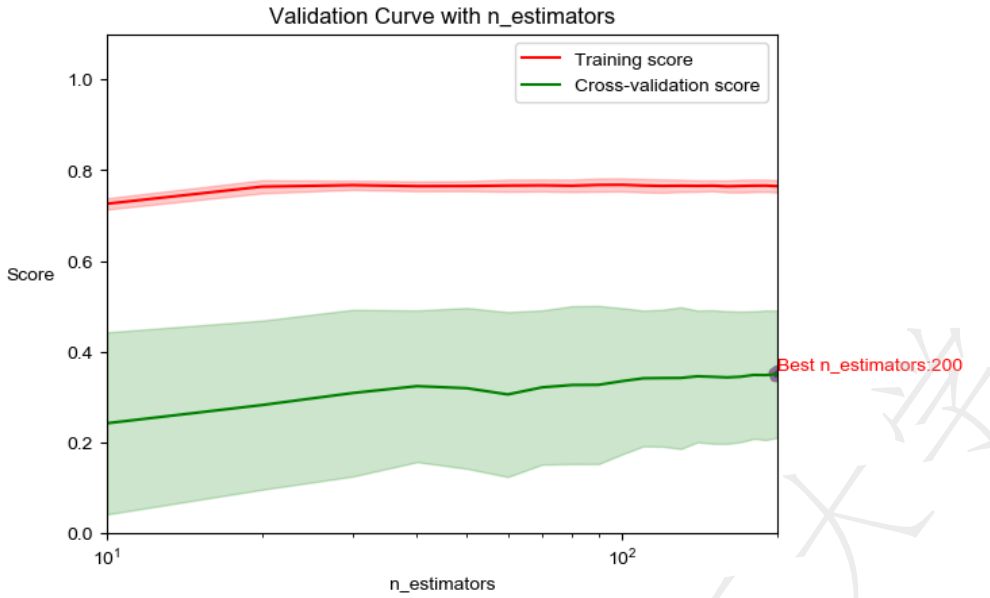



图 4.9 n_estimators 调参验证曲线

如图 4.9 所示，该图横坐标为树的数量，纵坐标为 $R^2$ 得分，由图可知红线为训练集上的得分，绿线为测试集上的交叉验证 $R^2$ 得分；训练集上的 $R^2$ 得分随着树的数目的增加呈缓慢增加的趋势并稳定在 0.7-0.8 之间；而测试集上的交叉验证 $R^2$ 得分也随着树的数目的增加呈缓慢增加的趋势，当树的数目为 200 时达到最大。

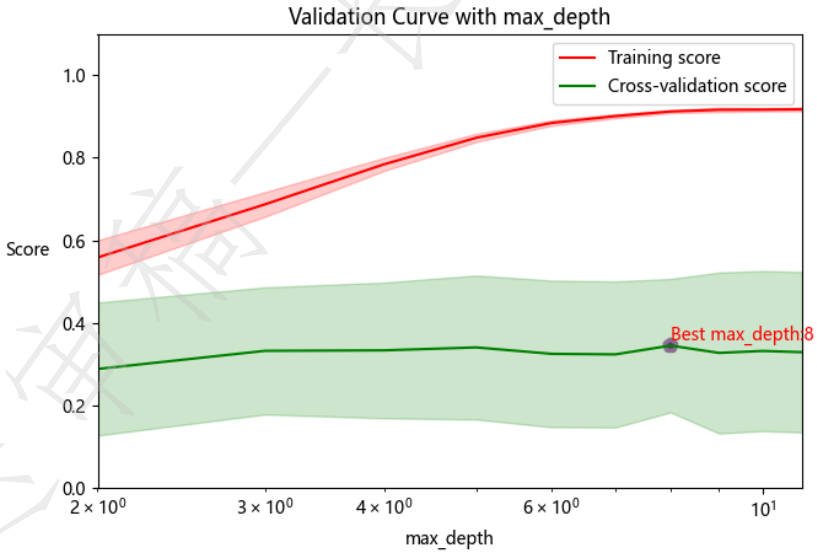



图 4.10 max_depth 调参验证曲线

确定好 n_estimators=200 后，将 n_estimators 的值代入到随机森林模型中，然后对树的深度 max_depth 进行调参，结果如图 4.10 所示。该图横坐标为树的深度，纵坐标为 $R^2$ 得分；红线为训练集上的得分，绿线为测试集上的交叉验证 $R^2$ 得分。由图可知训练集上



2025. 04. 10. 22. 12. 207791

的 $R^2$ 得分随着树的深度 max_depth 的增加出现急速上升的趋势，当树的深度 max_depth 达到 8 以后曲线基本保持最大 $R^2$ 得分 0.9 不变；而测试集上的交叉验证 $R^2$ 得分也随着树的深度 max_depth 的增加呈波动变化的趋势，当树的深度 max_depth=8 时达到最大。

e）模型性能评估

使用寻找到的最优参数建立随机森林模型，之后将建立好的模型对训练集和测试集进行模拟，最后得到其均方误差（MSE）和可决定系数（$R^2$）如下表 4.6 所示。

表 4.6 模型评估结果

| | 均方误差（MSE） | 可决定系数（$R^2$） |
|---|---|---|
| 训练集 | 0.145409 | 0.703264 |
| 测试集 | 0.108439 | 0.824263 |

由于测试集是用于评估模型的最终性能，而测试集上的可决定系数 $R^2$ 得分仅仅只有 0.703264，效果一般，故后续还需要对其超参数进行更进一步优化，使其能达到预期效果。

（2）随机森林全局寻优调参

由于传统序贯参数优化方法存在的局限性，本次采用了一种基于多参数联合优化的全局搜索策略。具体而言，传统方法采用的逐次单参数优化（Sequential Parameter Optimization）策略虽能提升单个参数性能指标，但忽视了参数间的非线性耦合关系，可能导致系统陷入局部最优解（Local Optimum）。为解决这一问题，本次改进采用三维参数空间联合优化方法，通过构建 n_estimators（决策树数量）、max_depth（树最大深度）和 min_samples_split（叶子节点所需最少样本数）的三维超参数网格，运用穷举搜索（Exhaustive Search）算法进行全局寻优。从而有效克服了传统方法中参数协同效应（Synergistic Effect）缺失的问题。

a）扩大全局搜索范围

基于上述理论，同时扩大树的深度、树的数量以及叶子节点所需最少样本数的范围。树的深度扩大为（3，30）之间，且从 3 开始进行迭代计算；树的数量扩大为（10，500）之间，且从 10 开始进行迭代计算；叶子节点所需最少样本数扩大为（2，10）之间，且从 2 开始进行迭代计算。然后训练其随机森林模型，然后对训练集和测试集进行预测。以测试集上的可决定系数 $R^2$ 为评判模型的标准，输出其每次组合迭代情况下的得分及三个超参数的值。最终得出三个参数的最优解为 max_depth=10，n_estimators=100，



2025.04.10.22.12.207791

min_samples_split=2，此时测试集上得分为 0.9079。

b）可视化预测误差

从机器学习度量指标库中导入回归模型评价指标，使用寻找到的最优参数建立模型。

best_model = RandomForestRegressor（random_state=222,

max_depth=10，n_estimators=100，min_samples_split=2）

best_model.fit（train_x, train_y）

输出其训练集和测试集上的均方误差（MSE）与可决定系数（$R^2$）如下表 4.7 所示。可以发现训练集上的均方误差由原来的 0.145409 降到了 0.038868，其模型的预测精度提高了 73.2%；可决定系数（$R^2$）由原来 0.703264 提高到 0.920154，其模型对数据的拟合程度提高了 23.6%。在测试集上的均方误差由原来的 0.108439 降到了 0.054121，其模型的预测精度提高了 50.1%；可决定系数（$R^2$）由原来 0.824263 提高到 0.907934，其模型对数据的拟合程度提高了 10.15%。而测试集是用于评估模型的最终性能，其 $R^2$ 得分为 0.907934，说明该随机森林模型拟合优秀。

表 4.7 全局寻优后模型评估结果

| | 均方误差（MSE） | 可决定系数（$R^2$） |
|---|---|---|
| 训练集 | 0.038868 | 0.920154 |
| 测试集 | 0.054121 | 0.907934 |

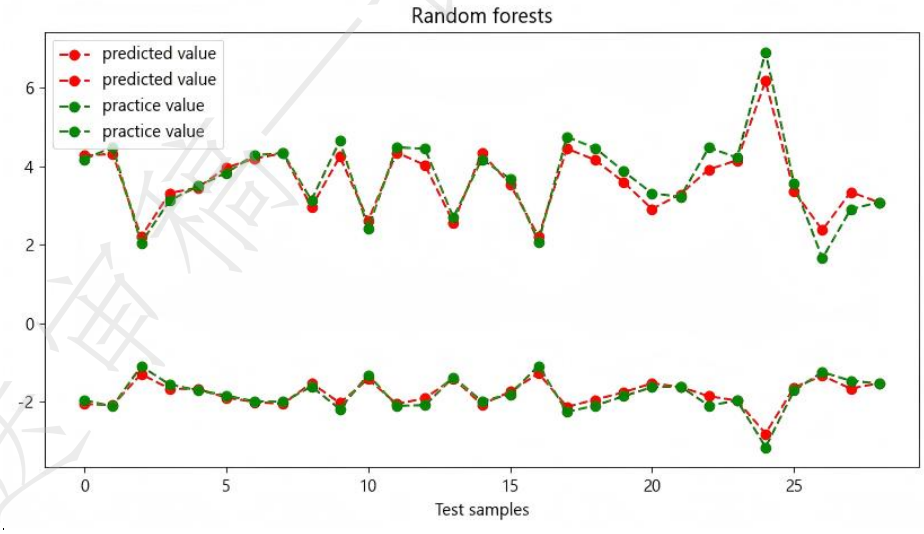



图 4.11 测试集 $\log(\alpha)$ 与 $-\beta$ 实际值与预测值对比图

最后，将随机森林在测试集上的拟合效果图可视化如上图 4.11 所示。红色点表示预测值，绿色点表示真实值。横坐标为测试集的样本，一共 28 组；纵坐标为 $\log(\alpha)$ 与 $-\beta$



2025. 04. 10. 22. 12. 207791

的值。其中下方折线表示的是$-\beta$的预测值与真实值可视化误差；上方则为$\log(\alpha)$的预测值与真实值可视化误差。从图 4.11 中可以看出，所构建的 RF 模型对样本点实现了较为精准的拟合，其预测结果具有较高的准确性。同时误差也误差较小，且整体$-\beta$的拟合效果高于$\log(\alpha)$的拟合效果。

### 4.4.4 诱发滑坡降雨阈值预测模型的结果分析

在上一小节中，本文运用交叉验证与全局寻优的方法，确定了相对最优的学习算法参数，进而构建了相应的算法架构，并运用该算法对降雨阈值系数进行评估，完成了模型的训练与测试工作。实践证明，所构建的随机森林算法模型不仅性能表现优异，而且具有简便易用的特点，能够为相关研究和应用提供有力支持。接下来将使用寻找到的最优参数建立随机森林模型，然后对其预测结果进行讨论分析。

（1）RF 模型预测结果

基于找到的最优 RF 模型，通过将样本数据集应用到此模型，最终得到训练集和测试集均方根误差（RMSE）和可决定系数（$R^2$）的回归性能结果如图 4.12-4.15。

如图 4.12 和图 4.14 所示，从折线图可以看出，在训练集和测试集上，所建立的 RF 模型能够较好地拟合样本点，降雨阈值系数$\log(\alpha)$与$-\beta$预测值和实际值总体相差不大即预测准确度较高，仅有部分预测值偏离真实值,但偏离程度较小，误差较小，这较为符合工程实际需求。计算各回归性能指标，训练集上模型的均方根误差为 0.197，可决定系数 R2 为 0.92。说明模型的训练效果较好；测试集上，均方根误差为 0.2326，可决定系数 R2 为 0.908。说明模型的泛化性能较好。

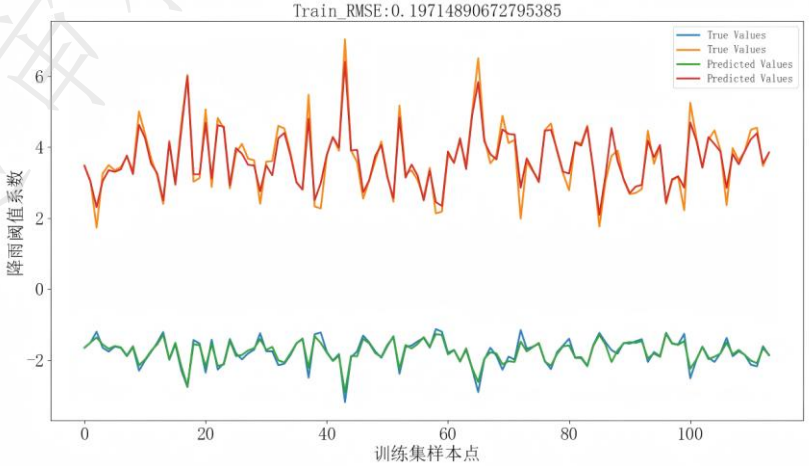



图 4.12 训练集上降雨阈值系数预测拟合情况（折线图）



2025.04.10.22.12.207791

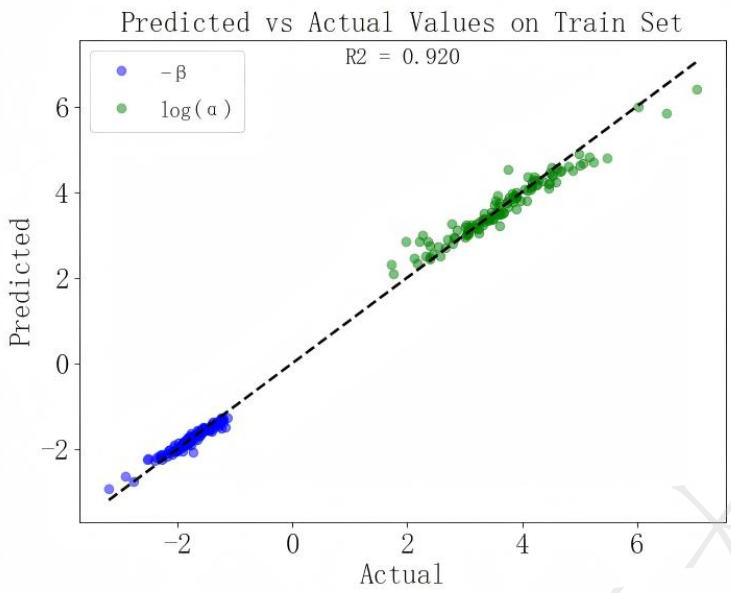



图 4.13 训练集上降雨阈值系数预测拟合情况（散点图）

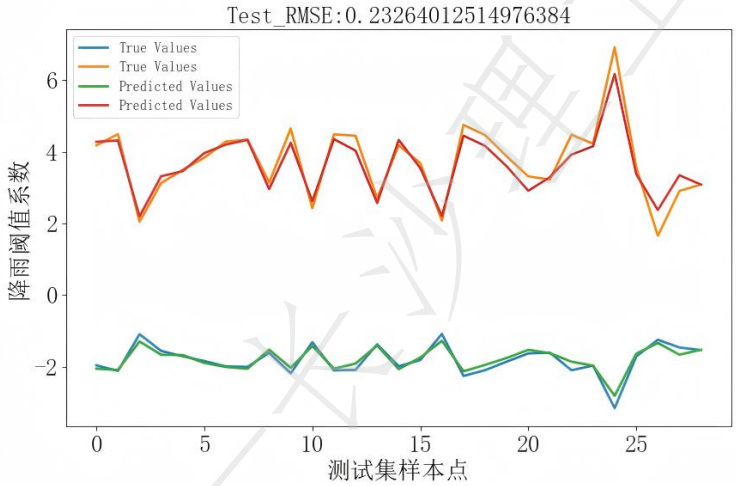



图 4.14 测试集上降雨阈值系数预测拟合情况（折线图）

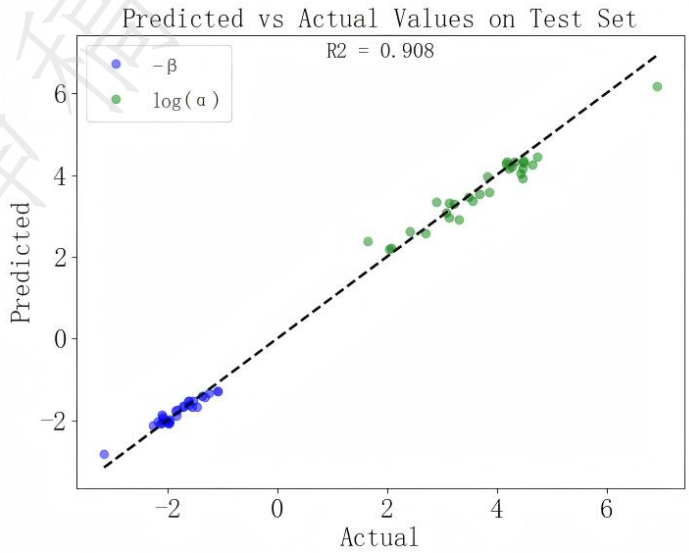



图 4.15 测试集上降雨阈值系数预测拟合情况（散点图）



2025.04.10.22.12.207791

由图 4.13 和图 4.15 散点图可看出，在训练集和测试集上，数据点在理论预测值与实际观测值一致的基准线周围呈现对称且密集的分布态势，即 $Fs_{(实际)}=Fs_{(预测)}$。回归分析结果表明，该算法能够有效捕捉安全系数与各关键参数之间的非线性关联特征，其拟合优度满足精度要求，验证了所建模型在边坡方面预测的可靠性。

（2）特征重要性分析

随机森林算法都具有计算特征重要程度并将其进行输出的功能。其中，特征重要性（feature_importance）是一种在某种程度上利于特征筛选并提高模型鲁棒性的特有属性。此外，针对边坡是否处于稳定状态的评估问题，特征重要性也可以从侧面反映各因素对边坡稳定的影响程度，从而为降雨诱发滑坡安全防护方案的制定提供有效参考，如图 4.16 所示。

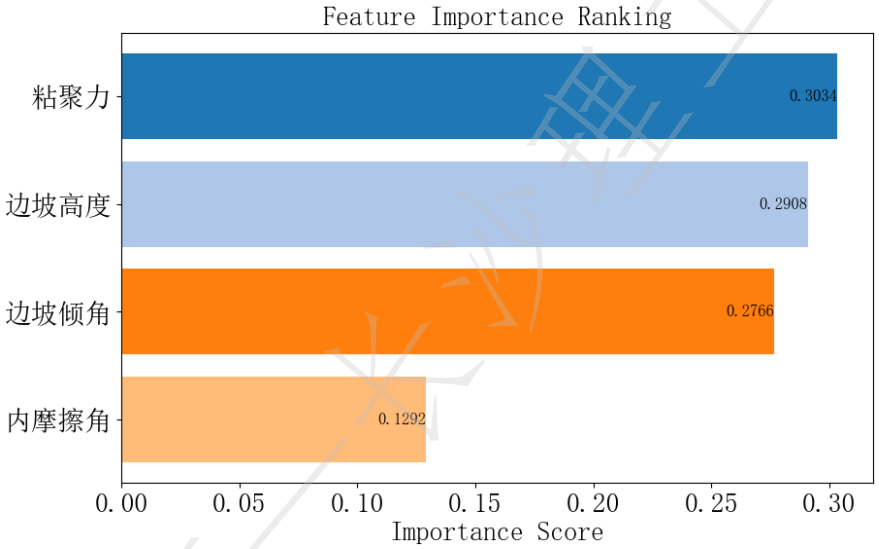



图 4.16 特征重要性分析（重复次数：10 次)

其中，横坐标为特征权重系数，纵坐标为各个特征。显然，粘聚力（0.3034）是影响边坡稳定性最敏感的因素，特征重要性排序为：粘聚力>边坡高度>边坡倾角>内摩擦角。边坡稳定性受多因素综合影响，各特征参数对失稳机理均具有显著作用，因此将其作为预测模型的输入参数是具备科学依据的。

研究表明，在特征选择过程中需重点考虑方法学的差异性，武梦婷[77]、Qi[78]及 Guyon[79]等学者的工作证实：数据集构成、分类算法及重要性评估方法的差异将显著影响特征权重的分布规律和排序结果。工程实践中建议选取关键控制指标（边体高度、边坡倾角、土体粘聚力）作为核心分析参数，并结合具体地质条件开展稳定性评价与防控



2025.04.10.22.12.207791

设计。需要指出的是，当前研究仍存在样本代表性不足和特征体系不完善等局限，随着相关研究的深入及多源数据的积累，通过建立更系统的特征工程框架有望获得更具普适性的结论。

## 4.5 本章小结

在本章中主要从介绍了降雨强度-历时(*I-D*)阈值模型、样本构造、降雨阈值的研究、参数优化、随机森林模型构建与结果分析，得到的结论如下：

（1）确定了以降雨历时为 10*d*，降雨强度范围为 0.3mm/h~15mm/h 的阈值模型，基于此阈值模型，以用 $\log(\alpha)$ 和 $-\beta$ 为随机森林的输出。

（2）采用了拉丁超立方抽样对 4 个特征输入抽取 500 组，并以有限元数值仿真软件 GeoStudio 进行仿真模拟，然后利用商业数学软件 Matlab 进行数据提取，最后通过 excel 拟合曲线得到 143 组有效原始样本数据集。

（3）通过全局寻优和交叉验证对模型超参数进行优化，最终确定了 max_depth=10，n_estimators=100,min_samples_split=2 的超参数值，并以使用寻找到的最优参数建立随机森林模型，使得测试集上的可决定系数（$R^2$）由原来 0.824263 提高到 0.907934，其模型的拟合精度提高了 10.15%；而均方误差（MSE）由原来的 0.108439 降到了 0.054121，其模型的预测误差降低了 50.1%。而测试集是用于评估模型的最终性能，说明了模型预测的准确性较高，有着很好的适用性。

（4）在特征重要性排序中，粘聚力（0.3034）是影响边坡稳定性最敏感的因素，特征重要性排序为：粘聚力>边坡高度>边坡倾角>内摩擦角。这些特征对边坡稳定性都有不可忽视的作用，可尝试作为边坡防治的着手点进行分析研究，且作为模型的输入是合理的。



2025.04.10.22.12.207791

# 第5章 基于诱发滑坡降雨阈值模型的边坡稳定性评价系统

我国境内约三分之二的陆地面积属于山地地形，在多个省级行政区划单位内，山地地貌占比超过九成。调查数据显示，全国范围内 84.3%的斜坡失稳现象与降雨活动存在直接或间接关联。降雨是滑坡的触发因素或前期诱因，每年由此引发的各类地质灾变不仅造成直接经济损耗数额惊人，其引发的次生影响带来的社会经济代价更难以精确量化。基于前期研究成果的系统梳理，本研究依托 PyQt[80]框架和 RF 模型构建新型技术平台，旨在整合地质力学参数与降雨要素，开发具备快速评估能力的诱发滑坡降雨阈值模型的边坡稳定性评价系统。该系统实现了滑坡数据管理与查询、临界降雨阈值计算、滑坡预警分析等核心功能。此系统架构采用 Python 语言开发环境，借助 PyQt6 实现前端界面与后端算法的无缝衔接，在确保运算效率的同时，将专业分析过程封装为可交互操作流程，显著降低了专业技术人员的操作复杂度。

## 5.1 需求分析

Petley 所构建的全球滑坡数据库[82]显示，在 2004 至 2010 年这 7 年时间里，总共记录了 2620 起滑坡灾害事件，这些灾害共造成 32322 人遇难。在这些滑坡灾害导致死亡人数较多的区域中，喜马拉雅山脉沿线以及中国境内是重灾区。在我国，滑坡灾害由于其发生频繁且危害巨大，已被列为地质灾害重点治理对象之一。在开展滑坡灾害的防治工作时，对于诱发滑坡的降雨阈值的评估是其中极为关键的一步。只有深入分析降雨情况以及滑坡的稳定性，针对不同降雨强度和降雨持续时间所引发的滑坡灾害，才能制定出相应的预防方案，并在滑坡发生之前及时组织人员撤离至安全地带。然而，当前行业内普遍缺乏一种能够直观、高效地对基于诱发滑坡降雨阈值模型的边坡稳定性评价与分析的可视化系统。通常情况下，专业设计人员需要花费大量时间与精力进行复杂计算以及数值模拟等工作，才能对诱发滑坡的降雨阈值做出较为准确的评估。鉴于以上情况，综合考虑各方面的需求，有必要结合 C/S 架构的优势，借助 PyQt6 这一强大的开发工具，搭建一个线上可视化平台。该平台应具备滑坡数据管理与查询、临界降雨阈值计算、滑坡预警分析等多个功能模块，以便以直观、清晰的可视化方式展示前期所完成的各项工作成果。



2025.04.10.22.12.207791

## 5.2 系统架构设计与实现环境

本系统采用客户端-服务器（C/S）模式构建，基于 Qt[81]框架的 Python 绑定技术进行开发。该架构不仅适用于本地图形界面（GUI）应用的构建，其胖客户端特性还可有效支撑复杂业务逻辑的实现，从而显著增强系统的事务处理效能。

（1）开发环境配置

研究开发的诱发滑坡降雨阈值模型的边坡稳定性评价系统选用 Windows10 64 位操作系统作为基础平台，配合 Anaconda3-5.1.0 集成环境（开源版本）。系统核心算法采用 Python 语言实现，主要依赖 scikit-learn、pandas 及 tkinter 等科学计算库。鉴于这些库存在复杂的依赖关系，选择集成式开发环境 Anaconda 可有效解决依赖包管理问题，既保障了开发效率，也降低了用户后期的部署难度。

（2）运行环境要求

系统可兼容 Windows 7 及更高版本的 64 位操作系统，需安装 Anaconda 运行环境（Windows 平台，Python3.7 版本）。硬件配置方面，建议至少预留 2GB 内存空间和 3GB 存储空间，以满足计算过程中的资源需求。这种环境配置既保证了系统运行的稳定性，也兼顾了用户端的易用性特征。

## 5.3 系统架构构建

### 5.3.1 系统开发目标

滑坡灾害是由多种复杂环境要素相互作用而引发的地质现象，其防治工作需以稳定性状况评估为前提。本研究建立的智能分析平台通过集成用户交互界面与机器学习算法，可依据输入的边坡参数（包括边坡倾角、边坡高度、土体粘聚力、土体内摩擦角）及降雨数据，运用集成学习中的随机森林回归算法，实现降雨诱发型边坡失稳风险的定量化评估。结合前期研究成果及工程实践需求，本系统拟达成以下建设目标：

（1）收集第四章的特征输入数据，经 GeoStudio 模拟后，将诱发滑坡的降雨阈值数据存储于系统数据库。同时，用户可对滑坡数据进行增删操作，并具备数据查阅功能。

（2）在滑坡分析流程中，系统服务器端将调用随机森林算法脚本，构建基于诱发滑坡降雨阈值模型的边坡稳定性系统。该模型依据随机森林算法，对滑坡特征输入数据进行降雨阈值系数预测与绘制降雨阈值函数图，为滑坡灾害防治提供科学依据。

（3）最后通过输入降雨参数对滑坡进行可视化预警分析。



2025.04.10.22.12.207791

### 5.3.2 系统架构层次划分

如图 5.1 所示的本系统层级结构示意图，采用分层架构模式自上而下划分为四个功能层级：

表现层：基于 PyQt 框架构建用户交互界面，负责与使用者进行可视化信息交互。该层级集成输入有效性验证机制，对用户提交的表单数据进行实时合规性检测。

应用层：依据前期研究成果整合核心功能模块，主要包括滑坡数据管理与查询、临界降雨阈值计算、滑坡预警分析等核心业务组件。

中间层：承载滑坡稳定性快速评价模型与降雨阈值预测算法的核心实现，采用 Python 编程语言构建机器学习模型的核心算法。系统通过标准化接口调用算法脚本，实现模型服务的灵活部署与调用。

数据库层：存储支撑随机森林模型的基础数据集，具备接收上层数据请求的事务处理能力。




图 5.1 系统总体结构图

## 5.4 系统功能架构设计及灾害预警应用

基于前期研究成果与实际应用需求，本研究构建了包含三大核心功能的滑坡预警系统，其架构示意图详见图 5.2。各功能模块的具体设计如下：

（1）数据管理

该组件主要用于维护滑坡灾害基础数据，支持在现有数据库基础上进行灾害样本的动态调整。用户可根据实际需求对样本数据进行实时更新，包括新增灾害点录入和历史



2025. 04. 10. 22. 12. 207791

数据删除等操作。

（2）用户管理

系统内的普通用户能够维护自身信息，系统管理员则可维护系统内所有用户信息。

（3）预警分析

作为本系统的核心功能模块，该单元集成了随机森林算法。用户通过可视化界面输入边坡参数及降雨特征参数后，系统将调用随机森林算法脚本，来预测诱发滑坡的降雨阈值，并通过输入降雨参数后评估其此边坡稳定性，计算后将稳定性结果呈于系统界面右侧区域。

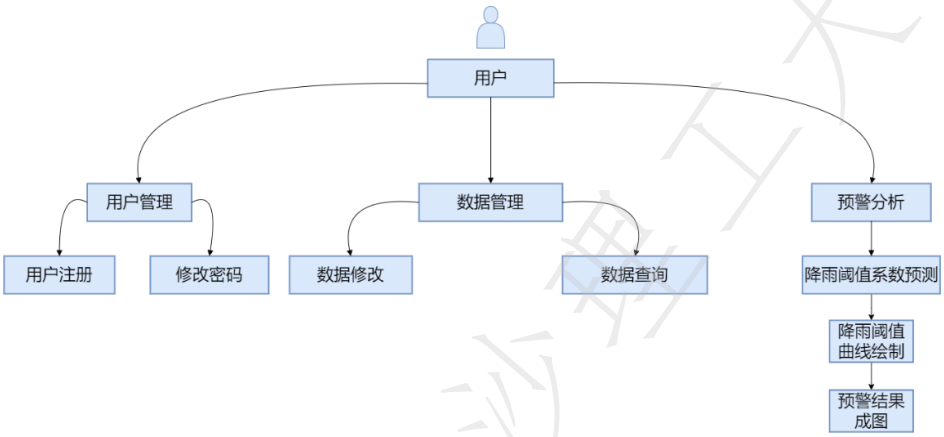



图 5.2 系统功能结构图

### 5.4.1 程序设计流程

基于诱发滑坡降雨阈值模型的边坡稳定性评价系统的设计流程如图 5.3 所示

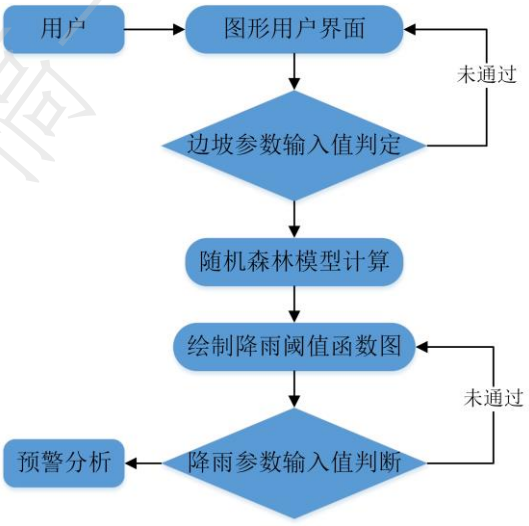



图 5.3 程序设计流程

详细流程说明如下：



2025.04.10.22.12.207791

（1）用户登录后，输入边坡的 4 个特征输入，分别是边坡高度、边坡倾角、土的粘聚力和土的内摩擦角。

（2）当系统获取边坡特征参数后，首先执行输入数据有效性校验环节。该环节将对参数数值进行合规性检测，若满足预设约束条件，则转入随机森林预测阶段；若存在异常数值，系统将在人机交互界面生成针对性错误代码及修正建议，待用户完成参数调整后重新触发数据校验程序。

（3）通过有效性验证的边坡参数将导入随机森林预测模型处理单元，经过算法运算后输出两个关键性降雨阈值指标。

（4）根据得到的降雨阈值参数，系统将自动绘制降雨阈值函数图，并划分安全区与危险区。

（5）随后进入降雨参数输入值判断模块，若输入值在规定范围内，则进行下一步：预警分析；若输入值未在规定范围，则提示错误，返回上一级重新输入。

（6）最后，通过输入的降雨参数会在降雨阈值函数图中显示出样本点，并根据输入的降雨参数落入的区域提示此状态下是否会发生滑坡。

### 5.4.2 系统交互界面架构设计

在程序应用系统中，人机交互界面的设计质量直接影响用户的操作体验。优秀的交互界面应当具备界面简洁、操作引导、错误容限等基本特征。本研究开发的诱发滑坡降雨阈值模型的边坡稳定性评价系统正是基于这些设计原则构建其图形化界面。该系统的可视化操作平台由三大核心模块构成：初始引导界面、主运算面板及功能对话框。

（1）初始引导界面

系统启动后首先呈现初始化引导界面（如图 5.4 所示）。界面主体采用与滑坡研究主题高度契合的动画作为背景。界面左上方醒目位置标注系统全称“基于诱发滑坡降雨阈值模型的边坡稳定性评价系统”。操作区域包含三个交互式按钮：“声明”、“登录”和“退出”。其中，“声明”按钮用于展示软件使用许可协议（详见图 5.5）。“登录”按钮设有双重验证机制，用户需勾选确认选项的复选框后方可激活登录功能，成功验证后进入主运算界面；若未完成确认操作，系统将触发警示对话框（参考图 5.6）。“退出”按钮则执行系统关闭指令，结束当前会话。



2025.04.10.22.12.207791

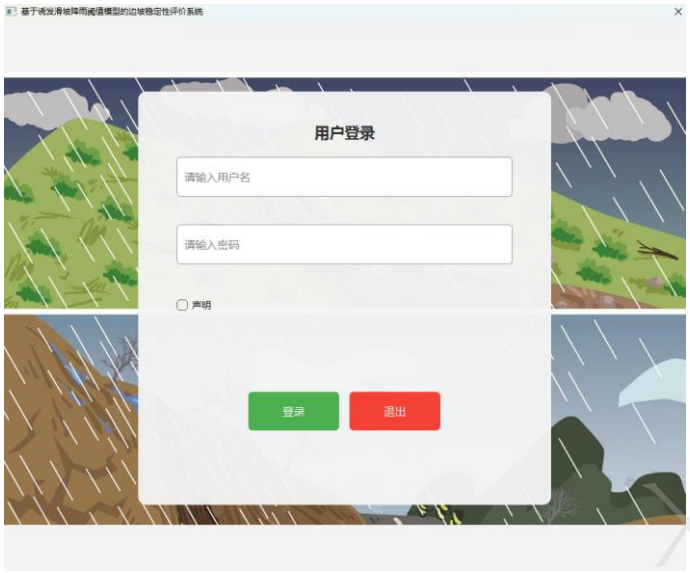



图 5.4 初始引导界面

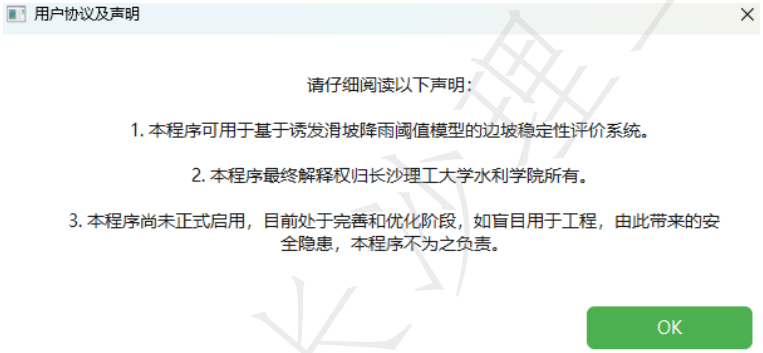



图 5.5 声明内容

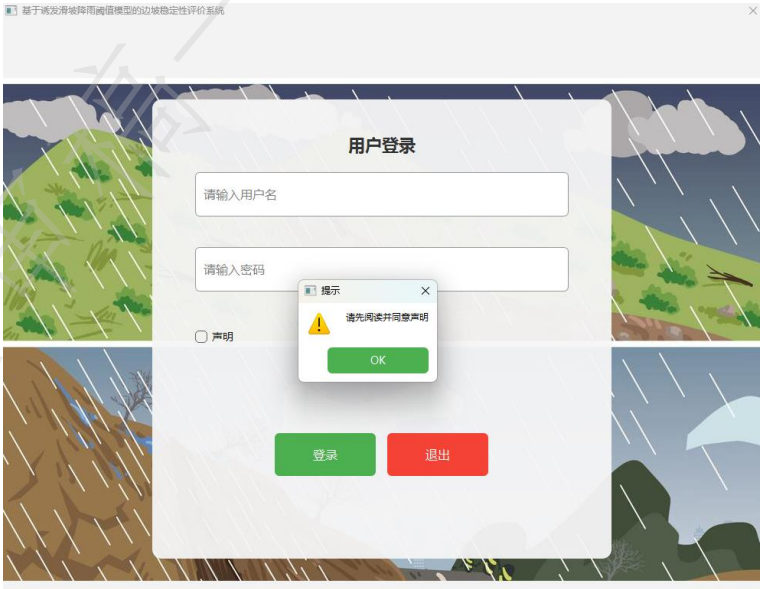



图 5.6 未勾选复选框情况下点击登录键



2025.04.10.22.12.207791

（2）主运算面板

系统主运算面板的布局结构详见图 5.7 所示，按照功能模块划分主要包含三个核心组件。顶部区域集中布置操作功能区，左侧面板为参数输入模块，右侧组合区域则整合了预测分析结果展示界面及可视化图形输出单元。




图 5.7 主运算面板

①功能区：该区域集成了预警分析、数据管理以及用户管理三项功能，用户可依据自身需求点击相应选项以实现功能切换。

②参数输入区：该区域设置四个控制单元：“预测”、“绘图”、“清空”、“退出”。“预测”负责执行基于随机森林的诱发滑坡降雨阈值模型计算核心算法；“绘图”模块可将降雨阈值系数进行二维坐标可视化绘制；“清空”用于清除当前输入参数及计算结果；“退出”实现程序的安全关闭。用户需在指定输入框内准确录入边坡几何参数与降雨特征参数数值，系统将依据图 5.3 所示流程进行数据解析与运算。

③结果展示模块：本区域包含数值输出窗口与动态绘图面板，分别呈现随机森林算法计算结果及阈值函数图。

（3）功能对话框

在系统运行过程中，为优化人机交互体验并降低操作难度，系统需对用户行为进行实时响应。其中，对话框作为关键交互组件，在用户输入异常时发挥着重要作用。本研究开发的基于诱发滑坡降雨阈值模型的边坡稳定性评价系统的 GUI 对话框模块，依托数值校验机制实现输入检测功能。通过分析图 5.3 所示流程可知，当检测到异常输入时，



2025. 04. 10. 22. 12. 207791

系统自动触发对应的错误提示信息，用户可依据具体提示内容快速定位问题参数。

图 5.8 展示的三种典型场景验证了该机制的可靠性。以图 5.8 a 为例，当边坡高度参数被赋值为-1 时，系统立即弹出“边坡几何参数需为正值”的警示信息，提示用户核查该物理量的合理性。图 5.8 b 呈现了数据类型异常情况，当边坡倾角字段接收字符型输入时，界面将显示“边坡倾角参数需为数值型数据”的校验结果。对于参数范围越界情形，如图 5.8 c 所示，当粘聚力值设定为 1kPa 时，系统生成“岩土粘聚力建议取值 5-40kPa”的专业提示。上述实例表明，本系统设计的动态校验机制能有效辅助用户识别并修正输入异常。




a） 输入值为负数判断　　b） 输入值为字母判定




c） 输入值不在理论范围内判断

图 5.8 错误提示信息



2025. 04. 10. 22. 12. 207791

### 5.4.3 用户信息管理

本部分实现了系统基础功能中用户信息管理模块的可视化。其界面设计如图 5.9 呈现，该界面由用户注册栏和修改密码栏组成。




图 5.9 用户信息管理

### 5.4.4 数据管理

本部分作为系统中滑坡样本数据管理模块的核心构成，完成了相关功能的开发与实现。其功能界面设计如图 5.10 呈现，点击“打开原始数据集”键，即可查询和修改数据样本集。

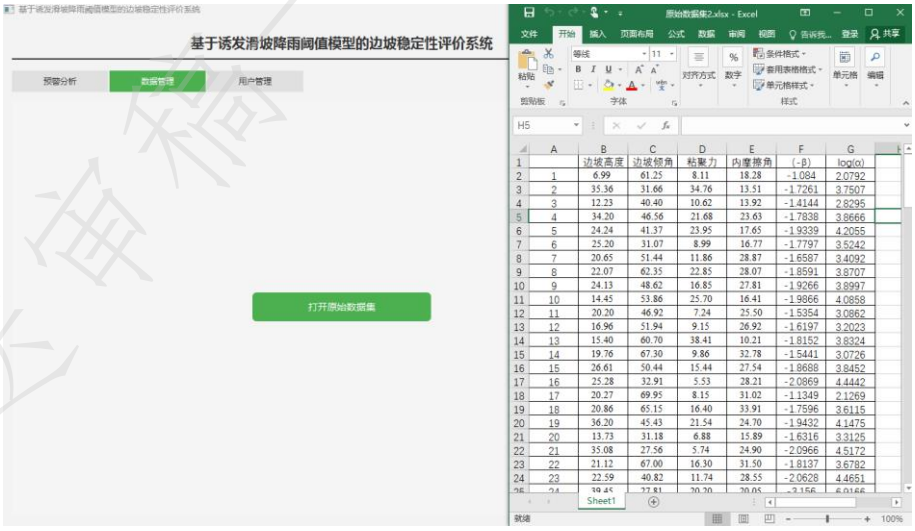



图 5.10 查询滑坡数据



2025.04.10.22.12.207791

### 5.4.5 滑坡预警分析

（1）开发环境及运行环境的准备

诱发滑坡降雨阈值模型的边坡稳定性评价系统采用 Python 语言开发，以.py 文件形式存于 robit 文件夹内。该文件夹还包含随机森林最终模型文件 main.py，以及登录界面所用照片文件，如登录界面背景图像（bg.jpg）和原始数据集 2 等。Main.py 为随机森林最终模型文件，即以四个特征参数边坡高度，边坡倾角，粘聚力，内摩擦角为输入，以降雨阈值系数 *log(a)*、*-β* 为双输出的模型（经过调参、训练等得到的最佳训练模型）。该模型经超参数优化与测试验证获得最佳性能，具备持续优化功能，可通过新增实测数据进行迭代训练以提升预测精度。

系统运行流程如下：

1）环境配置：安装开源 Python 发行版 Anaconda（推荐 Python3.7 版本），建议从清华大学镜像站下载适配 Windows 系统的安装包。

2）依赖库安装：在命令提示符窗口执行指令：pip3 install PyQt6 -i https://pypi.tuna.tsinghua.edu.cn/simple。

3）程序启动：定位至 robot 目录路径，执行命令：python gui.py。

具体操作过程详见示意图 5.11 所示的工作流图示。

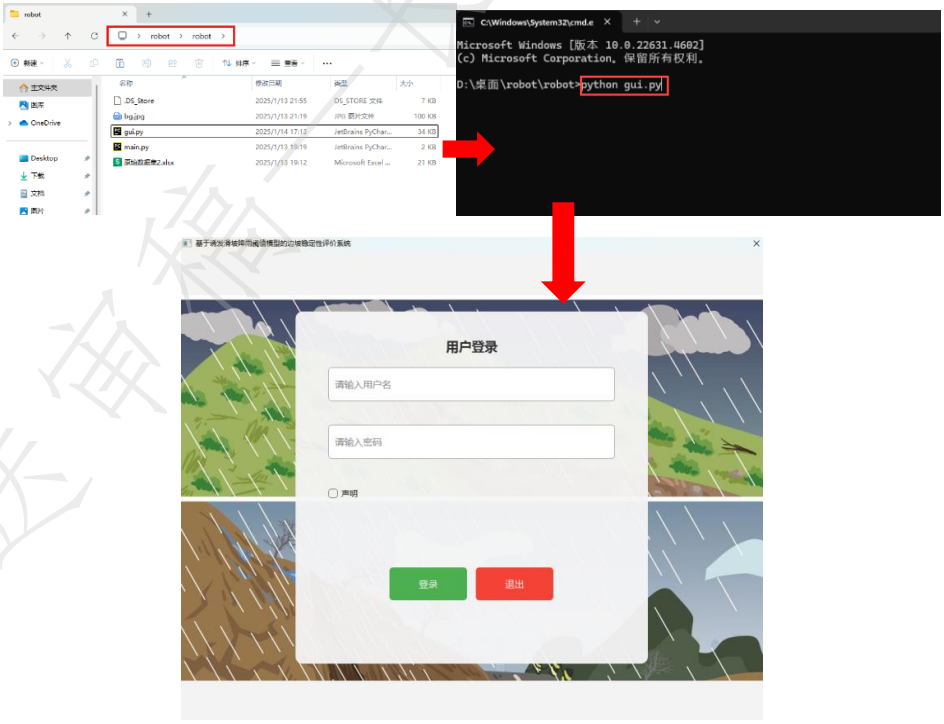



图 5.11 工作流程图



2025. 04. 10. 22. 12. 207791

（2）系统登录

因为我们的数据源并不是免费开源的，只有通过注册之后的账户，通过管理员授权的账户，才可以访问基于诱发滑坡降雨阈值模型的边坡稳定性评价系统，用户才可以访问系统数据库，对系统中的各类信息进行查询、分析。这样可以保证系统的内部数据的绝对安全。

系统启动后，系统将显示初始引导页面。操作流程要求用户首先在界面左下角选择声明按钮，详细阅读并理解声明条款；随后需勾选确认位于声明控件前方的选择框；完成上述操作后，通过点击登录按钮即可跳转至核心运算界面。若用户拒绝接受声明所述条款，可选择退出按钮关闭应用程序。

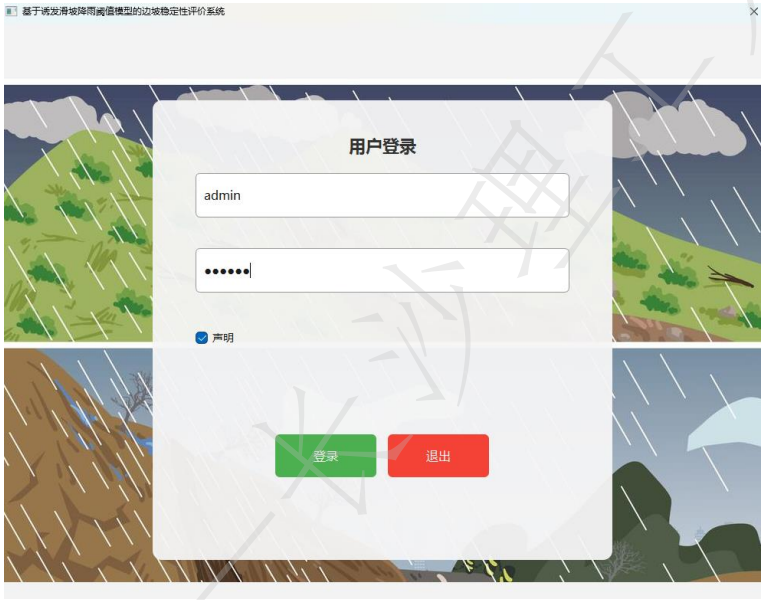



图 5.12 登录

（3）实例计算及应用

登录进系统后，我们点击“预警分析”选项对诱发滑坡的降雨阈值系数进行预测。首先输入边坡的四个特征参数，这里我们取边坡高度为 35m，边坡倾角为 60°，土的粘聚力为 15kpa，土的内摩擦角为 20º。然后点击预测，系统会自动根据输入的四个特征参数调用 robit 文件夹中的 main.py 文件脚本进行随机森林模型的训练。最后将训练的结果会在右侧的输出框中显示出来，如下图 5.13 所示，$-\beta=-1.5715$，$\log(\alpha)=3.1482$。



2025. 04. 10. 22. 12. 207791




图 5.13 降雨阈值系数预测结果图

为了能更加直观的了解降雨阈值系数$\alpha$、$\beta$，我们在系统中设计“绘图”键，即利用数形结合的思维把降雨阈值系数在直角坐标系上表示出来，这里是通过用降雨阈值曲线来表示降雨阈值系数$\alpha$、$\beta$。

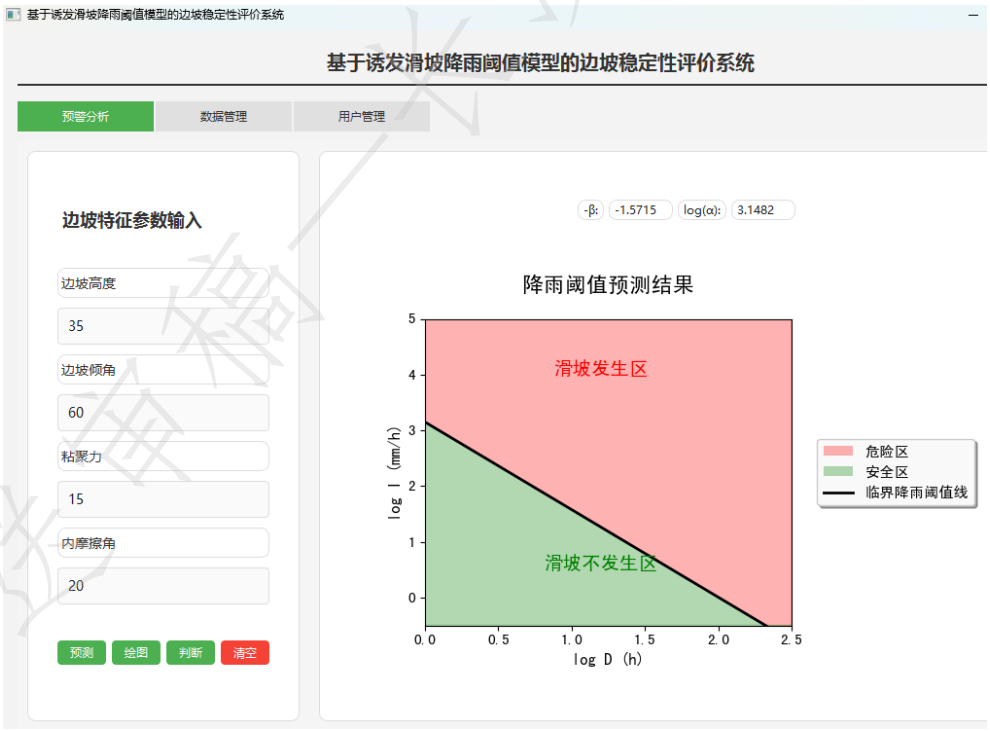



图 5.14 降雨阈值函数图

同时为了能在直角坐标系中更直观形象的反映出致灾区，我们通过把横坐标与纵坐



2025.04.10.22.12.207791

标对角化，即利用 $\log I = \log\alpha - \beta\log D$ 公式进行函数一次化。降雨阈值曲线则变化为降雨阈值一次函数，截距为 $\log(\alpha)$，斜率为 $-\beta$。此时图形分为上下两部分，上方为滑坡发生区，用红色表示；下方为滑坡不发生区，用绿色表示，并根据图 5.14 很容易的看出截距与斜率。

此时完成了降雨阈值系数预测和函数绘图，我们可以通过降雨阈值函数图来对滑坡进行一个灾害防治工作。可通过气象部门发出的降雨信息对潜在滑坡进行预警，而此系统的滑坡预警功能正能应对该情况。具体操作如下，首先点击系统“判断”键，程序会跳出图 5.15 所示的对话框，我们输入以降雨持续时间为 150h，降雨强度为 10mm/h 为例。然后点击“确定”键，系统会根据降雨参数值（即横坐标与纵坐标）判断点会落入哪个区域，如图 5.15 和图 5.16 所示，输入的降雨参数样本点落入到滑坡发生区，所以其判断结果为边坡不稳定。

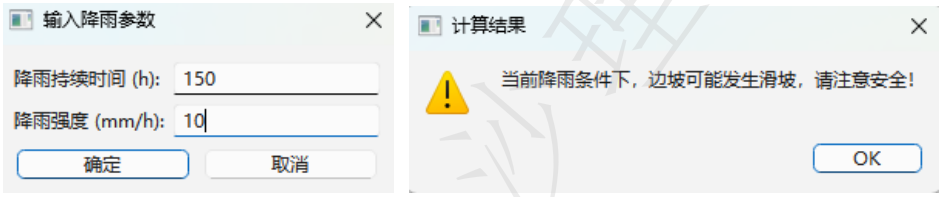



图 5.15 降雨参数输入及计算结果图（危险区）

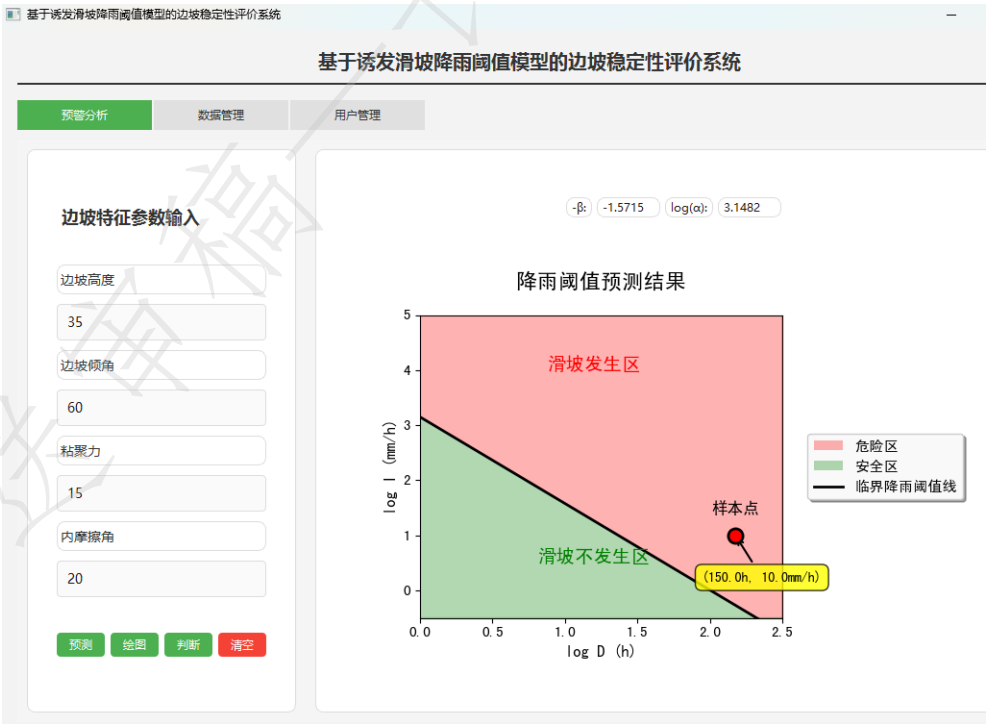



图 5.16 区域判定图（危险区）



2025.04.10.22.12.207791

同理，当我们对上述边坡输入其他降雨参数，例如输入降雨持续时间为 5h，降雨强度为 6mm/h。然后点击“确定”键，此时系统会根据输入的降雨参数值取对数化，然后会判断点会落入哪个区域，如图 5.17 和图 5.18 所示，输入的降雨参数样本点落入到滑坡不发生区，所以其判断结果为边坡稳定。




图 5.17 降雨参数输入图（安全区）

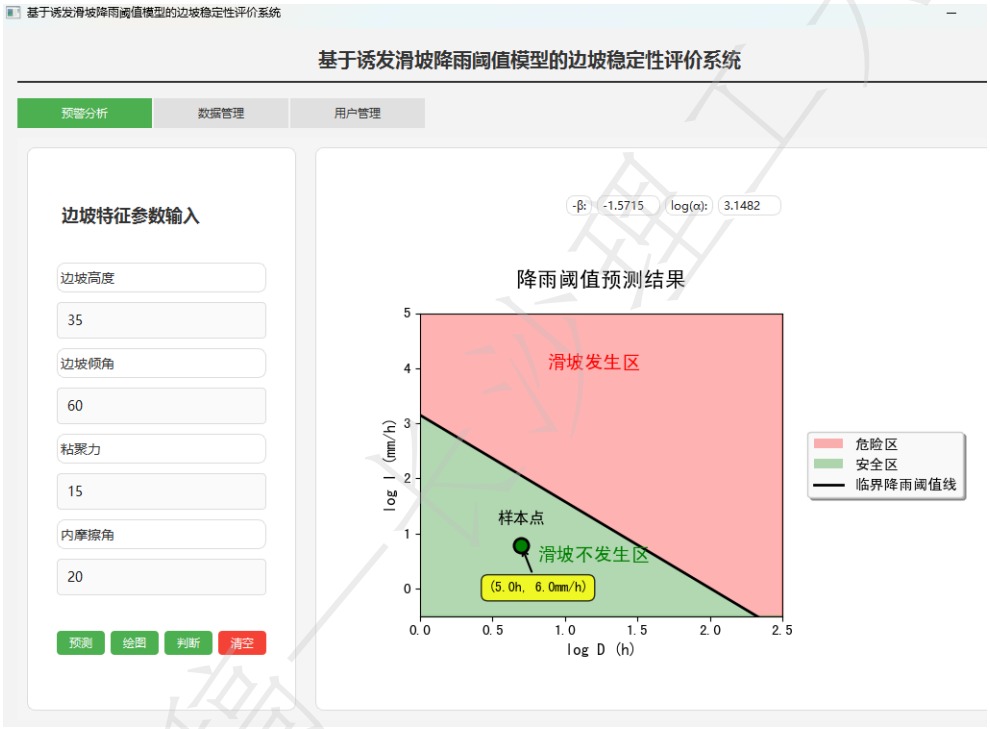



图 5.18 区域判定图（安全区）

由此可根据此系统的判定结果，提前作出预警通知，对沿线的居民下达撤退指令，以减少其人身和财产损失。

## 5.5 本章小结

本章着重阐述了基于诱发滑坡降雨阈值模型的边坡稳定性评价系统的设计与实现过程。

在系统分析与设计阶段，首先基于系统实际功能需求，明确了系统所需具备的功能，并对系统的开发环境进行了详细介绍。该系统主要使用 python 语言编写完成，以 python



2025.04.10.22.12.207801

为接口，在 ptQt6 界面中直接加载并通过 python 语言指令调用随机森林模型文件 main.py 来实现预测。而开发环境是通过安装 Anaconda 软件，并在 CMD 中输入 pip3 install PyQt6 -i https://pypi.tuna.tsinghua.edu.cn/simple 完成下载。

系统实现主要涵盖了用户管理、数据管理以及预警分析这三个核心功能模块。在用户管理方面，系统界面设计了系统登录、用户注册以及修改密码等基础功能模块；在数据管理上，为用户提供了一系列便捷的数据管理功能，其中包括数据的增加、删除、修改以及查询操作，并通过界面直观地展示出来，方便用户进行操作。预警分析则首先通过输入边坡特征参数来预测降雨阈值系数，并结合绘图功能将降雨阈值函数展示到直角坐标系中；其次利用 $\log I = \log \alpha - \beta \log D$ 表达式自动识别并画出滑坡发生区与不发生区；最后通过输入降雨参数并可视化样本点于坐标系中，来判断此降雨条件下是否会发生滑坡灾害，对降雨诱发滑坡的防灾减灾工作有着重要现实意义。

送审稿—长沙理工大学



2025. 04. 10. 22. 12. 207801

# 第6章 结论与展望

## 6.1 结论

本文以均质边坡模型为研究对象，通过理论分析、数值模拟和随机森林算法相结合的方法。以有限元软件 GeoStudio 模拟广泛降雨诱发滑坡生成的临界致灾数据为样本数据集，使用随机森林模型为评价工具，构建了基于随机森林的边坡安全系数预测模型。之后针对不同区域、不同土体由降雨诱发滑坡的降雨阈值进行研究，基于随机森林算法，将诱发滑坡的各种机制装入随机森林这个“黑盒子”中，通过输入特征参数从而得到该滑坡的降雨强度 *I*-降雨历时 *D* 函数表达式。最后结合 PyQt 技术来实现边坡稳定性评价系统业务功能的设计开发，完成了基于诱发滑坡降雨阈值模型的边坡稳定性评价系统的需求分析、系统架构设计、系统业务功能设计和数据库设计等部分。使前面所研究的内容进行可视化操作。全文工作的结论如下:

（1）建立了均质土质边坡，以非饱和土为研究对象，以降雨边坡相互作用为研究核心，以饱和/非饱和土力学为基础，研究降雨诱发滑坡机理。通过使用 GeoStudio 软件，模拟并分析了滑坡在降雨下土体渗流场与稳定性的变化情况。研究表明：降雨强度与入渗速率呈正相关，但超过土体阈值后差异消失。持续降雨导致孔隙水压梯度改变，浸润线抬升，5 天后土体完全饱和。安全系数呈现先陡降后缓降趋势，从初始 1.044 降至 0.716，饱和后稳定，反映渗流场与抗剪强度协同演化规律。

（2）基于 GeoStudio 软件生成的数据集，构建了以粘聚力 c、内摩擦角 φ、边坡倾角 Φ、边坡高度、降雨历时 *D* 及降雨强度 *I* 为输入特征，安全系数 *Fs* 为输出的随机森林（RF）边坡预测模型。测试结果表明，模型决定系数 $R^2$达 0.99998361、均方根误差仅 0.00132，验证集评估证实该模型具有极高的拟合精度，适用于实际边坡稳定性预测及工程指导。特征重要性分析揭示边坡高度是影响稳定性的首要因素，其权重系数显著高于其他特征参数。

（3）本研究通过集成随机森林算法与超参数优化方法，选取边坡几何参数（高度 *H*、倾角 Φ）与岩土力学参数（粘聚力 c、内摩擦角 φ）构建四维特征空间，以临界降雨强度（*I*）与临界降雨历时（*D*）为双输出量，建立多输入-多输出的降雨诱发滑坡阈值预



2025.04.10.22.12.207801

测模型。结果表明，采用全局寻优和交叉验证策略对模型超参数进行调优后，确定了最优超参数组合（max_depth=10，n_estimators=100，min_samples_split=2），模型性能显著提升：测试集均方误差降低 50.1%（0.108→0.054），决定系数 $R^2$提高 10.15%（0.824→0.908），表明优化后模型具有更好的预测精度与泛化能力。特征重要性分析揭示粘聚力为最敏感影响因素（贡献度最高）。该模型可通过准确预测降雨阈值，为滑坡灾害预警及防控决策提供科学依据，有助于降低滑坡灾害风险。

（4）本研究基于随机森林算法构建了诱发滑坡降雨阈值的边坡稳定性评价系统，通过 PyQt 框架设计了包含核心功能模块与数据管理体系的滑坡稳定性评价系统架构。结合数据实现了系统功能可视化，测试结果表明系统运行稳定，满足实际应用需求。

## 6.2 展望

本研究构建了基于随机森林算法的降雨诱发型滑坡阈值预测模型，并集成 PyQt 框架开发了边坡稳定性评价系统。但受研究深度限制，在模型构建和系统设计方面仍存在以下局限性：

（1）本研究是以均质边坡模型为研究对象，其土质土层假定为均质，但实际边坡中，大部分土体都是多层的。同时自然界中边坡几何形态具有显著不规则性，将其简化为标准几何形态可能导致临界安全系数评估存在偏差。后续研究需重点解决复杂地质条件下边坡数值模型的优化表征问题。

（2）在特征变量选取方面，本研究虽筛选了 6 个关键影响因子构建预测模型，但未充分考量渗透系数等对边坡渗流场具有显著调控作用的关键参数。未来应结合参数敏感性分析，建立更完备的多场耦合特征指标体系。

（3）当前系统采用单机架构实现本地数据样本的添加与管理，未能融合云端协同技术。在数字化技术快速发展的背景下，后续研究需引入分布式数据库架构，构建多用户协同的边坡灾害数据共享平台，以提升模型迭代优化效率。



2025.04.10.22.12.207801

# 参考文献


[1] D-M Cruden. A simple definition of a landslide[J]. Bulletin of the International Association of Engineering Geology - Bulletin de l'Association Internationale de Géologie de l'Ingénieur, 1991, 43(1): 27-29.

[2] 谢谟文，王纯祥，江崎哲郎，等. 滑坡发生地周围类似滑坡再发分析及灾害评价[J]. 岩石力学与工程学报, 2005, 24(15): 6.

[3] 孔纪名，田述军，阿发友，等. 贵州关岭"6.28"特大滑坡特征和成因[J]. 山地学报, 2010, (06): 87-93.

[4] Petley, D. Global patterns of loss of life from landslides[J]. Geology, 2012, 40(10): 927-930.

[5] Shibiao Bai, Wang Jian, Glade Thomas, et al. Rainfall Threshold Analysis and Landslide Susceptibility Mapping in Wudu County[A]//2013: 659-664.

[6] 唐栋，李典庆，周创兵，等. 考虑前期降雨过程的边坡稳定性分析[J]. 岩土力学, 2013, 34(11): 10.

[7] Avishek Dutta, Sarkar Kripamoy, Tarun Keshav. Machine learning regression algorithms for predicting the susceptibility of jointed rock slopes to planar failure[J]. Earth Science Informatics, 2024, 17(3): 2477-2493.

[8] Talas-Fikret Kurnaz, Erden Caner, Dağdeviren Uğur, et al. Comparison of machine learning algorithms for slope stability prediction using an automated machine learning approach[J]. Natural Hazards, 2024, 120(8): 6991-7014.

[9] Shan Lin, Zheng Hong, Han Bei, et al. Comparative performance of eight ensemble learning approaches for the development of models of slope stability prediction[J]. Acta Geotechnica, 2022, 17(4): 1477-1502.

[10] 者娜，刘才学，杨泰波，等. VMD 和随机森林在反应堆金属撞击信号识别中的应用研究[J]. 振动与冲击, 2021, 40(5): 102-107.

[11] L Breiman, Friedman J-H, Olshen R-A, et al. Classification and Regression Trees (CART)[J]. Biometrics, 1984, 40(3): 358.

[12] Leo Breiman. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.




2025. 04. 10. 22. 12. 207801

[13] 李亭，田原，邬伦，等. 基于随机森林方法的滑坡灾害危险性区划[J]. 地理与地理信息科学, 2014, 30(6): 7.

[14] 黎新裕. 基于机器学习法滑坡灾害信息的自动化提取——以汶川县绵虒镇为例[D]. 成都理工大学.

[15] 胡添翼，戴波，何启，等. 基于随机森林分类算法的边坡稳定预测模型[J]. 人民黄河, 2017, 39(5): 4.

[16] Fang Chen, Yu Bo, Xu Chong, et al. Landslide detection using probability regression, a case study of Wenchuan, northwest of Chengdu[J]. Applied Geography, 2017, 8932-40.

[17] 王红珠. 基于随机森林的山体滑坡状态监测系统设计与实现[D]. 西南交通大学, 2019.

[18] 孙德亮. 基于机器学习的滑坡易发性区划与降雨诱发滑坡预报预警研究[D]. 华东师范大学, 2019.

[19] 毛宇昆. 基于机器学习的滑坡稳定性评价及系统研发[D]. 2020.

[20] 刘睿，施娴娴，孙德亮，等. 基于 GIS 与随机森林的巫山县滑坡易发性区划[J]. 重庆师范大学学报：自然科学版, 2020, 37(3): 11.

[21] Yimo Liu, Zhang Wanchang, Zhang Zhijie, et al. Risk Factor Detection and Landslide Susceptibility Mapping Using Geo-Detector and Random Forest Models: The 2018 Hokkaido Eastern Iburi Earthquake[J]. Remote Sensing, 2021, 13.

[22] Aaron Maxwell, Sharma Shikha, Kite J, et al. Slope Failure Prediction Using Random Forest Machine Learning and LiDAR in an Eroded Folded Mountain Belt[J]. Remote Sensing, 2020, 12486.

[23] Hua-Jian Ding, Liu Jing-Yang, Zhang Chun-Mei, et al. Predicting optimal parameters with random forest for quantum key distribution[J]. Quantum Information Processing, 2020, 19(2): 60.

[24] P Reichenbach, Cardinali M, De Vita P, et al. Regional hydrological thresholds for landslides and floods in the Tiber River Basin (central Italy)[J]. Environmental Geology, 1998, 35(2): 146-159.

[25] F Guzzetti, Peruccacci S, Rossi M, et al. Rainfall thresholds for the initiation of landslides in central and southern Europe[J]. Meteorology and Atmospheric Physics, 2007, 98(3): 239-267.

[26] Ranjan-Kumar Dahal, Hasegawa Shuichi. Representative rainfall thresholds for landslides in the Nepal Himalaya[J]. Geomorphology, 2008, 100(3): 429-443.



2025. 04. 10. 22. 12. 207801

[27] HASNAWIR, KUBOTA Tetsuya. Analysis for early warning of sediment-related disaster in Mt. Bawakaraeng Caldera, South Sulawesi, Indonesia[J]. Journal of the Japan Society of Erosion Control Engineering, 2009, 62(4): 38-45.

[28] E-I Nikolopoulos, Borga M, Creutin J-D, et al. Estimation of debris flow triggering rainfall: Influence of rain gauge density and interpolation methods[J]. Geomorphology, 2015, 24340-50.

[29] T Endo. Probable distribution of the amount of rainfall causing landslides[J]. 1970.

[30] T ONODERA, YOSHINAKA R, KAZAMA H. SLOPE FAILURES CAUSED BY HEAVY RAINFALL IN JAPAN[J]. Journal of the Japan Society of Engineering Geology, 1974, 15(4): 191-200.

[31] Nel Caine. The Rainfall Intensity - Duration Control of Shallow Landslides and Debris Flows[J]. Geografiska Annaler: Series A, Physical Geography, 1980, 62(1-2): 23-27.

[32] M Moser, Hohensinn F. Geotechnical aspects of soil slips in Alpine regions[J]. Engineering Geology, 1983, 19(3): 185-211.

[33] Marco Borga, Dalla Fontana Giancarlo, Gregoretti Carlo, et al. Assessment of shallow landsliding by using a physically based model of hillslope stability[J]. Hydrological Processes, 2002, 162833-2851.

[34] M Casadei, Dietrich W, Miller Norman. Testing a model for predicting the timing and location of shallow landslide in soil-mantled landscapes[J]. Earth Surface Processes and Landforms, 2003, 28925-950.

[35] Alfonso Gutiérrez-Martín. A GIS-physically-based emergency methodology for predicting rainfall-induced shallow landslide zonation[J]. Geomorphology, 2020, 359107121.

[36] 陈志强，王亮清，刘顺昌. 基于斜率阈值法的滑坡预报分析[J]. 人民长江, 2010, 41(10): 5.

[37] Walter-F Megahan. Hydrologic effects of clearcutting and wildfire on steep granitic slopes in Idaho[J]. Water Resources Research, 1983, 19(3): 811-819.

[38] S-H Cannon, Ellen S-D. Rainfall conditions for abundant debris avalanches, San Francisco Bay region, California[J]. 1985.

[39] 魏丽，单九生，边小庚. 降水与滑坡稳定性临界值试验研究[J]. 气象与减灾研究, 2006, (2): 7.

[40] 常金源，包含，伍法权，等. 降雨条件下浅层滑坡稳定性探讨[J]. 岩土力学, 2015, 36(4): 7.

[41] 何玉琼，徐则民，王志奇，等. 滑坡降雨阈值模型的应用[J]. 吉林大学学报(地), 2012, 42(4): 1112-1118.



2025. 04. 10. 22. 12. 207801

[42] Chen Chien-Yuan, Tien-Chien Chen, Fan-Chieh Yu, et al. Rainfall duration and debris-flow initiated studies for real-time monitoring[J]. Environmental Geology, 2005, 47(5): 715-724.

[43] 谢剑明，刘礼领，殷坤龙，等. 浙江省滑坡灾害预警预报的降雨阀值研究[J]. 2004.

[44] 詹良通，李鹤，陈云敏，等. 东南沿海残积土地区降雨诱发型滑坡预报雨强-历时曲线的影响因素分析[J]. 岩土力学, 2012, 33(3): 10.

[45] 陈洪凯，魏来，谭玲. 降雨型滑坡经验性降雨阈值研究综述[J]. 重庆交通大学学报（自然科学版）, 2012, 031(005): 990-996.

[46] 沈玲玲，刘连友，杨文涛，等. 基于 TRMM 降雨数据的四川省地质灾害降雨阈值分析[J]. 灾害学, 2015, 30(2): 8.

[47] 杨攀，杨军. 考虑前期降雨的边坡稳定降雨阈值曲面[J]. 岩土力学, 2015, (S1): 6.

[48] 李巍岳，刘春，Marco，等. 基于滑坡敏感性与降雨强度-历时的中国浅层降雨滑坡时空分析与模拟[J]. 中国科学：地球科学, 2017, (004): 47.

[49] M-E Reid, Lahusen R-G. Real-time monitoring of active landslides along Highway 50, El Dorado County[J]. 1998.

[50] E-W Brand, Premchitt J, Phillipson H-B. Relationship between rainfall and landslides in Hong Kong[J]. 1984.

[51] David-R Montgomery, Dietrich William-E. A physically based model for the topographic control on shallow landsliding[J]. Water Resources Research, 1994, 30(4).

[52] M Mejia-Navarro, Wohl E-E. Geological hazard and risk evaluation using GIS: methodology and model applied to Medellin, Colombia[J]. Environmental & Engineering Geoscience, 1994, 31(4): 459-481.

[53] 杨万桥. 滑坡监测预警国内外研究现状及评述[J]. 工业 C, 2016, (6): 282.

[54] Ranjan-Kumar Dahal, Hasegawa Shuichi. Representative rainfall thresholds for landslides in the Nepal Himalaya[J]. Geomorphology, 2008, 100(3-4): 429-443.

[55] Adrian Wicki, Lehmann Peter, Hauck Christian, et al. Assessing the potential of soil moisture measurements for regional landslide early warning[J]. Landslides, 2020, 17(8): 1881-1896.

[56] Niu Hongtao. Smart safety early warning model of landslide geological hazard based on BP neural network[J]. Safety Science, 2020, 123104572.



2025. 04. 10. 22. 12. 207801

[57] 王兰生，李曰国，詹铮. 1981 年暴雨期四川盆地区岩质滑坡的发育特征[J]. 大自然探索, 1982, (1): 44-51.

[58] 殷坤龙，晏同珍. 汉江河谷旬阳段区域滑坡规律及斜坡不稳定性预测[J]. 地球科学, 1987, (06): 67-74.

[59] 惠振德，李晓玲. 陕南山区滑坡发育特征与敏感性分析[J]. 陕西师大学报：自然科学版, 1996, 24(1): 6.

[60] 王平. 基于 GIS 的自然灾害区划方法研究[J]. 地学前缘, 2001, 8(004): 321-322.

[61] 赵海卿，李广杰，张哲寰. 吉林省东部山区地质灾害危害性评价[J]. 吉林大学学报：地球科学版, 2004, 34(1): 6.

[62] 李铁锋，丛威青. 基于 Logistic 回归及前期有效雨量的降雨诱发型滑坡预测方法[J]. 中国地质灾害与防治学报, 2006, 17(1): 33-35.

[63] 程温鸣，彭令，牛瑞卿. 基于粗糙集理论的滑坡易发性评价——以三峡库区秭归县境内为例[J]. 中南大学学报：自然科学版, 2013, (3): 8.

[64] 戴岚欣，许强，范宣梅，等. 2017 年 8 月 8 日四川九寨沟地震诱发地质灾害空间分布规律及易发性评价初步研究[J]. 工程地质学报, 2017, 25(4): 14.

[65] 文海家，李洋，薛靖元，等. 基于大数据挖掘的山区公路沿线滑坡易发性小区划[J]. 自然灾害学报, 2018, 27(4): 7.

[66] 王慧芳，林子雁，肖燚，等. 基于生态系统服务潜在损失的滑坡灾害生态风险评价[J]. 应用生态学报, 2019, 30(10): 10.

[67] 李明波，王心悦，陈植华，等. 湖南雪峰山地区降雨型滑坡灾害临界雨量及预警区划分析[J]. 甘肃科学学报, 2019, 31(6): 6.

[68] 李明波，陈平，陈植华，等. 基于多模块的松散土质滑坡灾害综合预警模型研究[J]. 西北师范大学学报：自然科学版, 2020, 56(2): 7.

[69] 杨剑锋，乔佩蕊，李永梅，等. 机器学习分类问题及算法研究综述[J]. 统计与决策, 2019, (6): 5.

[70] Milad Malekipirbazari, Aksakalli Vural. Risk Assessment in Social Lending via Random Forests[J]. Expert Systems with Applications, 2015.

[71] Pall-Oskar Gislason, Benediktsson Jon-Atli, Sveinsson Johannes-R. Random Forests for land cover classification[J]. Pattern Recognition Letters, 2006, 27(4): 294-300.



2025. 04. 10. 22. 12. 207801

[72] Amanda Smith, Sterba-Boatwright Blair, Mott Joanna. Novel application of a statistical technique, Random Forests, in a bacterial source tracking study[J]. Water Research, 2010, 44(14): 4067-4076.

[73] B Efron, Tibshirani R-J. An introduction to the bootstrap. Monographs on Statistics and Applied Probability, No. 57. Chapman and Hall, London, 436 p[J]. 1993.

[74] 宁爽. 浅谈 C/S 架构下的高校学籍管理系统[J]. 电脑知识与技术：学术版, 2014, (7X): 4.

[75] Navid Kardani, Zhou Annan, Nazem Majidreza, et al. Improved prediction of slope stability using a hybrid stacking ensemble method based on finite element analysis and field data[J]. Journal of Rock Mechanics and Geotechnical Engineering: English Edition, 2021.

[76] H Rahardjo, Ong T-H, Rezaur R-B, et al. Factors Controlling Instability of Homogeneous Soil Slopes under Rainfall[J]. Journal of Geotechnical & Geoenvironmental Engineering, 2007, 133(12): 1532-1543.

[77] 武梦婷，陈秋松，齐冲冲. 基于机器学习的边坡安全稳定性评价及防护措施[J]. 北京科技大学学报, 2022, 044(002): 180-188.

[78] Chongchong-Qi A, B Xiaolin-Tang. Slope stability prediction using integrated metaheuristic and machine learning approaches: A comparative study[J]. Computers & Industrial Engineering, 2018, 118112-122.

[79] I-M Guyon, Gunn S-R, Nikravesh M, et al. Feature Extraction: Foundations and Applications[J]. Studies in Fuzziness & Soft Computing, 2006, 205(12): 68-84.

[80] 肖文鹏. 用 PyQt 进行 Python 下的 GUI 开发[J]. 中文信息：程序春秋, 2002, (7): 3.

[81] 李艳民. 基于 Qt 跨平台的人机交互界面的研究和应用[D]. 重庆大学, 2008.

[82] Christopher-R-J Kilburn, Petley David-N. Forecasting giant, catastrophic slope collapse: lessons from Vajont, Northern Italy[J]. 2003, 54(1-2): 32.



2025. 04. 10. 22. 12. 207801

# 致谢

送审稿—长沙理工大学



2025.04.10.22.12.207801

# 附录 A 攻读学位期间的主要研究成果

送审稿—长沙理工大学



2025.04.10.22.12.207801

# 附录 B 攻读学位期间主持（参与）的科研（实践）项目

**参与的科研（实践）项目：**

[1] 国家自然科学基金（******）：降雨作用下层状碎裂岩体结构面软化特性及顺倾边坡稳定性研究，2022.1-2024.12

[2] 湖南省自然资源厅科研项目（******）：降雨型滑坡变形破坏机理与预测模型研究，2022.1-2023.12

[3] 湖南水利科技项目（******）,湘江尾闾崩岸机理及处理措施研究，2021.09-2023.09

送审稿—长沙理工大学



2025.04.10.22.12.207801